




路由器 QoS 专题

文档版本 04
发布日期 2017-10-25

华为技术有限公司



版权所有 © 华为技术有限公司 2017。 保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明



HUAWEI 和其他华为商标均为华为技术有限公司的商标。

本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

您购买的产品、服务或特性等应受华为公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，华为公司对本文档内容不做任何明示或默示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

华为技术有限公司

地址： 深圳市龙岗区坂田华为总部办公楼 邮编：518129

网址： <http://www.huawei.com>

客户服务邮箱： support@huawei.com

客户服务电话： 4008302118

前 言

概述

本文档系统介绍了华为的 NE40E/80E/5000E、CX600 和 ME60 产品的 QoS 实现原理，并结合硬件介绍了设备转发平面的 QoS 处理流程。

产品版本



本文档不包含产品的具体版本实现差异和详细参数，单板差异以 VRPV5 版本为例。

修订记录

文档版本	发布时间	修改记录
04	2017-10-25	对 3.3.3 BA 和 PHB 详解章节做了如下更正： • 为了便于描述，将“BA 开关”改为“Remark 开关”。 • 用于做上行映射（BA）的 QoS 优先级字段，对于非 IP 也非 MPLS 报文的 BA，增加了单板差异描述。 • diffserv-mode { pipe short-pipe } 命令不影响 Remark 开关和 PHB 开关的状态。 • 修改“报文哪些优先级字段会在 PHB 反射动作中被修改”章节的描述。 • 修改“新增 MPLS 头的 EXP 值设置”章节的描述。 对 6.3 MPLS DiffServ 配置解析章节增加“PHB 动作是否修改 DSCP 字段，取决于单板类型和接口配置”小节。 对 5.3 拥塞避免的所有图片作了修正，WRED 对于超过最大丢弃概率时的丢包率并不是 100%而是配置值，只有当队列长度超过限制时丢包率才是 100%。

文档版本	发布时间	修改记录
03	2016-03-18	新增章节： • 4.5 流量监管和整形支持列表 • 9 协议报文的 QoS 处理 • 3.3.3 BA 和 PHB 详解 • 6.3 MPLS DiffServ 配置解析 • 3.6 流分类和标记常见问题解答 • 4.6 流量监管和整形常见问题解答 • 3.5.1 简单流分类实现差异 • 3.5.2 复杂流分类实现差异 • 4.4.1 流量监管和整形的单板实现差异 • 5.6 单板实现差异 • 6.7.1 MPLS DiffServ 实现差异 • 10 单板类型描述约定 修改章节： • 章节“5.3 拥塞避免”中的随机数 i 的取值范围由 $0 < i \leq a\%$ 更正为 $0 < i \leq 100\%$ • 修改了章节“5.4 队列缓存对时延和抖动的影响”中对抖动的描述。 • 修改了章节“4.2 流量整形”中对接口整形的描述。 • 8 路由器 QoS 转发全流程章节中加上、下行单板对 remark、service-class、qos car 三条命令执行顺序的描述。 • 3.4.4 QPPB 章节中，“典型应用一：AS 域间流量分类”的描述“在 Node-C 上的 AS100 域内所有接口使能针对目的地址的 QPPB”改为“在 Node-C 上的 AS100 域内所有接口使能针对源地址的 QPPB”；“在 Node-C 上与 AS400 相连的接口使能针对源地址的 QPPB”改为“在 Node-C 上与 AS400 相连的接口使能针对目的地址的 QPPB”。 • 删除“6.2 MPLS DiffServ”章节中的描述：“因此 Pipe 模式不支持倒数第二跳弹出 MPLS 标签。”
02	2014-08-25	新增章节： • 5.4 队列缓存对时延和抖动的影响 修改章节： • 将章节 8 路由器 QoS 转发全流程移至文章末尾“参考文献”之前。 • eTM 全称改为 egress Traffic Manager。 • “8 路由器 QoS 转发全流程”章节中，“转发过程中的

文档版本	发布时间	修改记录
		QoS 处理”的图 1-4，下行复杂流分类多了一条绿线。正确的是下行复杂流分类不使用内部流标记。 • 文中的 MDRR 更正为 DWRR。 • “4.1.2 令牌桶算法”的单速率令牌桶结构图，C 桶的 CBS 更正为等于 C 桶的深度，之前只标记到 C 桶的一半。 • “8 路由器 QoS 转发全流程”章节中，子接口终结接入 VPLS 场景--报文入隧道时的格式转换，图中的下行 TM，更正为 L2 Header(14)放在 Frame Header(14)的下面。 • “4.1.2 令牌桶算法”章节中的参数设置：对于超额突发流量 EBS，单位误写为 bit，更正为 byte。 • “4.1.2 令牌桶算法”章节中的单速率令牌桶“C 桶容量为 CBS，E 桶容量为 EBS，总容量是 CBS+EBS。”句子中删除“总容量是 CBS+EBS”。 • “4.1.3 CAR”章节中，双速双桶报文转发中，包序号为 2 的报文到来时，令牌增加后 C 桶令牌数量更正为 625。序号 3 报文到来时，C 桶距上次添加令牌时间更正为 1 秒（之前误写为 2 秒），且本轮 C 桶添加令牌数更正为 125。 • “5.2 队列及拥塞管理”章节中所有表格标题第 1 列，队列类型更正为服务等级。 • “5.2 队列及拥塞管理”章节中，对缓存队列的说明，移至新增的章节“6.4 队列缓存对时延和抖动的影响”。 • “5.3 拥塞避免”章节中，对队列最大长度的设置的详细介绍，移至新增章节“6.4 队列缓存对时延和抖动的影响”。 • “8 路由器 QoS 转发全流程”章节中，关于报文补偿的补充说明，对表格中 vlan-mapping-outbound、vll-outbound、vll-outbound1 的转换类型描述做了更正。 • “1.4 端到端 QoS 服务模型”章节中的句子“InterServ 模型能够在 IP 网上提供端到端的 QoS 保证。但是 InterServ 模型可扩展性差，难以在 IP 骨干网实施。”中，“InterServ”拼写错误，更正为“IntServ”。
01	2012-11-27	首次发布

目 录

前 言.....	ii
1 QoS 简介	1
1.1 什么是 QoS.....	1
1.2 QoS 度量指标.....	2
1.3 几种常见业务的 QoS 指标.....	5
1.4 端到端 QoS 服务模型	6
2 DiffServ 体系结构.....	9
2.1 DiffServ 网络模型	9
2.2 DSCP 与 PHB	10
2.3 四大 QoS 组件	13
3 流分类和标记	15
3.1 流分类与流动作	15
3.2 标记 QoS 优先级的报文字段	17
3.3 简单流分类.....	20
3.3.1 什么是简单流分类	20
3.3.2 QoS 优先级映射	20
3.3.3 BA 和 PHB 详解	27
3.4 复杂流分类.....	35
3.4.1 什么是复杂流分类	35
3.4.2 基于复杂流类的 QoS 策略.....	37
3.4.3 复杂流分类中的 ACL 匹配规则	40
3.4.4 QPPB.....	46
3.5 单板实现差异.....	53
3.5.1 简单流分类实现差异	53
3.5.2 复杂流分类实现差异	54
3.6 流分类和标记常见问题解答.....	61
3.6.1 简单流分类缺省映射表是否为 RFC 标准定义的?	61
3.6.2 可否同时重标记多个优先级字段?	61
3.6.3 当同一个流策略中配置多个流分类和流行为时, 执行顺序是什么样的?	61
3.6.4 如果入接口没有配置简单流分类, 设备缺省的行为是什么?	61

4 流量监管和流量整形	62
4.1 流量监管	62
4.1.1 流量监管简介	62
4.1.2 令牌桶算法	63
4.1.3 CAR	68
4.1.4 流量监管的应用	72
4.2 流量整形	76
4.3 流量监管和流量整形的比较	85
4.4 单板实现差异	86
4.4.1 流量监管和整形的单板实现差异	86
4.5 流量监管和整形支持列表	88
4.6 流量监管和整形常见问题解答	93
4.6.1 流量监管和整形分别在什么情况下执行?	93
4.6.2 基于端口和基于流的流量整形有什么区别?	94
4.6.3 流量整形是否会影响设备的其他功能?	94
4.6.4 使用流量整形, 最大时延是多少?	94
4.6.5 队列缓存的缺省长度是多少?	95
4.6.6 如果出接口不配置流量监管和整形, 其缺省行为是什么?	95
5 拥塞管理和避免	96
5.1 网络拥塞及其对策	96
5.2 队列及拥塞管理	99
5.3 拥塞避免	111
5.4 队列缓存对时延和抖动的影响	115
5.5 HQoS	116
5.6 单板实现差异	141
6 MPLS QoS	143
6.1 MPLS QoS 简介	143
6.2 MPLS DiffServ	144
6.3 MPLS DiffServ 配置解析	150
6.4 MPLS-TE	153
6.5 MPLS DiffServ-Aware TE	161
6.6 MPLS VPN QoS	176
6.7 单板实现差异	181
6.7.1 MPLS DiffServ 实现差异	181
7 ATM QoS	183
7.1 ATM QoS 概述	183
7.2 ATMoPSN 及 PSNoATM 的 QoS	192
8 路由器 QoS 转发全流程	199

9 协议报文的 QoS 处理	212
10 单板类型描述约定	218
11 参考文档	220
11.1 RFC 参考文档	220
11.2 宽带论坛参考文档	222
11.3 DSL 论坛参考文档.....	222
12 缩略语	223

1 QoS 简介

关于本章

- 1.1 什么是 QoS
- 1.2 QoS 度量指标
- 1.3 几种常见业务的 QoS 指标
- 1.4 端到端 QoS 服务模型

1.1 什么是 QoS

随着网络技术的飞速发展，互联网中的业务越来越多样化。除了传统的 WWW、E-Mail、FTP 应用外，用户还尝试在 Internet 上拓展新业务，比如 IP 电话、电子商务、多媒体游戏、远程教学、远程医疗、可视电话、电视会议、视频点播、在线电影等。企业用户也希望通过 VPN 技术，将分布在各地的分支机构连接起来，开展一些事务性应用，比如访问公司的数据库或通过 Telnet 管理远程设备。

图1-1 互联网业务



网络的普及，业务的多样化，使互联网流量激增，产生网络拥塞，转发时延增加，严重时还会产生丢包，导致业务质量下降甚至不可用。所以，要在 IP 网络上开展这些实时性业务，就必须解决网络拥塞问题。

解决网络拥塞的最好的办法是增加网络的带宽。但从运营、维护的成本考虑，这是不现实的，最有效的解决方案就是应用一个“有保证”的策略对网络拥塞进行管理。

QoS 技术就是在这种背景下发展起来的。QoS 是 Quality of Service（服务质量）的简称，其目的是针对各种业务的不同需求，为其提供端到端的服务质量保证。QoS 技术在当今的互联网中应用越来越多，其作用越来越重要。如果没有 QoS 技术，业务的服务质量就无法保证。

1.2 QoS 度量指标

QoS 采用如下参数来度量，为关键业务提供服务质量保证，使其获得可预期的服务水平。

- 带宽/吞吐量
- 时延
- 时延变化（抖动）
- 丢包率

带宽/吞吐量

带宽（bandwidth）也称为吞吐量（throughput），是指在一个固定的时间内（1 秒），从网络一端流到另一端的最大数据位数，也可以理解为网络的两个节点之间特定数据流的平均速率。带宽的单位是比特/秒（bit/s，简称为 bps）。

带宽可以用城市的供水网做比喻来帮助理解它的含义：供水管道的直径可以衡量运水的能力。水管的直径好比是带宽，水就好比是网络传输的数据。使用粗管子就意味着拥有更宽的带宽，也就是有更大的数据传输能力。

在网络通信中，人们在使用网络时总是希望带宽越来越宽，特别是互联网日益强大，人们对互联网的需求不再是单一地浏览网页、查看新闻。新一代多媒体、影像传输、数据库、网络电视的信息量猛增使得带宽成为了严重的瓶颈。因此，带宽成为网络设计主要的设计点，也是分析网络运行情况的要素。

图1-2 带宽太小





说明

在网络中，有两个常见的与带宽有关的概念——“上行速率”、“下行速率”。上行速率是指用户向网络发送信息时的数据传输速率，下行速率是指网络向用户发送信息时的传输速率。例如，用户用 FTP 上传文件到网上，影响上传速度的就是“上行速率”；而从网上下载文件，影响下载速度的就是“下行速率”。

时延

时延（Latency）是指一个报文或分组从一个网络的一端传送到另一端所需要的时间。

以语音传输为例，时延是指从说话者开始说话到对方听到所说内容的时间。若时延太大，会引起通话声音不清晰、不连贯或破碎。

大多数用户察觉不到小于 100 毫秒的延迟；当延迟在 100 毫秒和 300 毫秒之间时，说话者可以察觉到对方回复的轻微停顿，这种停顿可能会使通话双方都感觉到不舒服。超过 300 毫秒，延迟就会很明显，用户开始互相等待对方的回复，当通话的一方不能及时接收到期望的回复时，说话者可能会重复所说的话，这样会与远端延迟的回复碰撞，导致重复。

图1-3 时延过大




时延变化（抖动）

时延变化是指同一业务流中不同分组所呈现的时延不同。时延变化也称为抖动（Jitter）。抖动主要是由于业务流中相继分组的排队等候时间不同引起的，是对服务质量影响最大的一个问题。

某些业务类型，特别是话音和视像等实时业务是极不容忍抖动的。分组到达时间的差异将在话音或视像中造成断续。

图1-4 抖动过大



抖动也会影响一些网络协议的处理，有些协议是按固定的时间间隔发送交互性报文，抖动过大会导致协议震荡。

所有传输系统都有抖动，只要抖动在规定容差之内就不会影响服务质量。利用缓存可以克服过量的抖动，但这将增加时延。

丢包率

少量的丢包（Loss）对业务的影响并不大，例如，在语音传输中，丢失一个比特或一个分组的信息，通话双方往往注意不到。在视像广播期间，丢失一个比特或一个分组可能造成在屏幕上瞬间的波形干扰，但视像很快恢复正常。即使用传输控制协议（TCP）传送数据也能处理少量的丢包，因为传输控制协议允许丢失的信息重发。但大量的丢包会影响传输效率。所以，QoS 更关注的是丢包的统计数据——丢包率。丢包率是指在网络传输过程中丢失报文占传输报文的百分比。

图1-5 丢包率过大



1.3 几种常见业务的 QoS 指标

在 IP 网络上不同的业务对带宽、时延、时延抖动和丢包率等都有不同的需求。下表列出了当前几种常见业务的 QoS 需求。

业务类型	带宽/吞吐量	时延	抖动	丢包率
电子邮件、文件传输、远程终端	需求低	容许时延	容许抖动	不敏感
HTML 网页浏览	需求不定	容许适当时延	容许适当抖动	不敏感
电子商务	需求适当	敏感	敏感	敏感，必须可靠传输
基于 IP 的语音（VoIP）和实时视频	需求低	非常敏感，要求可预计的时延	非常敏感	敏感，要求可预计的丢包率
流媒体	需求高	非常敏感，要求可预计的时延	非常敏感	敏感，要求可预计的丢包率

MEF 论坛几种常见业务 QoS 指标

载自 MEF 论坛，主要包括可用性、时延、抖动、丢包率和故障恢复时间 5 个方面。

Service Class	Service Characteristics	Service Performance
Premium	Real-time IP telephony or IP video applications	Availability>99.99% Delay<40ms Jitter<1ms Loss<0.1% Restoration time:50ms
Silver	Bursty mission critical data applications requiring low loss and delay (eg.,Storage)	Availability>99.99% Delay<50ms Jitter=N/A Loss<0.1% Restoration time:200ms
Bronze	Bursty data applications requiring bandwidth assurances	Availability>99.90% Delay<500ms Jitter=N/A Loss NA Restoration time:2s
Standard	Best effort service	Availability>97.00% Delay=N/A

Service Class	Service Characteristics	Service Performance
		Jitter=N/A Loss NA Restoration time:5s

业界对于几种常见业务 QoS 指标的经验值

业务类别		时延	抖动	丢包率
语音	媒体	≤50ms	≤10ms	≤1%
	信令	≤100ms	≤10ms	≤0.1%
IPTV	组播	≤1s	≤200ms	≤0.1%
	点播	≤10s	≤200ms	≤0.1%
FTP 下载		N/A	N/A	N/A
HTTP 下载		N/A	N/A	N/A
HTTP 浏览		≤10s	N/A	N/A
游戏	UDP	≤1000ms	≤50ms	≤5%
	TCP	≤500ms	≤50ms	≤5%

1.4 端到端 QoS 服务模型

网络应用都是端到端的通信，两个主机进行通信，中间可能要跨越多个物理网络，经过多个路由器，要实现端到端的 QoS，就必须从全局考虑。QoS 的服务模型就是研究采用什么模式实现全局的服务质量保证。

QoS 有如下三种服务模型：

- 尽力而为（Best-Effort）服务模型
- 综合服务（Integrated Service，简称 IntServ）模型
- 差分服务（Differentiated Service，简称 DiffServ）模型

Best-Effort 服务模型

Best-Effort 是最简单的 QoS 服务模型，应用程序可以在任何时候，发出任意数量的报文，而且不需要通知网络。对 Best-Effort 服务，网络尽最大的可能性来发送报文，但对时延、可靠性等性能不提供任何保证。

Best-Effort 服务模型适用于对时延、可靠性等性能要求不高的业务质量保证。Best-Effort 是现在 Internet 的缺省服务模型，它适用于绝大多数网络应用，如 FTP、E-Mail 等。


IntServ 模型

IntServ 模型是指应用程序在发送报文前，需要通过信令（signaling）向网络描述它的流量参数，申请特定的 QoS 服务。网络在流量参数描述的范围内，预留资源以承诺满足该请求。在收到确认信息，确定网络已经为这个应用程序的报文预留了资源后，应用程序才开始发送报文。应用程序发送的报文应该控制在流量参数描述的范围内。网络节点需要为每个流维护一个状态，并基于这个状态执行相应的 QoS 动作，来满足对应用程序的承诺。

IntServ 模型使用 RSVP（Resource Reservation Protocol）作为信令，类似于 ATM SVC 的方式，是面向连接的。RSVP 工作在传输层，但不参与应用数据的传送，是一种网络上的控制协议（类似于 ICMP），用于在网络节点间传递资源预留信息以及建立资源预留。

在通过 RSVP 建立端到端通信的过程中，沿途的各路由器（包括核心路由器）必须为每个要求服务质量保证的数据流保存状态信息，称为“软状态”。“软状态”是一种临时性状态，被定期的 RSVP 信息更新。通过 RSVP 信息的预留，各路由器可以判断是否有足够的资源可以预留。只有所有的路由器都给 RSVP 提供了足够的资源，“路径”方可建立。

图1-6 IntServ 模型



IntServ 模型使用的 RSVP 信令需要跨越整个网络进行资源请求/预留，因此要求端到端所有网络节点支持 RSVP 协议，且每个节点需要周期性同相邻节点交换状态信息，协议报文开销大。更关键的是，所有网络节点需要为每个数据流保存状态信息，而当前在 Internet 骨干网上有着成千上万条数据流，因此 IntServ 模型在 Internet 骨干网上无法得到广泛应用。IntServ 模型一般应用在网络的边沿。


DiffServ 模型

DiffServ 模型的基本原理是将网络中的流量分成多个类，每个类享受不同的处理，尤其是网络出现拥塞时不同的类会享受不同的优先处理，从而得到不同的丢弃率、时延以

及时延抖动。同一类的业务在网络中会被聚合起来统一发送，保证相同的延迟、抖动、丢包率等 QoS 指标。

Diffserv 模型中，业务流分类和汇聚工作在网络边缘由边缘路由器完成。边界路由器可以通过多种条件（比如报文的源地址和目的地址、ToS 域中的优先级、协议类型等）灵活地对报文进行分类，对不同的报文设置不同的标记字段，而其他路由器只需要简单地识别报文中的这些标记，进行资源分配和流量控制。因此，DiffServ 是一种基于报文流的 QoS 模型。

图1-7 DiffServ 模型



与 Intserv 模型相比，DiffServ 模型不需要信令。在 DiffServ 模型中，应用程序发出报文前，不需要预先向网络提出资源申请，而是通过设置 IP 报文头部的 QoS 参数信息，来告知网络节点它的 QoS 需求。网络不需要为每个流维护状态，而是根据每个报文流指定的 QoS 参数信息来提供服务，对报文的服务等级划分，有差别地进行流量控制和转发，提供端到端的 QoS 保证。

DiffServ 模型充分考虑了 IP 网络本身灵活性、可扩展性强的特点，将复杂的服务质量保证通过报文自身携带的信息转换为单跳行为，从而大大减少了信令的工作。因此，DiffServ 模型不但适合运营商环境使用，而且也大大加快了 IP QoS 在实际网络中应用的进程。

IntServ 模型和 DiffServ 模型的结合

DiffServ 模型只包含有限数量的服务等级，状态信息的数量少，因此实现简单，扩展性较好，是 IP 骨干网广泛使用的 QoS 解决方案。但 DiffServ 模型只能在单个节点上预留资源，很难提供基于流的端到端的质量保证。

IntServ 模型能够在 IP 网上提供端到端的 QoS 保证。但是 IntServ 模型可扩展性差，难以在 IP 骨干网实施。

针对以上两种模型的优缺点，MPLS DS-TE 将两种模型相结合，在有效利用网络资源的同时，为不同的业务提供端到端的 QoS 保证。

MPLS DS-TE 的详细实现原理请参见“6.5 MPLS DiffServ-Aware TE”。

2 DiffServ 体系结构

关于本章

[2.1 DiffServ 网络模型](#)

[2.2 DSCP 与 PHB](#)

[2.3 四大 QoS 组件](#)

2.1 DiffServ 网络模型


目前存在多种 IP QoS 服务模型，其中应用最广的是差分服务模型（DiffServ）。本文提到的技术都是基于 DiffServ 模型。

DiffServ 网络模型

DiffServ 的基本思想是在网络边缘将进入的流分成各种不同的类型，将同种类型的流合并起来进行统一管理，保证相同的传输速率、延迟、抖动等服务质量参数，并对每一种类型在网络中分别进行处理。

业务分类和汇聚工作在网络的边缘节点进行，首先数据包被标识为一定的服务类型，并记录在包头字段里，然后将包按一定的流量控制策略送入网络。网络中心节点通过检查包头来确定对包进行何种处理。

图2-1 DiffServ 网络模型



- **DS 节点：**实现 DiffServ 功能的网络节点称为 DS 节点。
- **DS 边界节点：**负责连接另一个 DS 域或者连接一个没有 DS 功能的域的节点。DS 边界节点负责将进入此 DS 域的业务流进行分类和可能的流量调整。
- **DS 内部节点：**用于在同一个 DS 域中连接 DS 边界节点和其他内部节点。DS 内部节点仅需基于 DSCP 值进行简单的流分类以及对相应的流实施流量控制。
- **DS 域（DS Domain）：**一组采用相同的服务提供策略和实现了相同 PHB（Per Hop Behaviors）的相连 DS 节点组成。一个 DS 域由相同管理部门的一个或多个网络组成，如一个 DS 域可以是一个 ISP，也可以是一个企业的内部网。



说明

PHB 将在本文下一节介绍。

- **DS 区：**一个或多个邻接的 DS 域统称为 DS 区。同一 DS 区中的不同 DS 域可有不同的 PHB，以实现不同的服务提供策略，它们之间通过 SLA（Service Level Agreements）和 TCA（Traffic Conditioning Agreement）协调提供跨域服务。SLA/TCA 指明了如何在 DS 域边界节点调整从一个 DS 域传向另一个 DS 域的业务流。
- **SLA：**SLA 指用户（个人、企业、有业务往来的相邻 ISP 等）和服务提供商签署的关于业务流在网络中传递时所应当获得的待遇。SLA 包括很多方面，例如付费协议，其中的技术说明部分称为服务等级规范 SLS（Service Level Specification）。SLS 的研究重点是流量控制说明 TCS（Traffic Conditioning Specification），它描述了每个服务层次的详细性能参数，如平均速率、峰值速率、承诺突发尺寸、最大突发尺寸等，是 DiffServ 网络进行流控的主要依据。


2.2 DSCP 与 PHB

DiffServ 模型的一个重要概念是在转发分组时体现服务等级的**每跳行为 PHB（Per Hop Behaviors）**。DiffServ 模型中，IETF 重新定义了 IPv4 中的 ToS 和 IPv6 中的 TC，称作 DS 字段，**DS 字段的取值称为 DSCP（DiffServ code point）**。不同的 DSCP 取值对应于不同的 PHB。

DSCP

RFC1349 重新定义了 IPv4 报文中的 ToS 域，增加了 C 比特，表示传输开销（Monetary Cost）。之后，RFC2474 将 IPv4 报文头 ToS 域中的比特 0~5 重新定义为 DSCP，并将 ToS 域改名为 DS（Differentiated Service）字节。

图2-2 DSCP 域



在 IPv4 报文中，DS 字节的低 6 位（比特 0~5）用作区分服务代码点 **DSCP**，高 2 位（比特 6、7）是保留位。DSCP 中的低 3 位（比特 0~2）是类选择代码点 **CSCP**（Class Selector Code Point），它表示了一类 DSCP。网络中支持 DiffServ 技术的各设备根据 DSCP 值选择相应的转发行为。

在 IPv6 报文中，有两个字段与 QoS 有关，分别为**流量类别 TC（Traffic Class）**和**流标签 FL（Flow Label）**字段。**流量类别**字段有 8 位，和 IPv4 的服务类型(ToS)字段功能相同，用于**对报文的业务类别进行标识**；**流标签**字段有 20 位，用于**标识属于同一业务流的包**。流标签和源、目的地址一起，**惟一标识了一个业务流**。同一个流中的所有包具有相同的流标签，以便对有同样 QoS 要求的流进行快速、相同的处理。

PHB

在每一个 DS 节点上对分组的处理称为每跳行为 PHB（Per-Hop Behavior）。PHB 描述了 DS 节点对具有相同 DSCP 的分组采用的外部可见的转发行为。可以用优先级来定义 PHB，也可以用一些可见的服务特征如分组延迟、抖动或丢包率来定义。PHB 只定义了一些外部可见的转发行为，没有指定特定的实现方式。

RFC 定义了四种标准的 PHB：**类选择码 CS（Class Selector）**，**加速转发 EF（Expedited Forwarding）**，**确保转发 AF（Assured Forwarding）**和**尽力而为 BE（Best-Effort）**。其中，BE 是缺省的 PHB。

表2-1 RFC 定义的各 PHB 对应的 DSCP 取值及含义

PHB	DSCP 取值	含义
CS (RFC2474)	XXX000, 其中 X 取值 0 或 1。当 X 为全 0 时, 就是 Default PHB, 即 BE 类型 PHB。 CS 定义的 DSCP=IP Precedence$\times$8, 比如 CS6=6$\times$8=48, CS7=7$\times$8=56。	CS 表示类选择码, 代表的服务等级与在现有网络中使用的 IP Precedence 相同。 说明 RFC2474 预留了所有格式为 XXX000 的值, 以提供与 IP 优先权值的后向兼容, 因为不支持 DiffServ 的设备只解析 ToS 字段的前 3 位 (最左 3 位)。
EF (RFC2598)	101110	EF 被定义为这样的一种转发处理: 从任何 DS 节点发出的信息流速率在任何情况下必须获得等于或大于设定的速率。EF PHB 在 DS 域内不能被重新标记, 仅允许在边界节点重新标记。 定义 EF PHB 的目标是在 DS 域内模拟一种虚拟租用线 (Virtual Leased Line) 的转发效果, 提供一种低丢包率、低延迟、低抖动, 确定带宽的转发服务。 EF 流要求低时延、低抖动、低丢包率, 对应于实际应用中的视频、语音、会议电视等实时业务。
AF (RFC2597)	XXX YY0, 其中 X 取值 0 或 1, XXX 对应 IP Precedence; YY 表示丢弃优先级, 数值越大, 丢弃优先级越高。 XXX 由于有三个 bit, 最大取值为 8, 但是目前只用到了 1~4, 即有 4 种 AF 类型: AF1y~AF4y (1$\leq$y$\leq$3)。	AF 的推出是为了满足这样的需求: 用户在与 ISP 订购带宽服务时, 允许业务量超出所订购的规格。对不超出所订购规格的流量要求确保转发的质量; 对超出规格的流量将降低服务待遇继续转发, 而不只是简单地被丢弃。 运营商在提供 AF 服务时, 为每类 AF 分配不同的带宽资源, 保证对 AF 类提供带宽, 对于多余的带宽允许其他数据使用。 AF 流要求较低的延迟、低丢包率、高可靠性, 对应于数据可靠性要求高的业务如电子商务、企业 VPN 等。
BE (RFC2474)	000000	对应于传统的 IP 分组投递服务, 只关注可达性, 其他方面不做任何要求。任何路由器必须支持 BE PHB。

表2-2 PHB 常见用途

PHB	常见用途
-----	------

PHB	常见用途
CS6、CS7	CS6 和 CS7 默认用于协议报文，比如说 OSPF 报文，BGP 报文等应该优先保障，因为如果这些报文无法接收会引起协议中断。
EF	EF 用于承载语音的流量，因为语音要求低延迟，低抖动，低丢包率，是仅次于协议报文的最重要的报文。 说明 EF PHB 提供的是低时延服务，应该具有最低的抖动和丢包率，因而必须限制 EF 的专用带宽，以免其他服务得不到可用带宽。
AF4	AF4 用来承载语音的信令流量。 说明 语音流量必须优先于语音的信令，因为语音信令是语音的呼叫控制，在接通的时候等待几秒钟是可以忍受的，但是在通话过程的中断是绝对不能允许的。所以语音要优先于信令。
AF3	AF3 可以用来承载 IPTV 的直播流量。直播的实时性强，需要有连续性和大吞吐量的保证。
AF2	AF2 可以用来承载 VoD（Video on Demand）的流量。VoD 要求的实时性不如 IPTV 直播强，允许有延迟或者缓冲。
AF1	AF1 可以承载专线业务，因为 IPTV 和语音是运营商最关键的业务，需要最优优先保证，其次才是专线业务。当然面向银行之类需要钻石级保证的业务，可以安排为 AF4 甚至为 EF。
BE	当前 Internet 尽力而为的服务。

2.3 四大 QoS 组件

DiffServ 模型有如下四个 QoS 组件：

- **流分类和标记（classification and marking）**要实现差分服务，需要首先将数据包分为不同的类别或者设置为不同的优先级。将数据包分为不同的类别，称为流分类，流分类并不修改原来的数据包。将数据包设置为不同的优先级称为标记，而标记会修改原来的数据包。



说明

这里的标记是“外部标记”，一般是在报文离开设备的时候对在报文中进行设置，修改报文 QoS 优先级字段，目的是为了将 QoS 信息传递给下一台设备；本文后面还有“内部标记”，用于设备内部处理报文，不修改报文。一般是在报文进入设备的时候，就通过流分类，给报文打上内部标记，这样，在报文从设备发出之前，都可以根据内部标记进行 QoS 处理。


- **流量监管和整形（Policing and Shaping）**：是指将业务流量限制在特定的带宽，当业务流量超过额定带宽时，超过的流量将被丢弃或缓存。其中，将超过的流量丢弃的技术称为流量监管，将超过的流量缓存的技术称为流量整形。
- **拥塞管理（Congestion management）**：在网络发生拥塞时，将报文放入队列中缓存，并采取某种调度算法安排报文的转发次序。

- **拥塞避免** (Congestion avoidance): 监督网络资源的使用情况, 当发现拥塞有加剧的趋势时采取主动丢弃报文的策略, 通过调整流量来解除网络的过载。

其中, 分类和标记是实现差分服务的前提和基础; 流量监管、流量整形、拥塞管理和拥塞避免从不同方面对网络流量及其分配的资源实施控制, 是提供差分服务的具体体现。


四个 QoS 组件在网络设备上有着一定的处理顺序, 一般情况下按下图所示的顺序处理。

图2-3 QoS 技术处理流程



四个 QoS 组件按照 DiffServ 模型和业务开展的需要, 需要在网络的不同位置实施。原则上在业务接入端口入方向实施流分类/标记、流量监管; 业务接入端口出方向实施流量整形 (如果业务接入端口接入多个不同等级的业务, 则业务接入端口出方向还要实施队列调度和丢包策略); 网络侧端口出方向实施拥塞管理和拥塞避免。

图2-4 QoS 四大组件部署位置示例



3 流分类和标记

关于本章

- 3.1 流分类与流动作
- 3.2 标记 QoS 优先级的报文字段
- 3.3 简单流分类
- 3.4 复杂流分类
- 3.5 单板实现差异
- 3.6 流分类和标记常见问题解答

3.1 流分类与流动作

流分类

流分类是对进入 DiffServ 域的业务进行分类，以便在网络中得到相应的适当处理。流分类主要目的是让其他处理此报文的应用系统或设备知道该报文的类别，并根据这种类别对报文进行一些事先约定的处理。

实现流分类的技术

业务流进入 DiffServ 域时，可以有多种方法对它进行分类，例如根据报文所携带的 QoS 优先级位（请参见下一节“3.2 标记 QoS 优先级的报文字段”），识别出不同优先级特征的流量，或根据源地址、目的地址、MAC 地址、IP 协议或应用程序的端口号等信息对流进行分类。也可以根据业务等级协议 SLA 规定的一些策略给每个数据包加上标记，从而对数据包进行分类。

当报文在 DiffServ 域边界被分类之后，在网络的中间节点，就可以根据分类，对不同类别的流量给予差别服务。下游（downstream）节点可以选择使用上游（upstream）节点的分类结果，也可以按照自己的分类标准对数据流重新进行分类。

因此，实现流分类的技术被分成“简单流分类（Behavior Aggregate Classifier）”与“复杂流分类（Multi-Field Classifier）”，这两种技术的详细介绍请参见本文“3.3 简单流分类”和“3.4 复杂流分类”。

流动作

进行流分类是为了有区别地提供服务，它必须与某种流量控制或资源分配动作关联起来才有意义。流量控制或资源分配动作被称为流动作。

在华为路由器上，目前针对流分类可实施的流动作包括以下几类（这些流动作可以组合使用）：

流动作		含义
标记	外部 标记	设置/改写报文的优先级字段，用于向下一台设备传递差分服务的 QoS 信息。其中，改写报文的优先级字段也称为“重标记”。
	内部 标记	标记报文在设备内部处理的服务等级（service-class）与丢弃优先级，让匹配的报文能够直接进入指定服务等级的队列，而不需要根据报文头中的优先级字段来确定服务等级。 标记报文的丢弃优先级也叫着色（color），是指在相同 service-class 的时候，入同一个队列，当此队列快拥塞的时候，可以通过 color 再进行差分服务，体现在缓存使用上的优先顺序。
流量监管		将业务流量限制在特定的带宽，当业务流量超过额定带宽时，超过的流量将被丢弃。
拥塞管理		在网络发生拥塞时，将报文放入队列中缓存，采取某种调度算法安排报文的转发次序同时对输出流量进行整形（Shaping），满足业务流量在 QoS 属性（带宽、时延、抖动、丢包率）方面的要求。
拥塞避免		通过监视队列缓存的使用情况，当队列缓存使用情况达到指定门限时，主动丢弃报文来解除网络过载。
报文过滤		最基本的安全手段。通过流分类，决定报文是被直接丢弃还是可以继续后面的转发处理。
重定向/策略路由		根据流分类决定报文的转发路径。分为强策略路由与弱策略路由。 - 强策略路由是指根据指定的 IP 地址查转发表，查到则转发；查不到则丢弃； - 弱策略路由是指根据指定的 IP 地址查转发表，查到则转发；如果查不到，再根据报文的目的 IP 地址查转发表。
负载分担		设置报文的负载分担方式为逐流或逐包。 只对存在多条转发路径的报文有效。多条转发路径分为两种情况： - 一种是存在多条转发表项； - 另外一种是只有一条转发表项，但转发表项中的出口是一个

流动作	含义
	Trunk 接口。
报文分片	改写 IP 报文头中的 DF 字段。 说明 对于从用户终端发出来的报文，存在 1500 字节的大包，而一般的 PC 会设置 IP 头中的 DF=1，即不允许中间的网络设备对报文分片，但是由于报文会经过接入、汇聚、核心等多个层次的网络设备，一般会在接入、汇聚层增加 TAG 等信息，这样会导致最终的报文长度超过 MTU（1500 字节）。此时，如果 IP 报文头的 DF=1，会导致此报文被丢弃，所以为了不丢弃报文，同时不让用户层应用感知，网络设备提供可以修改 IP 报文头的 DF 标志的功能。
URPF（Unicast Reverse Path Forwarding）	一种安全手段，根据报文的源 IP 地址反查路由表，确定报文源 IP 地址的合法性，防止源地址欺骗的攻击。
流镜像	设备复制一份和被观察流的原始报文一模一样的报文，并传送到指定的观察端口上。
流采样	收集特定数据流的时间戳、源地址、目的地址、源端口号、目的端口号、TOS 值、协议号、报文长度和被采样报文的入接口等信息，从而可以监控特定用户的通信情况。


3.2 标记 QoS 优先级的报文字段

DiffServ 模型根据报文头中某些字段记录的 QoS 信息提供有差别的服务质量。这些和 QoS 相关的报文字段包括：

IPv4 的 ToS 字段

对于 IPv4 报文，基于 IPv4 包首部中的 ToS 域的前三位（即 IP Precedence）或前 6 位（即 DSCP 域）来标记报文。使用 IP 优先级可以将报文最多分成 $2^3=8$ 类；使用 DSCP 域可将报文最多分成 $2^6=64$ 类。

图3-1 IPv4 首部的 ToS 域



RFC 1349 中定义的 TOS 域各比特位的含义：

- 比特 0~2 表示 Precedence 字段。代表报文传输的 8 个优先级，按照优先级从高到低顺序取值为 7、6、……、1 和 0。最高优先级是 7 或 6，经常是为路由选择或更新网络控制通信保留的，用户级应用仅能使用 0~5 级。
- D 比特表示延迟要求（Delay，0 代表正常延迟，1 代表低延迟）。
- T 比特表示吞吐量（Throughput，0 代表正常吞吐量，1 代表高吞吐量）。
- R 比特表示可靠性（Reliability，0 代表正常可靠性，1 代表高可靠性）。
- C 比特表示传输开销（Monetary Cost，0 代表正常传输开销，1 代表低传输开销）。
- 比特 6 和 7 保留。

RFC 2474 则定义比特 0~6 表示 DSCP 域，其中前 3 比特是类选择代码点 CSCP（Class Selector Code Point），它表示了一类 DSCP。网络中支持 DiffServ 技术的各设备根据 DSCP 值选择相应的 PHB。DSCP 和 PHB 的介绍请参见“2.2 DSCP 与 PHB”章节。

IPv6 的 TC 字段

在 IPv6 报文中，有两个字段与 QoS 有关，分别为流量类别 TC（Traffic Class）和流标签 FL（Flow Label）字段。流量类别字段有 8 位，和 IPv4 的服务类型(ToS)字段功能相同，用于对报文的业务类别进行标识；流标签字段有 20 位，用于标识属于同一业务流的包。流标签和源、目的地址一起惟一标识了一个业务流。同一个流中的所有包具有相同的流标签，以便对有同样 QoS 要求的流进行快速、相同的处理。

图3-2 IPv6 的 TC 字段

8 bit		20 bit		
Version	Traffic Class	Flow Label	Payload Length	...

MPLS 的 EXP 字段

对于 MPLS 报文，则一般是根据 MPLS 报文中的 EXP 域进行流分类。EXP 域包括 3 位，通常作为 MPLS 报文的 CoS 域，与 IP 网络的 ToS 或 DSCP 域等效。

图3-3 MPLS 报文首部中的 Exp 域

20bits	3bits	1bits	8bits
Label	Exp	S	TTL

MPLS 报文首部包含 3 比特的 Exp 字段，表示报文传输的 8 个优先级，按照优先级从高到低顺序取值为 7、6、……、1 和 0。

由于 IP 报文的优先级字段是 3bits，与 Exp 的长度相同，所以可以直接形成一对一的映射。但 IP 报文的 DSCP 字段是 6bits，与 EXP 的长度不一样，所以出现多对一的情

况。在 IEEE 标准的实现中，将 DSCP 的前 3bits（即 CSCP）与 EXP 进行映射，而忽略 DSCP 的后 3bits。

802.1q 帧的 CoS 字段

对于 VLAN 帧，根据 VLAN 帧头中的 CoS 字段（802.1p 优先级）进行流分类。VLAN 帧头中的 PRI 字段（即 802.1p 优先级）标识了服务质量需求，VLAN 帧中的 PRI 字段位置如下图所示。

图3-4 VLAN 帧头中的 802.1p 优先级

16bits	3bits	1bits	12bits
TPID	PRI	CFI	VLAN ID

在 VLAN 帧头中包含 3 比特长的 PRI 字段。PRI 字段表示 8 个传输优先级，按照优先级从高到低顺序取值为 7、6、……、1 和 0。


表3-1 802.1p/IP 优先级的典型应用

802.1p/IP Precedence	典型应用
7	预留给网络控制报文（例如路由协议报文）
6	
5	语音流
4	视频会议
3	呼叫信令
2	高优先级数据流
1	中等优先级数据流
0	BE 数据流

ATM 的 CLP 字段

ATM 信元的 CLP 字段标识了信元丢弃优先等级（Cell Loss Priority），长度是 1 比特，用于拥塞控制。发生拥塞时优先丢弃 CLP=1 的信元。

图3-5 ATM 帧的 CLP 字段



3.3 简单流分类

3.3.1 什么是简单流分类

简单流分类是指采用简单的规则，如只根据 IP 报文的 IP 优先级或 DSCP 值、IPv6 报文的 TC 值、MPLS 报文的 EXP 域值、VLAN 报文的 802.1p 值、ATM 报文的 CLP 值，对报文进行粗略的分类，以识别出具有不同优先级或服务等级特征的流量，实现外部优先级和内部优先级之间的映射。

简单流分类过程实际上就是信任端口的上行报文携带的优先级标记，并进行优先级映射（即根据优先级映射表，将上行报文携带的 QoS 优先级统一映射到设备内部的服务等级和颜色，将下行报文的内部的服务等级和颜色映射成为 QoS 优先级），详细的介绍请参见“3.3.2 QoS 优先级映射”章节。

在华为路由器上，配置简单流分类就是配置 DS 域并定义该域中的优先级映射表，之后将 DS 域与信任的接口绑定。


简单流分类主要在网络的 DS 域内部节点部署。

3.3.2 QoS 优先级映射

不同的报文使用不同的 QoS 优先级，例如 VLAN 报文使用 802.1p，IP 报文使用 DSCP，MPLS 报文使用 EXP。为了保证不同报文的服务质量，在报文进设备时，需要将报文携带的 QoS 优先级统一映射到设备内部的服务等级 Service Class（也叫做调度优先级 PHB）和丢弃优先级（也叫颜色 Color），在设备内部，根据报文的服务等级进行拥塞管理，根据报文的颜色进行拥塞避免；在报文出设备时，需要将内部的服务等级和颜色映射为 QoS 优先级，以便后续网络设备能够根据 QoS 优先级提供相应的服务质量。

将 QoS 优先级映射到服务等级和颜色是在报文上行方向进行，而服务等级和颜色映射为 QoS 优先级则是在下行方向进行。

图3-6 QoS 优先级映射



Service Class

Service Class 是指报文在设备内部的服务等级，支持 8 种取值，优先级从高到低依次为 CS7、CS6、EF、AF4、AF3、AF2、AF1、BE。Service Class 决定了报文在设备内部所属的队列类型。

服务等级的高低取决于具体的队列调度算法配置：

- 如果 8 种类型的队列都配置为 PQ 调度，则 CS7>CS6>EF>AF4>AF3>AF2>AF1>BE；
- 如果 BE 配置为 PQ 调度（当然一般不会这么配置），其余 7 种类型的队列配置为 WFQ 调度，则 BE 的优先级比其余 7 个都高；
- 如果 8 种类型的队列都配置成 WFQ 调度，则相互之间无优先级高低之分。



说明

关于队列调度，请参见本文后面的介绍。

Color

Color 是指报文在设备内部的丢弃优先级，用于实现同一个队列内部，当队列发生拥塞时报文丢弃顺序。Color 支持 3 种取值，IEEE 定义的优先级从低到高依次为 Green、Yellow、Red。

丢弃优先级的高低实际取决于对应参数的配置，例如：配置 Green 最大只能使用 50% 缓存，Red 最大可以使用 100% 缓存，则 Green 的丢弃优先级比 Red 高。

端口信任

在“3.1 流分类与流动作”中介绍流分类时提到：“当报文在 DiffServ 域边界被分类之后，网络的中间节点可以根据分类结果对不同类别的流量给予差别服务。下游节点可以选择使用上游节点的分类结果，也可以按照自己的分类标准对数据流重新进行分

类”。那么，如果选择使用上游节点的分类结果，则表示该节点信任上游节点的分类结果，即信任（trust）从连接上游节点的端口接收的报文所携带的 QoS 标记。因此，设备在实现 QoS 优先级映射时，可以选择信任端口的上行报文携带的优先级标记（包括 DSCP、IP Precedence、802.1p、MPLS Exp、ATM CLP），这种模式称为端口信任模式。

华为路由器缺省情况下不信任接口，即不关心报文携带的优先级信息，统统将报文的服务等级标记为 BE，报文颜色标记为 Green。

DS 域与优先级映射表

在华为路由器上，设备根据优先级映射表实现 QoS 优先级映射。而在 DiffServ 模型中，不同 DS 域允许有不同的 PHB 映射关系，以实现不同的服务提供策略，因此设备需要允许管理员定义 DS 域并针对不同的 DS 域设定不同的优先级关系。

华为路由器允许管理员自定义 DS 域，同时系统预定义了如下两个域：

- **Default 域：**描述了缺省情况下 IP 报文、VLAN 报文、MPLS 报文的外部优先级和服务等级、颜色之间的映射关系。
- **5p3d 域：**描述了 VLAN 报文 802.1p 优先级和设备内部服务等级、颜色之间的映射关系，应用于仅支持 5 种服务等级（Service Class）和 3 种丢弃优先级的 802.1ad 局域网。



说明

IEEE 定义了 8 种调度优先级的 PHB（CS7、CS6、EF、AF4~AF1、BE），对于 AF4~AF1 又定义了 3 种丢弃优先级的 PHB。因此，PHB 数量是 $4 + 4 \times 3 = 16$ 种。

而 DSCP 有 64 个取值，可以涵盖这 16 种 PHB。但 VLAN 优先级的 802.1p 只有 8 个取值，无法涵盖这 16 种 PHB。通常是将 VLAN 的 8 个值与 8 个调度优先级对应。但 IEEE 802.1ad 协议定义的 STAG 格式与 CTAG 不同，STAG 支持 DEI（Drop Eligible Indicator）但 CTAG 不支持 DEI。为此 IEEE 802.1ad 同时提供了对 CTAG 和 STAG 都适用的一种利用 3Bit 的 PCP（Priority Code Point）来进行 Priority 和丢弃优先级（Drop Eligibility）的设定，即要求一个 802.1p 值能同时表达调度优先级+丢弃优先级的含义，因此诞生了 8p0d、7p1d、6p2d 和 5p3d 的概念。其中的“p”是指服务等级（Service Class），“d”是指丢弃优先级。5p3d 含义是支持 5 种服务等级（Service Class）和 3 种丢弃优先级。

这两个域默认存在，不允许删除。允许用户对 Default 域中的映射关系进行修改，5p3d 域的映射关系不允许修改。

Default 域的默认优先级映射表

在华为路由器上，默认的外部优先级和内部优先级之间的映射关系如下。

表3-2 DSCP 到服务等级的缺省映射表

DSCP	Service	Color	DSCP	Service	Color
0~7	BE	Green	28	AF3	Yellow
8	AF1		29	BE	Green
9	BE		30	AF3	Red
10	AF1		31	BE	Green

DSCP	Service	Color	DSCP	Service	Color
11	BE		32	AF4	
12	AF1	Yellow	33	BE	
13	BE	Green	34	AF4	
14	AF1	Red	35	BE	
15	BE	Green	36	AF4	Yellow
16	AF2		37	BE	Green
17	BE		38	AF4	Red
18	AF2		39	BE	Green
19	BE		40	EF	
20	AF2	Yellow	41~45	BE	
21	BE	Green	46	EF	
22	AF2	Red	47	BE	
23	BE	Green	48	CS6	
24	AF3		49~55	BE	
25	BE		56	CS7	
26	AF3		57~63	BE	
27	BE				

表3-3 服务等级到 DSCP 的缺省映射表

Service	Color	DSCP
BE	Green	0
AF1	Green	10
AF1	Yellow	12
AF1	Red	14
AF2	Green	18
AF2	Yellow	20
AF2	Red	22
AF3	Green	26
AF3	Yellow	28
AF3	Red	30

Service	Color	DSCP
AF4	Green	34
AF4	Yellow	36
AF4	Red	38
EF	Green	46
CS6	Green	48
CS7	Green	56

表3-4 IP Precedence/MPLS EXP/802.1p 到服务等级的缺省映射表

IP Precedence/MPLS EXP/802.1p	Service	Color
0	BE	Green
1	AF1	Green
2	AF2	Green
3	AF3	Green
4	AF4	Green
5	EF	Green
6	CS6	Green
7	CS7	Green

表3-5 服务等级到 IP Precedence/MPLS EXP/802.1p 的缺省映射表

Service	Color	IP Precedence/MPLS EXP/802.1p
BE	Green	0
AF1	Green、Yellow、Red	1
AF2	Green、Yellow、Red	2
AF3	Green、Yellow、Red	3
AF4	Green、Yellow、Red	4
EF	Green	5
CS6	Green	6
CS7	Green	7

5p3d 域的默认优先级映射表

IEEE 802.1ad 中对 PCP 的定义如下图。

图3-7 PCP encoding/decoding

Table6-3-- Priority Code Point encoding

Priority drop_eligible		7	7DE	6	6DE	5	5DE	4	4DE	3	3DE	2	2DE	1	1DE	0	0DE
PCP	8P0D (default)	7	7	6	6	5	5	4	4	3	3	2	2	1	1	0	0
	7P1D	7	7	6	6	5	4	5	4	3	3	2	2	1	1	0	0
	6P2D	7	7	6	6	5	4	5	4	3	2	3	2	1	1	0	0
	5P3D	7	7	6	6	5	4	5	4	3	2	3	2	1	0	1	0

Table6-4-- Priority Code Point decoding

PCP		7	6	5	4	3	2	1	0
Priority drop_eligible	8P0D (default)	7	6	5	4	3	2	1	0
	7P1D	7	6	4	4DE	3	2	1	0
	6P2D	7	6	4	4DE	2	2DE	1	0
	5P3D	7	6	4	4DE	2	2DE	0	0DE

图 3-7 中，数字 x（0<=x<=7）表示 802.1p Priority 为 x，drop_eligible 为 false，即不可设定丢弃优先级；数字+字母形式的 xDE 表示 802.1p Priority 为 x，drop_eligible 为 true，即可设定丢弃优先级。

华为路由器的 5p3d 域默认优先级映射表遵从 IEEE 802.1ad 协议的定义，其与 IEEE 802.1ad 协议的对应关系如下：

表3-6 华为路由器 5p3d 域与 IEEE 802.1ad 协议的对应关系

802.1p 到 Color 的映射		从 Color 到 802.1p 的映射	
IEEE 802.1ad 的 drop_eligible	华为路由器报文颜色	华为路由器报文颜色	IEEE 802.1ad 的 drop_eligible
false	Green	Green	false

802.1p 到 Color 的映射		从 Color 到 802.1p 的映射	
IEEE 802.1ad 的 drop_eligible	华为路由器报文颜色	华为路由器报文颜色	IEEE 802.1ad 的 drop_eligible
true	Yellow	Yellow、Red	true

华为路由器的 5p3d 域优先级映射关系如下。

表3-7 802.1p 到服务等级的映射表

802.1p	Service	Color
0	BE	Yellow
1	BE	Green
2	AF2	Yellow
3	AF2	Green
4	AF4	Yellow
5	AF4	Green
6	CS6	Green
7	CS7	Green

 说明

从 802.1p 到内部服务等级的正向映射时（表 3-7），入接口可能处于非 5p3d 域而出接口处于 5p3d 域，非 5p3d 域可能有 8 种优先级，因此映射前的 802.1p 有 8 种可能的取值，映射入 5p3d 域只能有五种优先级，因此映射到的内部 Service 只有 BE、AF2、AF4、CS6 和 CS7 五种；

从内部服务等级到 802.1p 的反向映射时（表 3-8），入接口可能是根据 DSCP/Exp/IP preference 或者是非 5p3d 域的 802.1p 做的正向映射，因此可能出现 8 种服务等级。而出接口可能处于非 5p3d 域，因此映射后的 802.1p 可能有 8 种取值。

表3-8 服务等级到 802.1p 的映射表

Service	Color	802.1p
BE	Green	1
AF1	Green	1
AF1	Yellow	0
AF1	Red	0
AF2	Green	3
AF2	Yellow	2
AF2	Red	2


Service	Color	802.1p
AF3	Green	3
AF3	Yellow	2
AF3	Red	2
AF4	Green	5
AF4	Yellow	4
AF4	Red	4
EF	Green	5
CS6	Green	6
CS7	Green	7

3.3.3 BA 和 PHB 详解

BA 和 PHB 动作

报文在设备上的 QoS 动作始终围绕 2 个内部优先级<Service-class, color>来进行的。

1. 这 2 个内部优先级初始化为<BE, Green>。
2. 报文一进入设备，如果入接口配置了 **trust upstream** 命令，则设备上行单板（接口入方向）会根据报文优先级，对照入映射表来重新设置<Service-class, color>，这一过程称为“上行映射（BA）”。
3. 如果对报文配置 remark，或者 car 后 remark 动作，则设备上行单板会直接去修改报文的<Service-class, color>。
4. 之后，设备根据<Service-class, color>来对报文进行队列调度等一系列 QOS 动作。
5. 这些 QoS 动作做完之后，设备下行单板（接口出方向）还要做出一个决定：是否根据内部优先级修改报文优先级，因为有些场景是不希望改变报文优先级的。根据内部优先级修改报文优先级的过程称为“下行反映射（PHB）”。



BA 和 PHB 开关

设备给每个接口设置了两个“开关”来控制对该接口出方向的报文做“反射”：

- 开关 1: Remark。这个开关是在流量的入口配置的，通过内部添加的信息头，会从入口经过交换网传递到出口。
- 开关 2: PHB。这个开关是在流量的出口配置的。

只有两个开关同时打开，才会做反射动作（但是下行为 Type-C 单板时，只要 PHB 开关打开，不管 Remark 开关是什么状态，都做反射）。

默认情况下，Remark 开关为关闭状态，PHB 开关在 V600R002 及之前版本默认为打开状态，V600R003 及后续版本为关闭状态。

可通过表 3-9 所示命令行设置这两个开关的状态。



说明

Type-C 单板，上行 Remark 开关固定打开，无法通过命令行改变。

表3-9 与 Remark 和 PHB 开关设置相关的命令行

命令行	上、下行单板行为	对开关状态的影响
trust upstream	上行单板会执行 BA，修改<Service-class, color>。	执行此命令，会将两个开关都打开。
diffserv-mode { pipe short-pipe }	上行单板会执行 BA，修改<Service-class, color>。	不影响两个开关的状态。
diffserv-mode uniform	此命令为默认配置，其不改变上、下行单板的行 为。	不影响两个开关的状态。
service-class	修改<Service-class, color>。	• 不带 no-remark 参数：将 Remark 开关打开。

命令行	上、下行单板行为	对开关状态的影响
		带 no-remark 参数：将 Remark 开关关闭。
qos default-service-class	修改<Service-class, color>。	不影响两个开关的状态。
remark （上行）	Type-B 单板：上行做 BA，不直接修改报文优先级，是否修改报文优先级取决于下行 PHB 开关状态。 - 其他单板：上行做 BA，且直接修改报文优先级，不受两个开关的影响。	将 Remark 开关打开。
remark （下行）	直接修改报文优先级，不受两个开关的影响。 例如，假设下行配置 remark dscp 11，报文内部标记<Service-class, color>是<ef,green>，则输出报文的 dscp 是 11，而不是根据<ef,green>查下行 PHB 表得到的值。如果输出报文含 VLAN，则 VLAN 的 802.1p 值还是根据<ef,green>查表得到的值。如果同时配置 remark dscp 11 和 remark 8021p，则 VLAN 的 802.1p 值也直接被修改，而不是查表所得。	不影响两个开关的状态。
qos phb enable	-	将 PHB 开关打开。
qos phb disable	-	将 PHB 开关关闭。
qos car { green yellow red } pass service-class color	直接改<Service-class, color>。	不影响 Remark 和 PHB 开关状态。

PHB 动作的控制

- 打开"Remark"开关的方法：接口入方向配置"**trust upstream**"、"**remark**"、"**service-class**"命令。

- 关闭"Remark"开关的方法：接口入方向配置 **service-class class-value color color-value no-remark** 命令，或者移除上述命令的配置。
- 打开"PHB"开关的方法：接口出方向配置 **trust upstream** 或者 **qos phb enable** 命令。
- 关闭"PHB"开关的方法：接口出方向配置 **qos phb disable** 命令或者删除 **trust upstream** 命令。

设备是否执行 QoS 优先级反射动作，与两个开关的状态，以及报文入、出接口所在单板的类型相关，详细请参见表 3-10。

表3-10 反射动作控制规则

单板类型		开关状态		是否执行 QoS 优先级反射动作
入接口单板	出接口单板	"Remark"开关	"PHB"开关	
任意	任意	关闭	关闭	否
任意	任意	打开	关闭	否
任意	任意	打开	打开	是
任意	Type-C	关闭	打开	是
Type-C	任意	关闭	打开	是
Type-C 外的其他单板	Type-C 外的其他单板	关闭	打开	否

用于做上行映射（BA）的 QoS 优先级字段是哪个

取决于报文入接口的配置，详细请参见表 3-11（如果是 ATM 接口，请参见 7.2 ATMoPSN 及 PSNoATM 的 QoS）。

表3-11 用于 BA 的字段

入接口配置（●表示配置，○表示不配置）	报文类型	被信任的优先级标记
○trust upstream 命令 ○trust 8021p 命令	任意类型	不信任任何字段，报文被映射到<BE,Green>。
○trust upstream 命令 ●trust 8021p 命令		
●trust upstream 命令 ○trust 8021p 命令	IPoE、 IPoVLAN、 IPoQinQ	DSCP
	IPoPPP、	DSCP

入接口配置（●表示配置，○表示不配置）	报文类型	被信任的优先级标记
	IPoHDL、 IPoFR	
	MPLS	外层标签的 EXP
	非 IP 也非 MPLS 报文	对于二层接口： - 上行单板是 Type-B 或者 Type-C 时，被映射到 <BE,Green>。 - 上行单板是其他类型单板时，信任外层 VLAN tag 的 802.1p，如果报文不带 VLAN tag，则被映射到 <BE,Green>。 对于三层接口： - 设备能识别出的报文被映射到<CS6,Green>。通常，这些可识别报文为协议报文，例如 IS-IS 报文、ARP 报文、PPPoE 报文等，因此映射到高优先级队列 CS6。 - 设备无法识别的报文，则被映射到<BE,Green>。通常这类报文为错误报文，因此映射到 BE 队列。
●trust upstream 命令 ●trust 8021p 命令	VLAN	802.1p
	QinQ	外层 TAG 的 802.1p
	非 VLAN 也非 QinQ	不信任任何字段。报文被映射到<BE,Green>。

报文哪些优先级字段会在 PHB 反映射动作中被修改

如果报文同时有多个 QoS 优先级字段，哪些优先级字段会在反映射动作中被修改，取决于应用场景，报文出接口所在单板的类型及出接口配置。

表3-12 二层转发（含 VPLS/VLL）场景中，反映射动作中被修改的字段

出接口配置（●表示配置，○表示不配置）	DSCP 值	802.1p 值
○trust upstream 命令 ○qos phb enable 命令 ●trust upstream 命令 ○trust 8021p 命令	不变	- 下行单板为 Type-C，填 0。 - 下行单板为其他类型：不变。
●qos phb enable 命令 ○trust 8021p 命令	不变	- 下行单板为 Type-A，不变，新增的填 0。 - 下行单板为其他类型：如果做 PHB 反映射，则根据 <Service-Class, color>和出接口指定的 DS 域反映射表进

出接口配置（●表示配置，○表示不配置）	DSCP 值	802.1p 值
		行设置。如果不做 PHB 反射，则不变。
●trust upstream 命令 ●trust 8021p 命令	不变	如果做 PHB 反射，则根据<Service-Class, color>和出接口指定的 DS 域反射表进行设置。 ● 如果不做 PHB 反射，则不变。
●qos phb enable 命令 ●trust 8021p 命令		
说明 是否做反射的相关信息请参见 BA 和 PHB 开关 和 PHB 动作的控制 。		

表3-13 L3 转发（含 MPLS L3VPN）场景中，反射动作中被修改的字段

出接口配置（●表示配置，○表示不配置）	DSCP 值	802.1p 值
○trust upstream 命令 ○qos phb enable 命令	不变。	• 下行单板为 Type-B ：根据<Service-Class, color>和出接口指定的 DS 域（如果未指定则按 Default 域）反射表进行设置。 • 下行单板为其他类型：不变，新增的填 0。
●trust upstream 命令 ○trust 8021p 命令	• MPLS L3VPN 入隧道：下行单板为 Type-B 和 Type-C 时，根据<Service-Class, color>和下行指定 DS 域反射表进行设置；下行单板为其他类型时，DSCP 不变。 • MPLS L3VPN 出隧道 Pipe 和 Short-pipe 模式：DSCP 不变 • IP 转发或 MPLS L3VPN 出隧道 Uniform 模式：根据<Service-Class, color>和下行指定 DS 域反射表进行设置。	• 下行单板为 Type-A：不变，新增的填 0。 • 下行单板为其他类型：根据<Service-Class, color>和下行指定 DS 域反射表进行设置。
●qos phb enable 命令 ○trust 8021p 命令		
●trust upstream 命令 ●trust 8021p 命令	• 下行单板为 Type-B：根据<Service-Class, color>和下行指定 DS 域反射表进行设置（如果是 L3VPN 出隧道的 Pipe 和 Short-pipe 模式时，DSCP 不变）。 • 下行单板为其他类型：不变。	根据<Service-Class, color>和下行指定 DS 域反射表进行设置。
●qos phb enable 命令	• MPLS L3VPN 入隧道：下	• 下行单板为 Type-A ：根据

出接口配置（●表示配置，○表示不配置）	DSCP 值	802.1p 值
● trust 8021p 命令	行单板为 Type-B 和 Type-C 时，根据<Service-Class, color>和下行指定 DS 域映射表进行设置；下行单板为其他类型时，DSCP 不变。 • MPLS L3VPN 出隧道 Pipe 和 Short-pipe 模式：DSCP 不变 • IP 转发或 MPLS L3VPN 出隧道 Uniform 模式：下行单板为 Type-A 时 DSCP 不变；下行为其他单板时，根据<Service-Class, color>和下行指定 DS 域映射表进行设置。	<Service-Class, color>和 Default 域映射表进行设置。 • 下行单板为其他类型：根据<Service-Class, color>和下行指定 DS 域映射表进行设置。
说明 此表中，根据<Service-Class, color>和下行指定 DS 域映射表进行设置的前提是在下行做 PHB 映射；如果下行未做映射，则设置规则与各自单板在未配置 trust upstream 命令也没配置 qos phb enable 命令的情况相同。 下行是否做 PHB 映射的相关信息请参见 BA 和 PHB 开关和 PHB 动作的控制。 入 MPLS 隧道场景中，新增 MPLS 标签 EXP 的设置规则请参见“新增 MPLS 头的 EXP 值设置”。		

表3-14 MPLS (P 节点)转发场景中，映射动作中被修改的字段

出接口配置（●表示配置，○表示不配置）	DSCP 值	EXP 值	802.1p 值
○ trust upstream 命令 ○ qos phb enable 命令	不变。	不变。	• 下行单板为 Type-B：根据<Service-Class, color>和 Default 域映射表进行设置。
● trust upstream 命令 ○ trust 8021p 命令	不变。	根据<Service-Class, color>和下行指定 DS 域映射表（如果是 Type-B ，则按 Default 域映射表）进行设置。	• 下行单板为其他类型：不变，新增的填 0。
● qos phb enable 命令 ○ trust 8021p 命令			新增 VLAN tag: • 下行单板为 Type-A：不变，新增的填 0。 • 下行单板为其他类型：根据<Service-Class, color>和 Default 域映射表进行设置。
● trust upstream 命令	不变。		根据<Service-Class, color>和下行指

出接口配置（●表示配置，○表示不配置）	DSCP 值	EXP 值	802.1p 值
●trust 8021p 命令			定 DS 域反射表进行设置。
●qos phb enable 命令			
●trust 8021p 命令			
说明 此表中，根据<Service-Class, color>和下行指定 DS 域反射表进行设置的前提是在下行做 PHB 反射；如果下行未做反射，则设置规则与各自单板在未配置 trust upstream 命令和 qos phb enable 命令的情况相同。 下行是否做 PHB 反射的相关信息请参见 BA 和 PHB 开关和 PHB 动作的控制。			

新增 MPLS 头的 EXP 值设置

当报文通过设备后新增了 MPLS 头，其 EXP 值的设置，取决于 PHB 开关状态和上、下行单板的类型。

表3-15 VPN 入隧道场景下新增 MPLS 头的 EXP 值设置

EXP 类别	单板类型	设置规则
外层 EXP	下行 Type-A	做 PHB 反射时：根据<Service-Class, color>和下行指定 DS 域反射表进行设置。 不做 PHB 反射时：标记为 0。
	下行 Type-B	根据<Service-Class, color>和 Default 域反射表进行设置。
	下行 Type-C , Type-D	做 PHB 反射时：根据<Service-Class, color>和下行指定 DS 域反射表进行设置。 不做 PHB 反射时：根据 Service-Class 设置，BE~CS7 分别为 0~7。
VPLS 内层 EXP	下行任意单板	做 PHB 反射时：根据<Service-Class, color>和 VSI 实例视图下的 mpls-inner-exp phb domain 命令指定的 DS 域（默认按公网出接口指定的 DS 域）反射表进行设置。 不做 PHB 反射时：与公网 EXP 不做 PHB 反射时的设置规则相同。
VLL/L3VPN 内层 EXP	下行 Type-A 或者 Type-D	做 PHB 反射时：根据<Service-Class, color>和下行指定 DS 域反射表进行设置。可以在槽位视图配置 mpls-inner-exp phb disable 命令，使下行按照上行单板设定的内层 EXP 值。 不做 PHB 反射时：直接按照上行单板设定的内层 EXP 值。
	下行 Type-B 或者 Type-C	直接按照上行单板设定的内层 EXP 值。

EXP 类别	单板类型	设置规则
说明 下行是否做 PHB 反射的相关信息请参见 BA 和 PHB 开关和 PHB 动作的控制。 上行单板设定的 VLL/L3VPN 内层 EXP 值的规则如下： ● 上行 Type-A 单板：根据 Service-Class 设置，BE~CS7 分别为 0~7。 ● 上行其他类型单板：VLL 内层 EXP 值根据<Service-Class, color>和入接口 <code>mpls l2vc diffserv domain</code> 命令行指定 DS 域反射表进行设置；L3VPN 内层 EXP 值根据<Service-Class, color>和 VPN 实例视图下的 <code>mpls-inner-exp phb domain</code> 命令指定的 DS 域的反射表进行设置。如果没有指定 DS domain，默认情况下，上行 Type-A 或者 Type-D 根据 Service-Class 设置，BE~CS7 分别为 0~7；上行 Type-B 或者 Type-C 根据<Service-Class, color>和 Default 域反射表进行设置。		

3.4 复杂流分类

3.4.1 什么是复杂流分类

复杂流分类的定义

随着网络的普及，网络中的业务越来越多样化，多种业务流共享同一网络资源，简单的流分类措施很难满足要求，尤其是很多业务可能都是基于 80 端口。这样，就要求网络具备很强的业务感知能力，能深度报文分析，对报文任意层次和字段的全面解析。复杂流分类可以在一定程度上满足此要求。

复杂流分类是指采用复杂的规则，如由五元组（源地址、源端口号、协议号码、目的地址、目的端口号）对报文进行精细的分类。为了节省配置，方便批量修改配置，复杂流分类的命令行采用模板化形式，详细信息请参见“3.4.2 基于复杂流类的 QoS 策略”。

复杂流分类主要部署在网络的边缘节点，目前华为路由器实现了三种复杂流分类方法，如下表。

复杂流分类方法		支持的匹配项	说明
二层（链路层）复杂流分类		VLAN 外层 Tag 的 802.1p 优先级	各匹配项可以任意组合。
		VLAN 内层 Tag 的 802.1p 优先级	
		源 MAC 地址	
		目的 MAC 地址	
		二层封装的协议字段	
IP 复	IPv4	DSCP 优先级	各匹配项可以任意组合。

复杂流分类方法		支持的匹配项	说明
杂流分类		IP 优先级	
		源 IPv4 地址	
		目的 IPv4 地址	
		IPv4 报文的分片	
		TCP/UDP 源端口	
		TCP/UDP 目的端口	
		协议号	
		TCP 同步标志	
	IPv6	IPv6 报文的 DSCP 优先级	各匹配项可以任意组合。 由于 IPv6 的地址位太宽，Type-A 和 Type-B 类单板对源 IP 地址进行了压缩，这些单板只支持匹配 96bit 的源 IP 地址。假设 IPv6 的 IP 地址为 0~127，这 96bit 是由 0~31 + 64~127 组成的。
		协议号	
		源 IPv6 地址	
		目的 IPv6 地址	
		TCP/UDP 源端口	
		TCP/UDP 目的端口	
MPLS 复杂流分类	EXP		最多可以识别 4 层标签，可以 4 层标签的以上三个字段任意组合。
	Label		
	TTL		

说明

华为路由器也支持区分 VLAN ID 做复杂流分类，只是在实现上，不是将 VLAN ID 作为匹配关键字的一部分，而是用来绑定复杂流分类的策略，就像接口绑定复杂流分类策略一样。通过这种实现方式，表 1-1 列出的三种类型的复杂流分类都可以支持区分 VLAN ID 做复杂流分类。

例如要实现以下效果：

VLAN=100,8021P=5，限制带宽 100Mbps

VLAN=200,8021P=5，限制带宽 100Mbps

VLAN=200,8021P=5，限制带宽 100Mbps

则配置如下：

```
traffic classifier test
  if-match 8021p 5
```

```
traffic behavior test
  car cir 100000
```

```
traffic policy test
```

```
classifier test behavior test

interface xxx
 traffic-policy test inbound vlan 100 link-layer // Link-layer 表示根据二层信
息做复杂流分类
 traffic-policy test inbound vlan 200 link-layer
 traffic-policy test inbound vlan 300 link-layer
```

此外，华为路由器也支持基于时间段做复杂流分类，从而进行流量控制。运营商可以根据用户的使用习惯、网络的拥塞情况等，在不同的时间段设置不同的策略，达到网络优化的目的。比如根据用户的使用习惯，20:00~22:00 为网络流量的高峰期，大量 P2P、下载类业务的使用影响了其他数据业务的正常使用，运营商可以设置在这个时间段内降低 P2P、下载类业务的带宽，防止网络拥塞。

配置例：

```
time-range test 20:00 to 22:00 daily

acl 2000
 rule permit source 129.9.0.0 0.0.255.255 time-range test //在 ACL 中配置
time-range 来控制规则的生效时间
 traffic classifier test
   if-match acl 2000

 traffic behavior test
   car cir 100000

 traffic policy test
   classifier test behavior test

interface xxx
 traffic-policy test inbound
```

3.4.2 基于复杂流类的 QoS 策略

华为路由器已实现多种复杂流分类方法和丰富的流动作。将这些流分类方法和对应可实施的流动作关联，形成流策略，并将流策略与接口绑定，可实现丰富的 QoS 策略，这就是基于复杂流分类的 QoS 策略（通常被称为“基于类的 QoS”）。


基于复杂流分类的 QoS 策略是对 QoS 策略配置的抽象，是“模板化”的 QoS 配置方式。“模板化”的最大优点是可以节省配置，支持批量修改。

“模板”分为三部分：

- 流分类（Classifier）模板：定义流量类型。用 if-match 语句设定流分类的匹配规则。
- 流动作（Behavior）模板：定义针对该类流量可实施的流动作。支持流分类的流动作请参见“3.1 流分类与流动作”中表 1 的描述。
- 流策略（Policy）模板：将流分类 Classifier 和流动作 Behavior 关联，成为一个 Classifier & Behavior 对。当 Policy 模板设置完毕之后，需要将 Policy 模板应用到接口上。

接口、流策略、流动作、流分类、ACL 之间的关系如下图。

图3-8 接口、流策略、流动作、流分类、ACL 之间的关系



- 1) 不同的接口可以应用相同的 Policy 模板。
- 2) 一个 Policy 模板中可以配置一个或多个 Classifier & Behavior 对。不同的 Policy 模板可以应用相同的 Classifier & Behavior 对。
- 3) 一个 Classifier 模板中可以配置一条或多条 if-match 语句，if-match 语句中可以引用 ACL 规则。不同的 Classifier 模板可以应用相同的 ACL 规则。一个 ACL 规则可以配置一个或多个 Rule 语句。
- 4) 一个 Behavior 模板中可以配置一个或多个流动作。

流分类的 And 和 Or 逻辑

如果流分类有多个匹配规则，则这些规则之间有 And 和 Or 两种逻辑关系：

- Or 逻辑：数据包只要匹配该流分类下的任何一条 if-match 子句定义的规则就属于该类。
- And 逻辑：数据包必须匹配该流分类下的全部规则才属于该类。

流策略的“共享”模式和“非共享”模式

Policy 模板分为“共享”模式和“非共享”模式。例如，定义了一个 Policy 模板，要求对 TCP 流的带宽限制在 100Mbps 之内；对 UDP 流限制在 200Mbps 之内；对其它流量，限制在 300Mbps 之内，最后将该 Policy 模板应用到 2 个接口下，则：

- 在“非共享”模式下，这两个接口互不相干，每个接口都能出来 100Mbps TCP 流，200Mbps UDP 流，300Mbps 其他流量。
- 在“共享”模式下，则带宽限制的是总流量，即两个接口一共能出来 100Mbps TCP 流，200Mbps UDP 流，300Mbps 其他流量。




注意

“共享”模式中，共享资源的两个或多个接口必须在同一块单板上。

流策略的执行过程

图3-9 流策略的执行过程



如上图，当收到一个报文，要做复杂流分类处理时，会按照 policy 模板中 Classifier 的配置顺序进行匹配。如果命中，则停止匹配；如果不命中，则匹配后面的 Classifier；如果是最后一个 Classifier，且还不命中，则报文走正常的转发处理，类似于没有应用流分类策略。

由于 Classifier 中配置的是一个或多个 if-match 语句，按照 if-match 语句配置顺序进行匹配；如果 if-match 语句指定的是 ACL 或 UCL，需要在 ACL 或 UCL 的多个 Rule 语

句中进行匹配：首先查找用户是否配置了该 ACL 或 UCL（因为流分类允许引用不存在的 ACL 和 UCL），命中的第一条则停止匹配，不再继续查找后续的规则。



说明

当 Rule 中的动作为 Deny 时，如果 behavior 是镜像或采样，即使对于丢弃的报文，也会执行 behavior。

关于 ACL 和 UCL 中多个 Rule 语句的匹配顺序，请参见“3.4.3 复杂流分类中的 ACL 匹配规则”。

ACL 中可以指定 permit 或 deny 动作，它与 ACL 所在 Classifier 所对应的 Behavior 中的动作的关系是：

- ACL 为 deny，则不关心 Behavior，报文最终动作是 deny；
- ACL 为 permit，则执行 Behavior，报文最终动作是 Behavior。

例如以下配置的匹配结果是：源地址是 50.0.0.1/24 的报文 IP 优先级被标记为 7；源地址是 60.0.0.1/24 的报文被丢弃；源地址是 70.0.0.1/24 的报文 IP 优先级不变。

```
acl 3999
  rule 5 permit ip source 50.0.0.0 0.255.255.255
  rule 10 deny ip source 60.0.0.0 0.255.255.255
traffic classifier acl
  if-match acl 3999
traffic behavior test
  remark ip-pre 7
traffic policy test
  classifier acl behavior test
interface GigabitEthernet1/0/1
  traffic-policy test inbound
```

3.4.3 复杂流分类中的 ACL 匹配规则

ACL 的分类

访问控制列表 ACL（Access Control List）是由一系列 permit 或 deny 语句组成的规则的集合，这些规则根据数据包的源地址、目的地址、端口号等来描述。ACL 通过规则对数据包进行分类，这些规则应用到设备上，设备根据这些规则判断哪些数据包可以接收，哪些数据包需要拒绝。

华为路由器上，流分类中的 ACL 规则支持情况如表 3-16，支持的过滤选项如表 3-17。

表3-16 流分类中的 ACL 规则支持情况

ACL 的类型		ACL 编号	说明
数字型 ACL	基本 ACL	2000～2999	用于限制数据包的源地址。
	高级 ACL	3000～3999	用于限制数据包的源地址、目的地址、协议号（TCP、UDP）、源端口和目的端口号的五元组。

ACL 的类型		ACL 编号	说明
	基于二层以太网帧头的 ACL	4000~4999	基于二层以太网帧头信息进行数据包限制。
	UCL（用户 ACL）	6000~9999	用于区分不同优先级的用户。
	MPLS ACL	10000-10999	基于 MPLS 首部的标签、Exp 或 TTL 信息进行数据包限制。
命名型 ACL			命名方式更容易明白其功能，其过滤规则与数字型的高级 ACL 相同。

表3-17 不同类型 ACL 所支持的过滤选项

ACL 类型	支持的过滤选项
基本 ACL	- 源 IP 地址 - 生效时间段：指定规则生效的时间范围。如果不配置，表示规则配置后马上生效
高级 ACL	- IP 报文协议号。支持名称形式配置，例如，GRE（协议号 47）、ICMP（协议号 1）、IGMP（协议号 2）、IP（指任何 IP 层协议）、IPinIP（协议号 4）、OSPF（协议号 89）、TCP（协议号 6）、UDP（协议号 17） - 源 IP 地址 - 目的 IP 地址 - UDP 或者 TCP 报文的源或目的端口信息 - DSCP - IP 报文分片信息。支持区分 5 种分片情况：分片报文；非分片报文；分片报文的首片；分片报文的后续片；分片报文的首片或者非分片报文 - IP 报文的 ToS（Type of Service）字段（指 RFC1349 中定义的 IP 包中 4bit 的 ToS 字段） 说明 RFC791 定义的 IP 协议首部中，ToS 字段为 8bit。而 RFC1349 则是将这个 8bit 拆分成 3bit 的优先级，4bit 的 ToS 信息，以及 1bit 的保留位。

ACL 类型	支持的过滤选项
	• IP Precedence（指 RFC1349 中定义的 IP 包 ToS 字段的高 3 位） • TCP 报文的标志信息，包括 URG（标识紧急指针有效）、ACK（标识确认序号有效）、PSH（标识接收方应该尽快将这个报文交给应用层）、PST（标识重建连接）、SYN（同步序号，用来发起一个连接）、FIN（标识发端完成发送任务） • ICMP 的消息名称、消息类型或消息码 • 生效时间段：指定规则生效的时间范围。如果不配置，表示规则配置后马上生效
基于二层以太网帧头的 ACL	• 802.1p 优先级。对于 QinQ 场景，则表示外层 TAG 的 802.1p 优先级 • 内层 TAG 的 802.1p 优先级。只对 QinQ 报文有效，表示内层 TAG 的 802.1p 优先级 • 目的 MAC 地址 • 源 MAC 地址 • 以太网二层协议类型（Protocol Type）
UCL（用户 ACL）	支持的过滤选项同“高级 ACL”，只是 UCL 使用 User-group 替换了高级 ACL 的源 IP 地址。关于 UCL 的介绍请参见本页后文。
MPLS ACL	• MPLS Exp 优先级 • MPLS 标签值 • MPLS 报文首部的 MPLS TTL（Time To Live）

ACL 的规则匹配过程

规则通过规则 ID 来标识，一个 ACL 中所有规则均按照规则 ID 从小到大的顺序显示。规则 ID 可以由用户进行配置，也可以由设备自动生成。

流分类中，ACL 规则匹配过程为：

- 首先查找用户是否配置了该 ACL（因为流分类允许引用不存在的 ACL）。
- 规则显示顺序决定匹配顺序。规则匹配时，从 ACL 中显示的第一条规则开始查找，当找到一条符合匹配条件的规则就通知给业务，不再继续查找后续的规则。

ACL 的规则匹配模式

规则匹配模式有两种：**config** 模式和 **auto** 模式。默认采用 **config** 模式。

- 如果是 **config** 模式，用户可以手工指定规则 ID，也可以由设备根据步长自动分配。

如果用户配置规则时指定了规则 ID，则规则 ID 的大小决定该规则的插入位置。例如设备已有 ID 为 5、10、15 的 3 条规则。如果新建一条 ID 为 3 的规则，则这 4 条规则的显示顺序为：3、5、10、15，相当于在规则 5 之前插入了一条规则。

如果用户配置规则时未指定规则 ID，则设备根据步长按用户配置的先后顺序自动分配规则 ID。例如，步长设定为 5，则设备按照 5、10、15……来分配规则 ID。如果步长是 2，自动生成的规则 ID 从 2 开始。步长可以方便用户进行规则维护，方便插入新规则。例如：默认步长为 5，当用户不输入规则 ID 时，设备自动生成的第一条规则的 ID 就是 5，当用户想在规则 5 前面插入新规则时，只需要输入比 5 小的规则 ID 即可，这样新规则就成了第一条规则。

因此，在 **config** 模式下，设备按照规则 ID 由小到大进行匹配，后插入的规则有可能先执行。

- 如果是 **auto** 模式，由设备自动分配规则 ID，按照“深度优先”规则把精度最高的规则排在最前面。可以通过比较地址的通配符来实现，通配符越小，则指定的范围就越小。

比如 129.102.1.1 0.0.0.0 指定了一台主机：129.102.1.1，而 129.102.1.1 0.0.0.255 则指定了一个网段：129.102.1.1~129.102.1.255，显然前者指定的主机范围小，在访问控制规则中排在前面。

具体标准如下：

- 对于基本 ACL，直接比较源地址通配符，通配符相同的则按配置顺序；
- 对于高级 ACL，首先比较协议范围，再比较源地址通配符，相同时再比较目的地址通配符，仍相同时则比较源端口号的范围，仍相同则再比较目的端口号的范围，范围小的排在前面，如果目的端口号范围也相同则按配置顺序。

auto 模式的应用场景示例：网络刚部署时，用户定义了一个比较大的匹配范围，用于过滤丢弃报文。随着实际应用的时间推移，需要让这个大范围中的某些特征的报文通过，则此时可以采用 **auto** 模式，只需要定义具体规则，不需要考虑如何对这些规则进行排序。

举例：用户先后执行了下面两条命令行配置，

```
rule deny ip dscp 30 destination 1.1.0.0 0.0.255.255
rule permit ip dscp 30 destination 1.1.1.0 0.0.0.255
```

如果是 **config** 模式，则在 ACL 中看到的是：

```
acl 3000
rule 5 deny ip dscp 30 destination 1.1.0.0 0.0.255.255
rule 10 permit ip dscp 30 destination 1.1.1.0 0.0.0.255
```

如果是 **auto** 模式，则在 ACL 中看到的是：

```
acl 3000
rule 1 permit ip dscp 30 destination 1.1.1.0 0.0.0.255
```

```
rule 2 deny ip dscp 30 destination 1.1.0.0 0.0.255.255
```

假设收到一个报文，DSCP=30，目的 IP=1.1.1.1，如果配置的 ACL 是 config 模式，该报文会被丢弃；如果配置的是 auto 模式，该报文会正常通过。

在流分类中的 ACL 匹配规则

华为各款中、高端路由器的流分类 ACL 匹配规则请参见表 3-18。

表3-18 流分类中的 ACL 匹配规则汇总


设备类型	流动作是 deny	deny 以外的流动作
NE40E/80E/5000E、 CX600、ME60	- 如果报文匹配 ACL 的规则是 permit，则执行相应的流行为（报文被 deny，不被转发）； - 如果报文匹配 ACL 的规则是 deny，则报文被 deny，不被转发，也不执行相应的流行为； - 如果报文没有与 ACL 中的任何一个规则相匹配，则不执行任何流行为，直接转发报文。	- 如果报文匹配 ACL 的规则是 permit，则执行相应的流行为； - 如果报文匹配 ACL 的规则是 deny，设备也不会继续执行流行为，而是丢弃该报文； - 如果报文没有与 ACL 中的任何一个规则相匹配，则不执行任何流行为，报文直接被转发。
NE20&NE20E V200R005C03SPC100（不含）以前的版本	- 如果报文匹配 ACL 的规则是 permit，则直接转发。 - 如果报文匹配 ACL 的规则是 deny，则报文被 deny，不被转发。 - 如果报文没有与 ACL 中的任何一个规则相匹配，则不执行任何流行为，直接转发报文。	- 如果报文匹配 ACL 的规则是 permit，则执行相应的流行为； - 如果报文匹配 ACL 的规则是 deny，则不会继续执行流行为，而是直接转发报文； - 如果报文没有与 ACL 中的任何一个规则相匹配，则不执行任何流行为，报文直接被转发。
NE20&NE20E V200R005C03SPC100（含）及其以后的版本	- 如果报文匹配 ACL 的规则是 permit，则报文被 deny，不被转发； - 如果报文匹配 ACL 的规则是 deny，则不执行任何流行为，直接转发报文。 - 如果报文没有与 ACL 中的任何一个规则相匹配，则不执行任何流行为，直接转发报文。	

设备类型	流动作是 deny	deny 以外的流动作
NE40/80	- 流策略引用的 ACL 规则中只能指定过滤项，不能指定 permit 和 deny 动作。 - 只要有某个条目匹配了某些报文，就会执行相应的流行为。 - 当报文不与 ACL 中的任何条目匹配时，不会做任何流动作，而是直接转发。	
NE05/08E/16E	- 流策略引用 ACL 规则时，对应的流动作不能指定 permit 和 deny 动作（如果要实现防火墙功能，则配置 firewall 命令而不是配置流策略）。 - 流策略引用 ACL 规则时，只要有某个 ACL 条目匹配了某些报文，就会执行相应的流行为；当报文不与 ACL 中的任何条目匹配时，不会做任何流动作，而是直接转发。	

UCL

UCL（User Control List）的规则匹配顺序与其他类型的 ACL 一致。与其他 ACL 不同的是，UCL 可以配置一个 User-group 字段，用于匹配源或目的用户组。源/目的用户组分为以下四种：

图3-10 UCL 组网图



- **用户到网络：**指匹配规则的过滤选项是源用户组，应用于用户侧上行数据流和网络侧下行数据流。

- **用户到用户**：指匹配规则的过滤选项是目的用户组，应用于用户侧上行数据流和用户侧下行数据流。
- **网络到网络**：指匹配规则的过滤选项既不包含源用户组也不包含目的用户组，应用于网络侧上行数据流和网络侧下行数据流。
- **网络到用户**：指匹配规则的过滤选项既包含源用户组也包含目的用户组，应用于网络侧上行数据流和用户侧下行数据流。


3.4.4 QPPB

QPPB（QoS Policy Propagation on BGP）是一种特殊的复杂流分类方法。

产生背景

在复杂组网环境中，如图 3-11，假设 AS400 是个高优先级网络，所有往/返 AS400 的报文都需要重新设置报文的 IP Precedence，以保证其报文的优先转发。为了满足此需求，需要在 AS100 中的边缘节点（Node-A、Node-B 和 Node-C）向其他 AS 转发往/返 AS400 的报文时，重新设置报文的 IP Precedence。对于 Node-C，只需要针对接口（连接 AS400 的接口）收发的流量进行重标记即可；但对于 Node-A 或 Node-B，则需要执行针对目的地址为 AS400 内 IP 地址的流分类，如果 AS400 内有大量的 IP 地址/地址段，则需要大量的流分类。如果网络结构不稳定，需经常变化网络结构，则需要大量的配置修改。

图3-11 跨 AS 组网




如果可以按照 AS 信息对报文分类，将使上述 Node-A 或 Node-B 的配置变得简单。为此，产生了 QPPB，一种可以针对 AS、团体属性等聚类信息对报文进行流分类的技术。

QPPB 技术顾名思义是指通过 BGP 传播 QoS 策略。应用 QPPB 技术可以由 BGP 路由发送者通过设置 BGP 属性预先对路由进行分类，BGP 路由接收者只需要配置合适的接收路由策略，匹配 BGP 路由属性后为 BGP 路由设置 QoS 参数，从而在转发数据时执行相应的 QoS 动作。在网络发生变化后，BGP 路由接收者可以不更改本地的配置，只是通过 BGP 路由发送者对发送的 BGP 路由属性做相关改动即可。

实现原理

本文以图 3-12 为例介绍 QPPB 的实现原理。图中 Node-A 和 Node-B 是 AS100 的 IBGP 邻居，Node-A 需要对所有往/返 AS400 的报文重新设置报文的 IP Precedence，则 QPPB 的实现过程如下：

图3-12 QPPB 实现原理




1. BGP 路由发送者（Node-C）在发送 BGP 路由时为 BGP 路由设置特定的属性（包括 AS_PATH，团体属性，扩展团体属性等）。
2. BGP 路由在通告过程中可以携带路由属性，这些特定的属性作为 BGP 路由分类的标识。
3. BGP 路由接收者（Node-A）预先在路由策略中设置路由属性匹配项，且对匹配上路由属性的路由设置关联的流动作。在收到 BGP 路由信息后，对匹配上路由属性的路由，在对应的 FIB 中设置 Behavior ID，不同的流动作设置了不同的 Behavior ID。
4. 在数据转发过程中，Node-A 可以针对发送到目的网络的数据包，从 FIB 中获取对应的 Behavior ID，执行 Behavior ID 所对应的流动作。

从以上过程可以看出，QPPB 技术实际并没有在 BGP 路由信息中发送 QoS 策略，只是在路由发送方通过对通告的路由设置路由属性，在路由接收方根据目的网段的路由属性设置 QoS 策略。

典型应用一：AS 域间流量分类

图3-13 QPPB 组网应用一：AS 域间流量分类



如图 3-13 的组网，使用 QPPB 可以方便地在 AS100 的边缘设备对 AS 域间的流量进行流分类。例如要在 Node-C 上对 AS200 和 AS400 之间的流量进行限速，则：

- 对于 AS200--->AS400 方向的流量，在 Node-C 上的 AS100 域内所有接口使能针对源地址的 QPPB。
- 对于 AS400--->AS200 方向的流量，在 Node-C 上与 AS400 相连的接口使能针对目的地址的 QPPB。




注意

查 FIB 转发的是针对上行流量而不是下行流量，因此使能 QPPB 的接口是流量上行的接口。

典型应用二：L3VPN 流量分类


图3-14 QPPB 组网应用二：L3VPN 流量分类



如图 3-14 所示是 QPPB 技术在 BGP/MPLS L3VPN 组网环境中的应用。当 PE 连接多个 VPN 时，可以对某个 VPN-instance 在路由发布时设置 Community 等属性后，再将路由通告出去；远端 PE 接收到路由信息后将路由及 QoS 等参数设置到 FIB 表项中，使得从 CE 来的流量在转发时能执行相应的 QoS 动作，这样，不同的 VPN 可获得不同的服务质量。

典型应用三——用户->ISP 的流量计费

图3-15 QPPB 组网应用三——用户->ISP 的流量计费



如图 3-15 所示是 QPPB 技术应用于用户到 ISP 的流量计费场景。配置方案如下：

- 通过 BGP 协议，发布路由时携带团体属性。
- 引入 BGP 路由时，匹配团体属性，在路由表中设置 Behavior ID。
- 配置 qppb-policy，匹配 qos-local-id，配置统计/CAR/Remark 等动作。
- 在流量入口方向使能基于目的地址的 QPPB。
- 在用户侧接口的 inbound 方向应用 qppb-policy。
- 报文在转发时，根据接口的 QPPB 使能配置，根据目的 IP 查路由表，获取路由表中的 Behavior ID（即 qos-local-id），再根据接口 qppb-policy 配置进行 qos-local-id 匹配，匹配上就进行统计/CAR/Remark 等动作处理。

配置例（以 Type-A 和 Type-C 类单板为例）：

定义团体属性匹配规则：

```
ip community-filter 10 permit 1000:10
ip community-filter 11 permit 1000:11
ip community-filter 12 permit 1000:12
ip community-filter 13 permit 1000:13
```

定义路由策略:

```
Route-policy policyA permit node 10
  if-match community-filter 10
  apply qos-local-id 10
Route-policy policyA permit node 11
  if-match community-filter 11
  apply qos-local-id 11
Route-policy policyA permit node 12
  if-match community-filter 12
  apply qos-local-id 12
Route-policy policyA permit node 13
  if-match community-filter 13
  apply qos-local-id 13
```

在引入 BGP 路由时, 引用 route-policy:

```
bgp 100
  peer 1.1.1.10 as-number 100
  peer 1.1.1.11 as-number 100
  peer 1.1.1.12 as-number 100
  peer 1.1.1.13 as-number 100
  peer 1.1.1.10 route-policy policyA import
  peer 1.1.1.11 route-policy policyA import
  peer 1.1.1.12 route-policy policyA import
  peer 1.1.1.13 route-policy policyA import
```

定义流行为:

```
traffic behavior b10
  car cir 2000
traffic behavior b11
  car cir 3000
traffic behavior b12
  car cir 4000
traffic behavior b13
  car cir 5000
```

定义 QPPB 策略:

```
qppb local-policy policyA
  qos-local-id 10 behavior b10
  qos-local-id 11 behavior b11
  qos-local-id 12 behavior b12
  qos-local-id 13 behavior b13
```

在用户侧接口入方向应用 QPPB 策略:


```
qppb-policy policyA destination inbound
```

查看统计:

```
display qppb local-policy statistics interface X/X/X inbound
```

典型应用四——ISP->用户的流量计费

图3-16 OPPB 组网应用四——ISP->用户的流量计费



如图 3-16 所示是 QPPB 技术应用于 ISP 到用户的流量计费场景。配置方案如下:

- 通过 BGP 协议，发布路由时携带团体属性。
- 引入 BGP 路由时，匹配团体属性，在路由表中设置 Behavior ID。
- 配置 qppb-policy，匹配 qos-local-id，配置统计/CAR/Remark 等动作。
- 在流量入接口方向使能基于源地址的 QPBB。
- 在用户侧接口的 outbound 方向应用 qppb-policy。
- 报文在转发时，根据接口的 QPPB 使能配置，根据源 IP 查路由表，获取路由表中的 Behavior ID（即 qos-local-id），qos-local-id 经过内部交换传递到流量出接口，再根据出接口的 qppb-policy 配置进行 qos-local-id 匹配，匹配上就进行统计/CAR/Remark 等动作处理。

配置例:

定义团体属性匹配规则:

```
ip community-filter 10 permit 1000:10
ip community-filter 11 permit 1000:11
ip community-filter 12 permit 1000:12
ip community-filter 13 permit 1000:13
```

定义路由策略:

```
Route-policy policyA permit node 10
  if-match community-filter 10
  apply qos-local-id 10
```

```
Route-policy policyA permit node 11
  if-match community-filter 11
  apply qos-local-id 11
Route-policy policyA permit node 12
  if-match community-filter 12
  apply qos-local-id 12
Route-policy policyA permit node 13
  if-match community-filter 13
  apply qos-local-id 13
```

在引入 BGP 路由时，引用 route-policy:

```
bgp 100
  peer 1.1.1.10 as-number 100
  peer 1.1.1.11 as-number 100
  peer 1.1.1.12 as-number 100
  peer 1.1.1.13 as-number 100
  peer 1.1.1.10 route-policy policyA import
  peer 1.1.1.11 route-policy policyA import
  peer 1.1.1.12 route-policy policyA import
  peer 1.1.1.13 route-policy policyA import
```

定义流行为:

```
traffic behavior b10
  car cir 2000
traffic behavior b11
  car cir 3000
traffic behavior b12
  car cir 4000
traffic behavior b13
  car cir 5000
```

定义 QPPB 策略:

```
qppb local-policy policyA
  qos-local-id 10 behavior b10
  qos-local-id 11 behavior b11
  qos-local-id 12 behavior b12
  qos-local-id 13 behavior b13
```

在流量入接口方向使能基于源地址的 QPBB。

```
qppb-policy qos-local-id source inbound
```

在用户侧接口出方向应用 QPPB 策略:

```
qppb-policy policyA outbound
```

查看统计:

```
display qppb local-policy statistics interface X/X/X outbound
```

3.5 单板实现差异

3.5.1 简单流分类实现差异

上行入映射

差异项	单板类型	差异描述																					
根据 VLAN tag 的 DEI (Drop Eligible Indicator) 比特位做简单流分类	Type-B	不支持																					
	Type-C	不支持																					
	Type-A	支持																					
	Type-D	如果 DEI=1, 颜色标记为 yellow, 否则颜色标记为 green。																					
举例： 场景描述：入接口配置 trust upstream 命令； 入接口接收到的报文类型：VLAN 或 QinQ 报文； 从出接口发送的报文类型：任意类型。 eth vlan 802.1p=5 DEI=1 IP  入接口：trust upstream trust 8021p field dei enable vlan 出接口 上行映射表 <table><tr><td>802.1p</td><td>phb</td><td>color</td></tr><tr><td>5</td><td>EF</td><td>Green</td></tr></table> 结果： <table><tr><th>上行单板</th><th>phb</th><th>color</th></tr><tr><td>Type-A</td><td>EF</td><td>yellow</td></tr><tr><td>Type-B</td><td>EF</td><td>green</td></tr><tr><td>Type-C</td><td>EF</td><td>green</td></tr><tr><td>Type-D</td><td>EF</td><td>yellow</td></tr></table>			802.1p	phb	color	5	EF	Green	上行单板	phb	color	Type-A	EF	yellow	Type-B	EF	green	Type-C	EF	green	Type-D	EF	yellow
802.1p	phb	color																					
5	EF	Green																					
上行单板	phb	color																					
Type-A	EF	yellow																					
Type-B	EF	green																					
Type-C	EF	green																					
Type-D	EF	yellow																					
其他上行映射的实现差异请参见章节“用于做上行映射（BA）的 QoS 优先级字段是哪个”。																							

下行反射射

详细实现差异请参见章节“PHB 动作的控制”，“报文哪些优先级字段会在 PHB 反射射动作中被修改”和“新增 MPLS 头的 EXP 值设置”。

MPLS Diffserv

详细请参见 [MPLS DiffServ 实现差异](#)

3.5.2 复杂流分类实现差异

重标记

差异项	单板类型	差异描述																										
remark dscp 命令执行结果	Type-B	DSCP 重标记结果与命令行不一定相同。DSCP 是根据下行复杂流分类反映射表设置。																										
	Type-C	DSCP 重标记结果与命令行一致。																										
	Type-A																											
	Type-D																											
	举例： 场景：在报文的入接口或出接口配置重标记 remark dscp 命令。 eth IP dscp=20 → eth IP dscp= ? → 入接口： trust upstream remark dscp 31 出接口： trust upstream 上行映射表： <table><tr><td>dscp</td><td>→</td><td>phb</td><td>color</td></tr><tr><td>31</td><td></td><td>BE</td><td>green</td></tr></table> 下行反映射表： <table><tr><td>phb</td><td>color</td><td>→</td><td>dscp</td></tr><tr><td>BE</td><td>green</td><td></td><td>0</td></tr></table> 结果： <table><tr><th>上行单板</th><th>DSCP</th></tr><tr><td>Type-A</td><td>31</td></tr><tr><td>Type-B</td><td>0</td></tr><tr><td>Type-C</td><td>31</td></tr><tr><td>Type-D</td><td>31</td></tr></table>			dscp	→	phb	color	31		BE	green	phb	color	→	dscp	BE	green		0	上行单板	DSCP	Type-A	31	Type-B	0	Type-C	31	Type-D
dscp	→	phb	color																									
31		BE	green																									
phb	color	→	dscp																									
BE	green		0																									
上行单板	DSCP																											
Type-A	31																											
Type-B	0																											
Type-C	31																											
Type-D	31																											
报文入接口配置的 remark dscp 命令	Type-B	根据下行映射表设置 DSCP 值。如果出接口没有打开 PHB 开关，则 DSCP 值不变。																										
	Type-C	在上行直接修改 DSCP 值。																										
	Type-A																											
	Type-D																											
Example: 场景一: MPLS L3VPN • 入接口配置 trust upstream 和 remark dscp 命令； • 出接口配置 trust upstream 命令。																												

差异项	单板类型	差异描述																																												
		eth IP dscp=20 → eth IP dscp=? 入接口：trust upstream remark dscp 32 出接口：trust upstream 上行映射表： <table><tr><td>dscp</td><td>phb</td><td>color</td></tr><tr><td>32</td><td>af4</td><td>green</td></tr></table> 下行反映射表： <table><tr><td>phb</td><td>color</td><td>dscp</td></tr><tr><td>af4</td><td>green</td><td>46</td></tr></table> 结果： <table><tr><td>上行单板</td><td>dscp</td></tr><tr><td>Type-A</td><td>46</td></tr><tr><td>Type-B</td><td>46</td></tr><tr><td>Type-C</td><td>46</td></tr><tr><td>Type-D</td><td>46</td></tr></table> 场景二：MPLS L3VPN • 入接口配置 remark dscp 和 service-class 命令； • 出接口配置 qos phb disable 命令。 eth IP dscp=20 → eth IP dscp=? 入接口：trust upstream remark dscp 32 出接口： 上行映射表： <table><tr><td>dscp</td><td>phb</td><td>color</td></tr><tr><td>32</td><td>af4</td><td>green</td></tr></table> 下行反映射表： <table><tr><td>phb</td><td>color</td><td>dscp</td></tr><tr><td>af4</td><td>green</td><td>46</td></tr></table> 结果： <table><tr><td>上行单板</td><td>dscp</td></tr><tr><td>Type-A</td><td>32</td></tr><tr><td>Type-B</td><td>20</td></tr><tr><td>Type-C</td><td>32</td></tr><tr><td>Type-D</td><td>32</td></tr></table>	dscp	phb	color	32	af4	green	phb	color	dscp	af4	green	46	上行单板	dscp	Type-A	46	Type-B	46	Type-C	46	Type-D	46	dscp	phb	color	32	af4	green	phb	color	dscp	af4	green	46	上行单板	dscp	Type-A	32	Type-B	20	Type-C	32	Type-D	32
dscp	phb	color																																												
32	af4	green																																												
phb	color	dscp																																												
af4	green	46																																												
上行单板	dscp																																													
Type-A	46																																													
Type-B	46																																													
Type-C	46																																													
Type-D	46																																													
dscp	phb	color																																												
32	af4	green																																												
phb	color	dscp																																												
af4	green	46																																												
上行单板	dscp																																													
Type-A	32																																													
Type-B	20																																													
Type-C	32																																													
Type-D	32																																													
VPLS 场景 Egress PE 的出接口 remark dscp 命令行	Type-B	支持，使用命令行 remark payload-dscp 。																																												
	Type-C	不支持。																																												
	Type-A																																													
	Type-D																																													
remark mpls-exp 命令行	Type-B	不支持。																																												
	Type-C	支持（仅下行支持）。																																												
	Type-A	支持（仅上行支持）。																																												
	Type-D	支持（上、下行都支持）。																																												
	Example: 场景一：MPLS 的 Transit 节点上，报文入接口和出接口都配置了																																													

差异项	单板类型	差异描述																																																																																														
		trust upstream 命令，且入接口配置了 remark mpls-exp 命令。 <table><tr><td>eth</td><td>Outer label exp=2</td><td>Inner label exp=2</td><td>IP</td></tr></table> 入接口: trust upstream remark mpls-exp 3 <table><tr><td>eth</td><td>Outer label exp= ?</td><td>Inner label exp= ?</td><td>IP</td></tr></table> 出接口: trust upstream 上行映射表: <table><tr><td>exp</td><td>→</td><td>phb</td><td>color</td></tr><tr><td>2</td><td></td><td>af2</td><td>green</td></tr><tr><td>3</td><td></td><td>af3</td><td>green</td></tr></table> 下行反映射表: <table><tr><td>phb</td><td>color</td><td>→</td><td>exp</td></tr><tr><td>af2</td><td>green</td><td></td><td>2</td></tr><tr><td>af3</td><td>green</td><td></td><td>3</td></tr></table> 结果: <table><tr><th>上行单板</th><th>外层EXP</th><th>内层EXP</th></tr><tr><td>Type-A</td><td>3</td><td>3</td></tr><tr><td>Type-B</td><td>2</td><td>2</td></tr><tr><td>Type-C</td><td>2</td><td>2</td></tr><tr><td>Type-D</td><td>3</td><td>3</td></tr></table> 场景二：MPLS 的 Transit 节点上，报文入接口和出接口都配置了 trust upstream 命令，且出接口配置了 remark mpls-exp 命令。 <table><tr><td>eth</td><td>Outer label exp=2</td><td>Inner label exp=2</td><td>IP</td></tr></table> 入接口: trust upstream <table><tr><td>eth</td><td>Outer label exp= ?</td><td>Inner label exp= ?</td><td>IP</td></tr></table> 出接口: trust upstream remark mpls-exp 3 Result 上行映射表: <table><tr><td>exp</td><td>→</td><td>phb</td><td>color</td></tr><tr><td>2</td><td></td><td>af2</td><td>green</td></tr><tr><td>3</td><td></td><td>af3</td><td>green</td></tr></table> 下行反映射表: <table><tr><td>phb</td><td>color</td><td>→</td><td>exp</td></tr><tr><td>af2</td><td>green</td><td></td><td>2</td></tr><tr><td>af3</td><td>green</td><td></td><td>3</td></tr></table> <table><tr><th>下行单板</th><th>外层EXP</th><th>内层EXP</th></tr><tr><td>Type-A</td><td>2</td><td>2</td></tr><tr><td>Type-B</td><td>2</td><td>2</td></tr><tr><td>Type-C</td><td>3</td><td>3</td></tr><tr><td>Type-D</td><td>3</td><td>3</td></tr></table>	eth	Outer label exp=2	Inner label exp=2	IP	eth	Outer label exp= ?	Inner label exp= ?	IP	exp	→	phb	color	2		af2	green	3		af3	green	phb	color	→	exp	af2	green		2	af3	green		3	上行单板	外层EXP	内层EXP	Type-A	3	3	Type-B	2	2	Type-C	2	2	Type-D	3	3	eth	Outer label exp=2	Inner label exp=2	IP	eth	Outer label exp= ?	Inner label exp= ?	IP	exp	→	phb	color	2		af2	green	3		af3	green	phb	color	→	exp	af2	green		2	af3	green		3	下行单板	外层EXP	内层EXP	Type-A	2	2	Type-B	2	2	Type-C	3	3	Type-D	3	3
eth	Outer label exp=2	Inner label exp=2	IP																																																																																													
eth	Outer label exp= ?	Inner label exp= ?	IP																																																																																													
exp	→	phb	color																																																																																													
2		af2	green																																																																																													
3		af3	green																																																																																													
phb	color	→	exp																																																																																													
af2	green		2																																																																																													
af3	green		3																																																																																													
上行单板	外层EXP	内层EXP																																																																																														
Type-A	3	3																																																																																														
Type-B	2	2																																																																																														
Type-C	2	2																																																																																														
Type-D	3	3																																																																																														
eth	Outer label exp=2	Inner label exp=2	IP																																																																																													
eth	Outer label exp= ?	Inner label exp= ?	IP																																																																																													
exp	→	phb	color																																																																																													
2		af2	green																																																																																													
3		af3	green																																																																																													
phb	color	→	exp																																																																																													
af2	green		2																																																																																													
af3	green		3																																																																																													
下行单板	外层EXP	内层EXP																																																																																														
Type-A	2	2																																																																																														
Type-B	2	2																																																																																														
Type-C	3	3																																																																																														
Type-D	3	3																																																																																														

ACL/UCL 匹配规则

差异项	单板类型	差异描述
ACL/UCL 匹配 TOS 值	Type-B	ACL/UCL 匹配 TOS 值不关注 TOS 的最后一个比特位，匹配结果可能不正确。 例如，只想 ACL 匹配 TOS=1 的报文，结果是 TOS=0 和 TOS=1 的报文都匹配上了。

差异项	单板类型	差异描述
	Type-C	无此问题。
	Type-A	
	Type-D	
	举例： 场景： <pre># acl 3000 rule 5 permit tcp tos 0 # traffic classifier a if-match acl 3000 # traffic behavior a deny # traffic policy a classifier a behavior a # Interface GigabitEthernet1/0/1 traffic-policy a inbound #</pre> 结果是： • 如果接口 GigabitEthernet1/0/1 所在单板是 Type-B 类型，则丢弃 TOS=0 和 TOS=1 的报文。 • 如果接口 GigabitEthernet1/0/1 所在单板是 Type-A、Type-C 或 Type-D 类型，则只丢弃 TOS=1 的报文。	
	复杂流分类的 all-layer 模式	Type-B
Type-C		不支持。
Type-A		支持
Type-D		使用 traffic-policy policy-name { inbound outbound } all-layer 命令。 设备首先执行二层复杂流分类。如果二层复杂流分类没有匹配任何报文，则继续执行三层复杂流分类。 说明 在 all-layer 模式中，设备不执行 MPLS 复杂流分类。 缺省情况下，设备只执行三层复杂流分类。
举例： 场景： 丢弃 802.1p=0 或者 dscp=40 的报文。		

差异项	单板类型	差异描述									
	eth vlan 802.1p=2 IP dscp=40  入接口： If-match 802.1p 0 If-match dscp 40 traffic behavior: deny traffic-policy inbound all-layer 出接口： 结果： <table><tr><th>上行单板</th><th>流行为</th></tr><tr><td>Type-A</td><td>discarding</td></tr><tr><td>Type-B</td><td>forwarding</td></tr><tr><td>Type-C</td><td>forwarding</td></tr><tr><td>Type-D</td><td>discarding</td></tr></table>	上行单板	流行为	Type-A	discarding	Type-B	forwarding	Type-C	forwarding	Type-D	discarding
上行单板	流行为										
Type-A	discarding										
Type-B	forwarding										
Type-C	forwarding										
Type-D	discarding										
复杂流分类匹配内层 VLAN 的 802.1p	Type-B	不支持。									
	Type-C	V600R005 及之前版本：支持，且只在上行支持。 V600R006 及后续版本：支持，且上、下行都支持。									
	Type-A	不支持。									
	Type-D	支持，且上、下行都支持。									
	举例： 场景：丢弃内层 VLAN 的 802.1p 为 5 的入方向流量（以 V600R006 或后续版本为例）。 eth vlan 802.1p=2 vlan 802.1p=5 IP dscp=40  入接口： acl 3000 rule 5 permit 8021p-inner 5 Traffic classifier: if-match acl 3000 Traffic behavior: deny traffic-policy inbound link-layer 出接口： 结果： <table><tr><th>上行单板</th><th>流行为</th></tr><tr><td>Type-A</td><td>forwarding</td></tr><tr><td>Type-B</td><td>forwarding</td></tr><tr><td>Type-C</td><td>discarding</td></tr><tr><td>Type-D</td><td>discarding</td></tr></table>		上行单板	流行为	Type-A	forwarding	Type-B	forwarding	Type-C	discarding	Type-D
上行单板	流行为										
Type-A	forwarding										
Type-B	forwarding										
Type-C	discarding										
Type-D	discarding										
复杂流分类匹配 MPLS 报文头字段	Type-B	不支持。									
	Type-C	支持。									
	Type-A	使用 traffic-policy policy-name { inbound outbound }									

差异项	单板类型	差异描述										
	Type-D	mpls-layer 命令。										
举例： 场景：丢弃内层标签 EXP 为 2 的出方向报文。 eth Outer label exp=3 Inner label exp=2 IP 入接口： P 出接口： acl 3000 rule 5 permit exp any exp 2 traffic classifier acl 3000 traffic behavior deny traffic-policy outbound mpls-layer 结果： <table><tr><th>下行单板</th><th>流行为</th></tr><tr><td>Type-A</td><td>discarding</td></tr><tr><td>Type-B</td><td>forwarding</td></tr><tr><td>Type-C</td><td>discarding</td></tr><tr><td>Type-D</td><td>discarding</td></tr></table>			下行单板	流行为	Type-A	discarding	Type-B	forwarding	Type-C	discarding	Type-D	discarding
下行单板	流行为											
Type-A	discarding											
Type-B	forwarding											
Type-C	discarding											
Type-D	discarding											

QinQ 终结子接口场景

差异项	单板类型	差异描述
QinQ 终结子接口的复杂流分类	Type-B	如果 QinQ 终结子接口工作在三层，则只支持三层复杂流分类； 如果 QinQ 终结子接口工作在三层，则只支持二层（链路层）复杂流分类。
	Type-C	支持所有类型的复杂流分类。
	Type-A	
	Type-D	
QinQ 终结主接口的复杂流分类	Type-B	复杂流分类对子接口流量生效。
	Type-C	复杂流分类对子接口流量不生效。
	Type-A	
	Type-D	
QinQ 终结子接口出方向的复杂流分类支持的流行为	Type-B	只支持 permit、deny、remark 和流量统计。
	Type-C	支持“3.1 流分类与流动作”章节描述的所有流行为。
	Type-A	

差异项	单板类型	差异描述
	Type-D	

MPLS L2VPN 场景

差异项	单板类型	差异描述																					
VLL or PWE3 场景的复杂流分类	Type-B	不支持。																					
	Type-C	支持。																					
	Type-A																						
	Type-D																						
举例： 场景：VLL or PWE3 场景中，PE 的 UNI 接口配置复杂流分类。 eth vlan 802.1p=2 IP  eth Outer label Inner label eth vlan IP 用户侧接口：trust upstream PE 网络侧接口：trust upstream 配置： trust upstream If-match 8021p 2 service-class af1 color yellow traffic-policy inbound link-layer 上行映射表： <table><tr><td>802.1p</td><td>phb</td><td>color</td></tr><tr><td>2</td><td>af2</td><td>green</td></tr></table> 结果： <table><tr><td>上行单板</td><td>phb</td><td>color</td></tr><tr><td>Type-A</td><td>af1</td><td>yellow</td></tr><tr><td>Type-B</td><td>af2</td><td>green</td></tr><tr><td>Type-C</td><td>af1</td><td>yellow</td></tr><tr><td>Type-D</td><td>af1</td><td>yellow</td></tr></table>			802.1p	phb	color	2	af2	green	上行单板	phb	color	Type-A	af1	yellow	Type-B	af2	green	Type-C	af1	yellow	Type-D	af1	yellow
802.1p	phb	color																					
2	af2	green																					
上行单板	phb	color																					
Type-A	af1	yellow																					
Type-B	af2	green																					
Type-C	af1	yellow																					
Type-D	af1	yellow																					

IPv6 场景

差异项	单板类型	差异描述
对匹配复杂流分类的 IPv6 流量执行 CAR	Type-B	不支持
	Type-C	支持
	Type-A	
	Type-D	

3.6 流分类和标记常见问题解答

3.6.1 简单流分类缺省映射表是否为 RFC 标准定义的？

问题

章节 [Default 域的默认优先级映射表](#) 所描述的缺省映射表是 RFC 标准还是华为自定义的？

解答

这是华为自定义的，不是 RFC 标准。RFC5127 描述了推荐的 EXP 和 DSCP 映射关系，华为路由器遵从此标准。

3.6.2 可否同时重标记多个优先级字段？

问题

可以同时重标记多个优先级字段吗？例如，同时修改 802.1p、EXP 和 DSCP。

解答

可以同时重标记多个优先级字段，在流行为视图下同时配置 **remark 8021p**、**remark mpls-exp** 和 **remark dscp** 命令。

3.6.3 当同一个流策略中配置多个流分类和流行为时，执行顺序是什么样的？

问题

当同一个流策略中配置多个流分类和流行为时，执行顺序是什么样的？按顺序执行？

解答

是的，按顺序执行。详细信息请参见[流策略的执行过程](#)。

3.6.4 如果入接口没有配置简单流分类，设备缺省的行为是什么？

问题

如果入接口没有配置简单流分类，设备缺省的行为是什么？

解答

如果报文入接口没有配置简单流分类，即没有配置 **trust upstream**、**diffserv-mode pipe** 或 **diffserv-mode short-pipe** 命令，则该接口收到的所有报文默认映射为 <BE, Green>，入 BE 队列。

4 流量监管和流量整形

关于本章

- 4.1 流量监管
- 4.2 流量整形
- 4.3 流量监管和流量整形的比较
- 4.4 单板实现差异
- 4.5 流量监管和整形支持列表
- 4.6 流量监管和整形常见问题解答

4.1 流量监管

4.1.1 流量监管简介

流量监管 TP (Traffic Policing) 是指对进入设备的流量进行监控, 确保其没有滥用网络资源。通过监控进入网络的某一流量的规格, 限制它在一个允许的范围之内, 若某个连接的报文流量过大, 就丢弃报文, 或重新设置该报文的优先级 (比如限制 HTTP 报文不能占用超过 50% 的网络带宽), 以保护网络资源和运营商的利益不受损害。

运营商之间都签有服务水平协议 (SLA), 其中包含每种业务流的承诺速率 CIR (Committed Information Rate)、峰值速率 PIR (Peak Information Rate)、承诺突发尺寸 CBS (Committed Burst Size)、峰值突发尺寸 PBS (Peak Burst Size) 等流量参数, 对超出 SLA 约定的流量报文可指定给予 pass (通过)、drop (直接丢弃) 或 markdown (降级) 等处理, 此处降级是指降低服务等级 (Service Class), 或者是提高丢弃等级 (Color), 即报文在网络拥塞时将被优先丢弃, 从而保证在 SLA 约定范围之内的报文享受到 SLA 预定的服务。

流量监管采用承诺访问速率 CAR (Committed Access Rate) 来对流量进行控制。CAR 使用令牌桶算法进行流量速率的评估, 依据评估结果, 实施预先设定好的监管动作。对应于 SLA 预定的处理动作, 流量监管动作包括:

- 转发 (pass): 对测量结果不超过 CIR 的报文通常处理为继续正常转发。

- 丢弃 (discard): 对测量结果超过 PIR 的报文通常进行丢弃。
- 重标记 (remark): 对处于承诺速率 (CIR) 与峰值速率 (PIR) 之间的流量通常执行 Remark 动作, 此时的报文不丢弃, 而是通过 Remark 降低优先级进行尽力而为转发。


4.1.2 令牌桶算法

什么是令牌桶

要实现流量的控制, 必须有一种机制可以对通过设备的流量进行度量。令牌桶是目前最常采用的一种流量测量方法, 用来评估流量速率是否超过了规定值。

如图 4-1, 令牌桶可以看作是一个存放令牌的容器, 预先设定一定的容量。系统按给定的速度向桶中放置令牌, 当桶中令牌满时, 多余的令牌溢出。

图4-1 令牌桶示意图




说明

令牌桶只是一种流量测量方法, 并不能对流量进行过滤或采取某种措施, 比如说丢弃数据包等, 这些操作由其他功能完成。

令牌桶中装的是令牌而不是分组。

如图 4-2, 当数据流到达设备时首先会根据数据的大小从令牌桶中取出与数据大小相当的令牌数量用来传输数据。也就是说要使数据被传输必须保证令牌桶里有足够多的令牌, 如果令牌数量不够, 则数据会被丢弃或缓存。这就可以限制报文的流量只能小于等于令牌生成的速度, 达到限制流量的目的。

图4-2 用令牌桶处理报文



当前令牌桶算法已广泛应用于 CAR 技术、流量整形技术以及接口限速 LR（Line Rate）等 QoS 技术中。



说明

如何应用令牌桶算法将在本文档中后文的 CAR、流量整形中分别介绍，本节仅介绍令牌桶算法。

两种令牌桶算法

IETF 定义了两种令牌桶算法——单速率三色标记算法（RFC 2697）和双速率三色标记算法（RFC 2698），使用红、黄、绿三色来标记评估结果。（注：此处的红、黄、绿三色同流分类中表示丢弃优先级的红、黄、绿三色没有关系，两者只是重名而已）。这两种算法都允许流量在一定程度上突发，但单速率三色标记关注报文尺寸的突发，而双速率三色标记则关注速率上的突发。单速率较双速率实现简单，成为目前业界比较常用的流量评估方式。

两种令牌桶算法都有两种工作模式——色盲模式（Color-Blind）与非色盲模式（Color-Aware，也叫“色敏模式”），其中色盲模式是较常用的，也是默认的模式。

单速率令牌桶参数

单速率令牌桶主要由如下三个参数构成：


- CIR（Committed Information Rate）：承诺信息速率，单位是 bit/s，表示向令牌桶中投放令牌的速率。
- CBS（Committed Burst Size）：承诺突发尺寸，单位为 bit，用来定义在部分流量超过 CIR 之前的最大突发流量，即为令牌桶的容量（深度）。承诺突发尺寸必须大于报文的最大长度（最大时一个分组可以领取桶中的全部令牌）。CBS 越大，表示所允许的突发量越大。
- EBS（Extended burst size）：超额突发尺寸，用来定义在所有流量超过 CIR 之前的最大突发量。

如果到达的分组未超过 CBS，则把它标记为绿色；如果超过了 CBS 而未超过 EBS，则把它标记为黄色；否则，标记为红色。在网络流量比较简单的情况下，单速率三色标记算法可以用在网络入口处来测量流量。

单速率令牌桶结构

对于单速率标记算法的实现，华为路由器采用双桶结构。

图4-3 单速率令牌桶结构



双桶结构由两个桶实现，为方便将两个令牌桶称为 C 桶和 E 桶。C 桶容量为 CBS，E 桶容量为 EBS，总容量是 CBS+EBS。如果不允许有突发流量，EBS 则设置成 0。

当 $EBS \neq 0$ 时，称为单速双桶。当 $EBS = 0$ ，E 桶的令牌数始终为 0，相当于只使用了一个令牌桶——C 桶，这种情况也称为单速单桶。单速单桶中，报文只标记为绿、红两色。

说明

“单速率”是指算法中的两个令牌桶有同样的承诺信息速率（CIR），也就是具有相同令牌添加速率。

单速率令牌添加方式

单速率标记算法中，初始状态时两桶是满的。先往 C 桶中添加令牌，等 C 桶满了，再往 E 桶中添加令牌（E 桶的令牌用做以后临时超过 CIR 的突发流量），当两桶都被填满时，新产生的令牌将会被丢弃。

单速率流量评估规则

当报文到来后，直接与桶中的令牌数相比较，如果有足够的令牌就转发（通常用一个令牌关联一个比特的转发权限），如果没有足够的令牌则丢弃或缓存。

为方便使用 T_c 和 T_e 表示桶中的令牌数量， T_c 和 T_e 初始化等于 CBS 和 EBS。

色盲模式下，在对到达报文（假设报文大小为 B）进行评估时，遵循以下规则：

- 对于单速单桶：
 - 如果报文长度不超过 C 桶中的令牌数 T_c ，则报文被标记为绿色，且 $T_c = T_c - B$ ，
 - 如果报文长度超过 C 桶中的令牌数 T_c ，报文被标记为红色， T_c 值不变。

- 对于单速双桶：
 - 如果报文长度不超过 C 桶中的令牌数 T_c ，则报文被标记为绿色，且 $T_c = T_c - B$ ，
 - 如果报文长度超过 C 桶中的令牌数 T_c 但不超过 E 桶中的令牌数 T_e ，则报文被标记为黄色，且 $T_e = T_e - B$ ，
 - 如果报文长度超过 E 桶中的令牌数 T_e ，报文被标记为红色，但 T_c 和 T_e 不变。

色敏模式下，在对到达报文（假设报文大小为 B）进行评估时，遵循以下规则：

- 对于单速单桶：
 - 如果报文已被标记为绿色但报文长度不超过 C 桶中的令牌数 T_c ，则报文被标记为绿色，且 $T_c = T_c - B$ ；
 - 如果报文已被标记为绿色且报文长度超过 C 桶中的令牌数 T_c ，则报文被标记为红色， T_c 保持不变；
 - 如果报文已被标记为黄色或红色，都直接将报文标记为红色， T_c 保持不变。
- 对于单速双桶：
 - 如果报文已被标记为绿色且报文长度不超过 C 桶中的令牌数 T_c ，则报文被标记为绿色，且 $T_c = T_c - B$ ，
 - 如果报文已被标记为绿色且报文长度超过 C 桶中的令牌数 T_c 但不超过 E 桶中的令牌数 T_e ，则报文被标记为黄色，且 $T_e = T_e - B$ ，
 - 如果报文已被标记为黄色但报文长度不超过 E 桶中的令牌数 T_e ，则报文被标记为黄色，且 $T_e = T_e - B$ ，
 - 如果报文已被标记为黄色且报文长度超过 E 桶中的令牌数 T_e ，则报文被标记为红色，且 T_e 保持不变，
 - 如果报文已被标记为红色，直接将报文标记为红色， T_c 和 T_e 不变。

双速率令牌桶参数

双速率令牌桶主要包括四个参数：

- CIR（Committed Information Rate）：承诺信息速率，表示端口允许的信息流平均速率，单位是 bit/s。
- CBS（Committed Burst Size）：承诺突发尺寸，用来定义在部分流量超过 CIR 之前的最大突发流量，单位为 bit。承诺突发尺寸必须不小于报文的最大长度。
- PIR（Peak Information Rate）：表示峰值信息速率，表示端口允许的突发流量的最大速率，单位是 bit/s。该值必须不小于 CIR 的设置值。
- PBS（Peak Burst Size）：表示峰值突发尺寸，用来定义每次突发所允许的最大的流量尺寸。

双速率令牌桶结构


双速率三色标记算法业界都使用两个令牌桶，但它关注的是速率的突发，所以不像单速率三色标记算法那样把第一个桶中未使用的令牌放到第二个桶中，而是使用两个独立的令牌桶，存在两个令牌填充速率。为方便将两个令牌桶称为 C 桶和 P 桶，C 桶容量为 CBS，令牌填充速率为 CIR，P 桶容量为 PBS，令牌填充速率为 PIR。



说明

“双速率”是指该算法中两个令牌桶中的令牌填充速率不同。

图4-4 双速率令牌桶结构



双速率令牌添加方式

初始状态时两桶是满的。往 C 桶和 P 桶分别以 CIR 和 PIR 的速率填充令牌。因这两个令牌桶是相互独立的，当其中一个桶被填满时，这个桶新产生的令牌将会被丢弃，另一个桶继续填令牌。

双速率流量评估规则

双速率三色标记算法关注的是速率的突发，首先评估的是数据流的速率是否符合规定的突发要求，其规则是先比较 P 桶，再比较 C 桶。

双速率三色标记算法也有色盲模式和色敏模式两种。为方便用 T_c 和 T_p 表示桶中的令牌数量， T_c 和 T_p 初始化等于 CBS 和 PBS。

色盲模式下，在对到达报文（假设数据包大小为 B）进行评估时，遵循以下规则：

- 如果报文长度超过 P 桶中的令牌数 T_p ，则报文被标记为红色，且 T_c 和 T_p 保持不变，
- 如果报文长度不超过 P 桶中的令牌数 T_p 但超过 C 桶中的令牌数 T_c ，则报文被标记为黄色，且 $T_p = T_p - B$ ，
- 如果报文长度不超过 C 桶中的令牌数 T_c ，报文被标记为绿色，且 $T_p = T_p - B$ ， $T_c = T_c - B$ 。

色敏模式下，在对到达报文（假设报文大小为 B）进行评估时，遵循以下规则：

- 如果报文已被标记为绿色且报文长度超过 P 桶中的令牌数 T_p ，则报文被标记为红色，且 T_p 和 T_c 不变。
- 如果报文已被标记为绿色且报文长度不超过 P 桶中的令牌数 T_p 但超过 C 桶中的令牌数 T_c ，则报文被标记为黄色，且 $T_p = T_p - B$ ， T_c 不变。
- 如果报文已被标记为绿色且报文长度不超过 C 桶中的令牌数 T_c ，则报文被标记为绿色，且 $T_p = T_p - B$ ， $T_c = T_c - B$ 。

- 如果报文已被标记为黄色，则只比较 P 桶，如果报文长度超过 P 桶中的令牌数 T_p ，则报文被标记为红色，且 T_p 和 T_c 不变。
- 如果报文已被标记为黄色，且报文长度不超过 P 桶的令牌数，则报文被标记为黄色，且 $T_p = T_p - B$ ， T_c 不变。
- 如果报文已被标记为红色，直接将报文标记为红色， T_c 和 T_p 不变。

4.1.3 CAR

什么是 CAR


流量监管采用承诺访问速率 CAR（Committed Access Rate）来对流量进行控制。CAR 利用令牌桶来衡量每个数据报文是超过还是遵守所规定的报文速率。

CAR 主要有两个功能：

- 流量速率限制：通过使用令牌桶对流经端口的报文进行度量，使得在特定时间内只有得到令牌的流量通过，从而实现限速功能。
- 流分类：根通过令牌桶算法对流量进行测量，根据测量结果给报文打上不同的流分类内部标记（包括服务等级与丢弃优先级）。

CAR 的处理流程

图4-5 CAR 处理流程示意图



- 当报文到来时，首先检查端口的匹配规则，如果匹配上了，则进行速率控制，报文进入令牌桶中进行流量速率评估。
- 令牌桶评估后，报文被标记为红、黄、绿三种颜色。红色表示报文速率过大，不符合规定；黄色表示虽然不符合规定但允许临时的突发，绿色表示符合规定。
- 报文标为红色的直接丢弃，黄色则重新标记后转发，绿色则直接转发。

CAR 的报文标记过程

华为路由器依据 RFC2697/RFC2698 实现 CAR 功能。CAR 中令牌添加方式是报文触发，添加令牌的数量是 $CIR \times$ 当前时间与上次添加令牌的时间之差。向桶内注入令牌后，再判断桶内的令牌数是否满足传送该报文的要求。

CAR 支持单速单桶、单速双桶、双速双桶的标记方式。本文举例介绍这三种标记的色盲模式如何处理报文（色敏模式的处理与之类似）。

● 单速单桶

假设设备端口的 CIR 设置为 1Mbps，CBS 为 2000 bytes，初始状态时 C 桶满（单速单桶的 EBS 为 0，只有一个 C 桶）。

- 假设第 1 个到达的报文是 1500 bytes 时，检查 C 桶发现令牌数大于数据包的长度，所以数据包被标为绿色，C 桶减少 1500 bytes，还剩 500 bytes。
- 假设 1ms 之后到达第 2 个报文 1500 bytes，先填充令牌，新增令牌=CIR*时间间隔=1Mbps*1ms=1000bit=125bytes，加上 C 桶原来剩余的令牌 500bytes，此时 C 桶共有 625bytes，令牌不够，报文标记为红色。
- 假设又过 1ms 后到达第 3 个报文 1000 bytes，但 C 桶只有 625 bytes，小于报文长度，因此新增令牌 CIR*1ms=1000bit=125bytes，此时 C 桶共有 750 bytes，依然不够，因此报文被标记为红色。
- 假设又过 20ms 后到达第 4 个报文 1500 bytes，但 C 桶只有 750 bytes，小于报文长度，因此 C 桶新增令牌 CIR*20ms=20000bit=2500bytes，C 桶此时令牌数 3250 bytes，而 CBS=2000bytes，因此溢出 1250bytes 令牌被丢弃，此时 C 桶大于报文长度，报文标记为绿色，C 桶减少 1500bytes，剩 500bytes。

以上过程汇总如下：

包序号	时刻	包长	与上次添加令牌的间隔	本轮增加令牌	令牌增加后 C 桶令牌	报文处理后 C 桶剩余令牌	报文标记结果
-	-	-	-	-	2000	2000	-
1	0	1500	0	0	2000	500	绿色
2	1	1500	1	125	625	625	红色
3	2	1000	1	125	750	750	红色
4	22	1500	20	2500	2000	500	绿色

● 单速双桶

假设设备端口的 CIR 设置为 1Mbps，CBS 为 2000 bytes，EBS 为 2000 bytes，初始状态时 C 桶和 E 桶满。

- 假设第 1 个到达的报文是 1500 bytes 时，检查 C 桶发现令牌数大于数据包的长度，所以数据包被标为绿色，C 桶减少 1500 bytes，还剩 500 bytes，E 桶保持不变。
- 假设 1ms 之后到达第 2 个报文 1500 bytes，但 C 桶只有 500 bytes，小于报文长度，因此新增令牌 CIR*1ms=1000bit=125bytes，此时 C 桶共有 625 bytes，依然不够。检查 E 桶有足够令牌，因此报文标记为黄色，E 桶减少 1500bytes，剩 500bytes，C 桶不变。
- 假设又过 1ms 后到达第 3 个报文 1000 bytes，但 C 桶只有 625 bytes，小于报文长度，因此新增令牌 CIR*1ms=1000bit=125bytes，此时 C 桶共有 750

bytes，依然不够，检查 E 桶也不够，因此报文被标记为红色，C 桶、E 桶令牌数不变。

- 假设又过 20ms 后到达第 4 个报文 1500 bytes，但 C 桶只有 750 bytes，小于报文长度，因此 C 桶新增令牌 $CIR \times 20ms = 20000bit = 2500bytes$ ，C 桶此时令牌数 3250 bytes，而 CBS=2000bytes，因此溢出 1250bytes 添加到 E 桶，此时 E 桶有 1750bytes。由于此时 C 桶大于报文长度，报文标记为绿色，C 桶减少 1500bytes，剩 500bytes，E 桶不变。

以上过程汇总如下：

包序号	时刻	包长	与上次添加令牌的间隔	本轮增加令牌	令牌增加后各桶令牌		报文处理后各桶剩余令牌		报文标记结果
					C 桶	E 桶	C 桶	E 桶	
-	-	-	-	-	2000	2000	2000	2000	-

1	0	1500	0	0	2000	2000	500	2000	绿色
---	---	------	---	---	------	------	-----	------	----

2	1	1500	1	125	625	2000	625	500	黄色
3	2	1000	1	125	750	500	750	500	红色
4	22	1500	20	2500	2000	1750	500	1750	绿色

● 双速双桶

假设设备端口的 CIR 设置为 1Mbps，PIR 设置为 2Mbps，CBS 为 2000 bytes，PBS 为 2000 bytes，初始状态时 C 桶和 P 桶满。

- 第 1 个到达的报文假设是 1500 bytes 时，检查发现报文长度不超过 P 桶也不超过 C 桶，所以数据包被标为绿色，C 桶和 P 桶都减少 1500 bytes，C 桶还剩 500 bytes，P 桶还剩 500bytes。
- 假设 1ms 后到达第 2 个报文 1500 bytes，超过 P 桶，因此 P 桶新增令牌 $PIR \times 1ms = 2000bit = 250bytes$ ，此时 P 桶共有 750 bytes，依然小于报文长度。因此报文标记为红色，P 桶、C 桶令牌数不变。
- 假设又过 1ms 后到达第 3 个报文 1000 bytes，超过 P 桶，因此 P 桶新增令牌 $PIR \times 1ms = 2000bit = 250bytes$ ，此时 P 桶共有 1000 bytes，等于报文长度，再检查 C 桶，此时 C 桶 500bytes，小于令牌数，因此 C 桶新增令牌 $CIR \times 2ms = 2000bit = 250bytes$ ，此时 C 桶 750bytes，仍然小于报文长度，因此报文被标记为黄色，P 桶减少 1000bytes，剩 0bytes，C 桶不变。
- 假设又过 20ms 之后到达报文 1500 bytes，但 P 桶没有令牌，不够发送报文，因此 P 桶新增令牌 $PIR \times 20ms = 40000bit = 5000bytes$ ，超过 P 桶容量 PBS，因此 P 桶 = PBS = 2000bytes，溢出的令牌丢弃；这样 P 桶有 2000bytes，大于报文长度，因此比较 C 桶，C 桶此时令牌数 750bytes，小于报文长度，因此 C 桶新增令牌 $CIR \times 20ms = 20000bit = 2500bytes$ ，大于 CBS 的 2000 bytes，因此溢出的

令牌丢弃，C 桶此时令牌数 2000 bytes，大于报文长度，报文被标记为绿色，C 桶减少 1500bytes 还剩 500bytes，P 桶减少 1500bytes 还剩 500bytes。

以上过程汇总如下：

包序号	时刻	包长	与上次添加令牌的间隔		本轮增加令牌		令牌增加后各桶令牌		报文处理后各桶剩余令牌		报文标记结果
			C 桶	P 桶	C 桶	P 桶	C 桶	P 桶	C 桶	P 桶	
-	-	-	-	-	-	-	2000	2000	2000	2000	-

1	0	1500	0	0	0	0	2000	2000	500	500	绿色
---	---	------	---	---	---	---	------	------	-----	-----	----

2	1	1500	1	1	125	250	500	750	500	750	红色
3	2	1000	2	1	250	250	750	1000	750	0	黄色
4	22	1500	20	20	2500	5000	2000	2000	500	500	绿色

三种令牌桶的使用场景

单速单桶和单速双桶关注报文尺上的突发，其令牌添加方式和报文处理流程比较简单；双速双桶关注速率上的突发，其令牌添加方式和报文处理流程相对复杂。

单速和双速各有优点，不同的实现方式决定了其具有一定的性能差异（丢包率、突发流量处理性能、大小包混合转发性能、数据转发平缓程度等），在实际应用中，应针对不同的流量特征选择恰当的标记方式。

- 如果只是为了限制带宽，使用单速单桶。
- 如果在限制带宽的基础上，还要对输入流量的突发情况进行区分，做不同的标记处理，则使用单速双桶。注意：标记为 **yellow** 的动作一定要同标记为 **green** 的配置的不一样，否则限速效果与单速单桶一样。
- 如果在限制带宽的基础上，还要对输入流量的带宽情况进行区分，区分出带宽是小于 CIR 还是在 CIR~PIR 之间，则使用双速双桶。注意：标记为 **yellow** 的动作也要同标记为 **green** 的动作配置得不一样，否则限速效果与单速单桶一样。

CAR 的参数设置

在令牌桶算法中，CIR 设置越大，令牌产生的速率越大，则分组获得令牌就越多，流向网络的流量也就越大，因此，CIR 的大小是控制流入网络中流量多少的关键。另外，令牌桶桶深 CBS 也是一个重要参数，随着令牌桶桶深的增加，C 桶中积累令牌的数目也将越多，流入网络的流量就越大。

- 对于承诺突发流量 CBS，不应该小于报文的最大长度，因为路由器是逐包转发的。例如，当 CIR=100Mbps，CBS=200bytes，那么对于 1500byte 每包的流量而言，每次令牌桶比较的包长都大于 CBS，即使数据流速率小于 100Mbps，也全部被标记为红色或黄色，导致 CAR 效果不准确。
- 对于超额突发流量 EBS，单位为 bit。在华为设备上，CBS 与 EBS 是由两个单独的令牌桶承载的，CBS 与 EBS 的大小没有什么必然联系，如果不允许有突发流量的话，EBS 只要设置成 0。要使令牌桶有扩展突发能力只要 EBS 设置的大于 0。

令牌桶算法的带宽参数设置取决于实际网络业务的限速需要。桶深是一个重要参数，具体该如何设置，则取决于具体的业务流量情况。原则上，桶深需要满足如下条件：

1. 桶深 $\geq$ MTU
2. 桶深 $\geq$ 业务流量的正常突发

条件 1 比较直观，容易操作；但条件 2 实际操作比较困难，因此出现了一些经验性的计算公式，例如：

桶深(Bytes)=带宽(kbps) * RTT(ms) / 8，其中的 RTT 是 TCP 协议的往返时间，通常取 200ms。

对华为路由器总结的经验性公式为：

- 带宽 $\leq$ 100Mbps 时，桶深(Bytes)=带宽(kbps) * 1500(ms) / 8
- 带宽 $>$ 100Mbps 时，桶深(Bytes)=100,000(kbps) * 1500(ms) / 8



注意

CAR 之后的带宽计算是基于整包的，即不仅仅包括 IP 头及 IP 净荷。例如，对于以太网业务，还包含了帧头和 CRC，但不包含前导码、帧间隔。完整的以太网帧如下（长度单位：字节）：


Minimum 12	7	1	6	6	2	46 to 1500	4
Inter frame gap	Preamble	SFD	Destination MAC	Source MAC	Length/type	Data payload	CRC

CAR 之后的带宽计算不包括其中的 Inter frame gap、Preamble、SFD。

4.1.4 流量监管的应用


如图 4-6，流量监管主要应用于网络边缘入口处，对超出 SLA 约定的流量报文给予通过、直接丢弃或降级处理，从而保证在 SLA 约定范围之内的报文享受到 SLA 预定的服务，同时保证核心设备的正常数据处理。

图4-6 流量监管的应用一



如图 4-7，通过路由器连接广域网和局域网，局域网的带宽（100Mbps）通常比广域网（2Mbps 或更低）高。当局域网用户试图通过广域网发送大量数据时，在网络边缘（路由器）就会发生拥塞。这种情况下，可以在网络边缘（路由器）的入口处进行流量监管，限制大流量数据的速率。


图4-7 流量监管的应用二



基于接口的流量监管

基于接口的流量监管是指对进入该接口的所有流量进行控制，而不区分具体报文的类型。例如图 4-8，ISP 某台边界路由器接入了三个用户网络。根据 SLA，每个用户不能发送超过 256kbps 的流量，但有时他们可能会随意发送。此时，可以在边界路由器的入接口上进行流量监管，将用户流量限制在 256Kbps 以下，超过 256Kbps 的流量将被丢弃。

图4-8 基于接口的流量监管应用




基于类的流量监管

基于类的 CAR 策略是指对进入该接口的满足特定条件的某一类或几类报文进行流量控制，而非所有报文。

例如图 4-9，假设有 3 个用户（1.1.1.1、1.1.1.2、1.1.1.3）集合到一台路由器。根据 SLA，每个用户不能发送超过 256Kbps 的数据流，但有时他们可能会随意发送。当一个用户发送了大量的数据流时，可能会干涉到其他用户的数据流，即使这些用户按照 256kbps 甚至更低速率发送。此时，可以在路由器的入接口上基于源地址进行流分类和流量监管，监测进入路由器的速率，如果某个用户的速率超过 256Kbps，则丢弃该用户超过速率的分组。

图4-9 基于类的流量监管应用



说明


此例中需要在一个接口上配多个 CAR 策略，针对不同源地址的数据流进行速率限制。这种情况下，CAR 策略生效的顺序是按照配置的顺序排列的，最先配置的策略会在数据流到达端口时最先生效。

流量监管和其他 QoS 策略的配合

流量监管通常和其他的 QoS 策略配合使用，共同提供全网 QoS 保障。

图 4-10 是流量监管和拥塞避免配合使用的场景。假设有 4 个用户网络集合到一台 ISP 网络的边缘路由器。根据 SLA 规定，每个用户网络都不能发送超过 256Kbps 的 FTP 数据流，但有时他们可随意发送，甚至会发送超过 1Mbps 的 FTP 数据流。当一个用户网络发送了大量的 FTP 数据流时，可能会干涉到某个其他用户网络的 FTP 数据流，即使这些用户网络按照 256kbps 甚至更低速率在发送。此种情况中，可以在每个入接口上配置基于类的流量监管，监测入接口的 FTP 的速率，并重标记报文的 DSCP 值。如果速率小于等于 256Kbps，分组被标记为 AF11，如果速率在 256Kbps 到 1Mbps 之间，分组被标记为 AF12，如果速率超过 1Mbps 的分组标记为 AF13。在 ISP 网络的其他节点出接口上对 AF1 类流量配置 WRED（Weighted Random Early Detection）丢弃策略，避免网络拥塞。WRED 根据分组的 DSCP 标记丢弃该类分组。首先丢弃 AF13 分组，AF12 分组和 AF11 分组就会在最后被丢弃。

图4-10 流量监管和拥塞避免配合使用



流量监管的数据统计功能

对进入网络中的用户流量进行控制和统计是十分必要的。但是传统的接口统计计数存在以下不足：

- 在上行只能统计出 CAR 之前的流量，无法统计用户真正需要的流量和流量超过带宽限制时的丢包情况。
- 在下行只能统计出接口 CAR 后的接口流量，无法统计通过和丢弃的流量。

因此，运营商需要在 CAR 后再做一次统计，用来分析用户流量超过限制的情况，以这个数据为依据，建议用户购买更大的带宽。华为路由器实现接口 CAR 的统计功能，能够对上行 CAR 后的流量，即企业用户或者网吧真正的接入流量情况以及下行 CAR 后的报文通过和丢弃情况进行统计记录，方便运营商了解用户的网络流量情况。


4.2 流量整形

什么是流量整形

流量整形是对输出报文的速率进行控制，使报文以均匀的速率发送出去。


流量整形通常是为了使报文速率与下游设备相匹配。当从高速链路向低速链路传输数据，或发生突发流量时，带宽会在低速链路出口处出现瓶颈，导致数据丢失严重。这种情况下，需要在进入高速链路的设备出口处进行流量整形，如图 4-11。

图4-11 从高速链路向低速链路传输数据



通过在上游设备的接口出方向配置流量整形，将上游不规整的流量进行削峰填谷，输出一条比较平整的流量（如图 4-12），从而解决下游设备的瞬时拥塞问题。

图4-12 使用流量整形的效果



流量整形的实现原理

流量整形通常使用缓冲区和令牌桶来完成，当报文的发送速度过快时，首先在缓冲区进行缓存，在令牌桶的控制下再均匀地发送这些被缓冲的报文。

华为路由器上，流量整形中令牌添加方式是周期性添加，添加的时间间隔为 CBS/CIR，每次添加的令牌数为 CBS 个。

流量整形使用的令牌桶类型是单速单桶，评估结果只有符合（Green）和超标（Red）两种。

说明

华为路由器上，流量整形之后的带宽计算不包括帧头和 CRC，这与 CAR 相反。例如 shaping 23Mbps，对于 IPoE 而言，是指 IP 流量为 23Mbps，不包含帧头、CRC。


此外，流量整形中的 CBS 参数是否支持手工修改与产品类型、版本、单板类型相关。

流量整形是在队列调度之后，数据包在出队列的过程中进行的（队列及队列调度的相关介绍请参见本文下一章节“5 拥塞管理和避免”）。

流量整形分为两种：


- 队列流量整形：对接口的每个队列进行流量整形，区分优先级。
 - 队列调度之后在出队的时候，对于不需要整形的报文，直接转发；对于需要进行整形的报文，则先进行令牌桶评估。
 - 在令牌桶评估后，如果数据包速率符合要求，则被标记为绿色并转发；如果数据包速率超标，则当前正在出队的数据包仍然转发出去，同时，将该数据包所在队列的状态改为不可调度，等令牌桶填充了新的令牌时再调度此队列。队列的状态改为不可调度后，该队列允许报文继续入队，但入队满了的时候会丢弃报文。因此，虽然流量整形使超额的数据能够从接口平滑地输出，但并不表示流量整形永远不会丢包。

图4-13 队列流量整形过程



- 接口流量整形：也叫接口限速 LR（Line rate），限制接口发送的所有报文（包括紧急报文）的总速率，是对整个出接口进行流量整形，不区分优先级。如图 4-14，
 - 队列调度之后在出队的时候，对所有队列的数据包总和进行令牌桶评估。
 - 在令牌桶评估后，如果数据包总速率符合要求，则转发；如果数据包总速率超标（即令牌桶中的令牌不足），则接口暂停调度，等令牌足够时再继续调度。


图4-14 端口流量整形过程



流量整形的应用

流量整形的典型应用是基于下游网络节点的流量监管的 SLA 指标来控制本地流量的输出，减少报文丢失。


图4-15 流量整形的应用



- 端口流量整形的应用

如图 4-16，假设一个 Hub-Spoke 组网模式的企业，总部与分支机构通过 ISP 使用专线相连，其链路带宽为 1Gbps。当所有分支同时向总部发送数据时，可能会在连接总部的 ISP 边缘节点造成拥塞。为了避免在 ISP 丢包，可以在各分支的边缘设备出口处进行端口流量整形。

图4-16 端口流量整形的应用




- 队列流量整形的应用

如图 4-17，假设一个 Hub-Spoke 组网模式的企业，总部与分支机构通过 ISP 使用专线相连，其链路带宽为 1Gbps。分支机构访问 Internet 是经过总部的，而总部到 Internet 的链路只有 100Mbps。如果所有分支机构以高速率同时访问 Internet，则可能使分支机构及总部访问 Internet 的总 web 流量超过 100Mbps，导致 web 流量在 ISP 被丢弃。

如果在分支机构的出口设备及总部访问 Internet 的出口设备上配置基于队列对 web 流量进行整形，可防止 web 流量的丢失。


图4-17 队列流量整形的应用



整形精度调整-最后一公里 QoS

最后一公里是指宽带接入交换机（如以太/ATM DSLAM）到最终用户的这一段传输线路。在最后一公里，如图 4-18，企业/家庭用户通常采用 IPoE、PPPoE、IPoA、PPPoA、IPoEoA 或 PPPoEoA 方式接入到以太/ATM DSLAM，DSLAM 再通过城域网接入到 IP 骨干网边缘设备 BRAS/SR。

图4-18 最后一公里组网示例




对于宽带接入的场景，BRAS/SR 和 DSLAM 之间是以太链路，BRAS/SR 采用以太封装报文，其流量整形是基于以太封装的。

如果用户和 DSLAM 之间是 ATM 链路，DSLAM 的用户侧采用 ATM 封装报文，其封装开销可能大于以太封装开销，因此 BRAS/SR 整形后的流量可能超出 DSLAM 的 ATM 线路能力，导致 DSLAM 处拥塞而发生丢包。

例如图 4-19，假设用户和 DSLAM 之间使用 PPPoEoA 传输报文，DSLAM 和 BRAS/SR 之间使用 PPPoE 传输报文。

图4-19 最后一公里报文字段变化 (PPPoE->PPPoEoA)



报文在 DSLAM 上，对整个 PPPoE 包进行 1483B 类型封装（添加 LLC 封装首部），再把 1483B 帧进行 AAL5 封装（添加 AAL5 的 CPCS-PDU Trailer），最后切成 48 字节的 ATM 信元负载，封装到 ATM 信元中。


根据图 4-20 所示的各种报文首部长度的计算，图 4-19 场景中，如果 AAL5 封装时使用 LLC 封装方式，则 PPPoE 封装开销共 14+6=20 字节，PPPoEoA 封装开销共 6+14+8+8=36 字节。

假设 PPPoE 负载为 L 字节，则 PPPoEoA 帧的负载为 L+36。当 L+36 为 48 的倍数时，传输该数据包需要的 ATM 信元个数 = $(L+36)/48$ ；当 L+36 不是 48 的倍数时，需要的信元个数 = $(L+36)/48+1$ 。因此，该数据包封装 ATM 信元首部后的长度变为 $((L+36)/48+1)*53$ 字节或者 $((L+36)/48)*53$ 字节。


假如 BRAS/SR 发给 DSLAM 的 PPPoE 负载都为 100 字节，速率为 2Mbps，则 DSLAM 发给 CPE 的报文速率将变为 $((100+36)/48+1)*53/120*2\text{Mbps} \approx 3.4\text{Mbps}$ 。

图4-20 报文封装格式


PPPoE封装格式:




Eth封装格式:




VLAN封装格式:




QinQ封装格式:




AAL5封装格式 (VC封装方式):



AAL5封装格式 (PPPoA, LLC封装方式):



AAL5封装格式 (IPoA/IPoEoA/PPPoEoA, LLC封装方式):



即使用户和 DSLAM 之间也是以太网链路，其封装开销也可能比 BRAS/SR 上的用户侧封装开销大。例如，BRAS/SR 封装的以太网报文不带 VLAN Tag，用户和 DSLAM 之间采用 VLAN 或 QinQ 封装，其报文则携带了一层或两层 VLAN TAG。

为了解决上述问题，可在 BRAS/SR 配置最后一公里 QoS 特性。最后一公里 QoS 是指设备在进行流量整形时，根据用户订购带宽和 DSLAM 下行接口带宽进行精度调整，通过调整报文字节对整形带宽进行补偿。

由于 BRAS/SR 无法解析以多层协议封装的用户报文（例如转发 PPPoE 报文时 BRAS/SR 只解析 Eth 封装，不解析 Eth 封装之前的协议封装），且对于 DSLAM 采用 ATM 链路接入 CPE 的场景（如图 4-20）：

- DSLAM 进行 AAL5 封装时，需要对负载进行填充，使其长度为 48 字节的倍数。
- DSLAM 进行 AAL5 封装时，有可能进行 LLC 封装，也可能进行 VC 封装。这两种封装的开销不同，且 PPPoA 的 LLC 封装与 IPoA/PPPoEoA/IPoEoA 也不同。

以上原因导致 BRAS/SR 无法自动推断出报文经过 DSLAM 封装后的总长度，需要手工配置补偿字节数 overhead。

配置补偿字节数之后，对于 DSLAM 采用以太链路接入 CPE 的场景，BRAS/SR 会自动根据转发的报文长度及配置的 overhead，直接推断出报文经过 DSLAM 封装后的总长度，从而自动对整形带宽进行修正。

对于 ATM，BRAS/SR 也会自动根据报文长度及 overhead，计算出 DSLAM 进行 ATM 封装所需的填充字节数（即 AAL5 的 PAD 字段长度），从而推断出报文经过 DSLAM 封装后的总长度，配置补充值时无需考虑 AAL5 的 PAD 开销和 ATM 信元首部开销。





作为参考，下文给出了常见报文封装开销及几种典型场景下需要配置的补偿值。




表4-1 报文封装开销

封装类型		封装开销（字节）
PPP 首部		2
Eth 首部		14
VLAN 首部		4
QinQ 首部		8
AAL5 封装	VC 方式	AAL5 Header + AAL5 tail = 0 + 8 = 8
	LLC Type1（无连接模式，如 IPoE、PPPoE、IPoA、PPPoA、IPoEoA 和 PPPoEoA）	AAL5 Header + AAL5 tail = 8 + 8 = 16
	LLC Type2（连接模式，如 PPPoA）	AAL5 Header + AAL5 tail = 4 + 8 = 12

表4-2 最后一公里 QoS 常用调整字节表

场景	配置补偿值(字节)
----	-----------

场景	配置补偿值(字节)
 PPPoEoA CPE ATM DSLAM BRAS /SR IP payload IP header PPP header PPPoE header Eth header AAL5 tail PAD IP payload IP header PPP header PPPoE header Eth header AAL5 header	- 对于 LLC 封装: $\text{AAL5 Header} + \text{AAL5 tail}$ $= 8 + 8$ $= 16$ - 对于 VC 封装: $= 0 + 8$ $= 8$
 PPPoA CPE ATM DSLAM BRAS /SR IP payload IP header PPP header PPPoE header VLAN header Eth header AAL5 tail PAD IP payload IP header PPP header AAL5 header	- 对于 LLC 封装: $= \text{AAL5 header} + \text{AAL5 tail}$ $- \text{PPPoE header} - \text{VLAN header} - \text{Eth header}$ $= 4 + 8 - 6 - 4 - 14$ $= -12$ - 对于 VC 封装: $= 0 + 8 - 6 - 4 - 14$ $= -16$
 IPoEoA CPE ATM DSLAM BRAS /SR IP payload IP header PPP header PPPoE header Eth header AAL5 tail PAD IP payload IP header Eth header AAL5 header	- 对于 LLC 封装: $= \text{AAL5 header} + \text{AAL5 tail}$ $- \text{PPP header} - \text{PPPoE header}$ $= 8 + 8 - 2 - 6$ $= 8$ - 对于 VC 封装: $= 0 + 8 - 2 - 6$ $= 0$
 IPoA CPE ATM DSLAM BRAS /SR IP payload IP header PPP header PPPoE header Eth header AAL5 tail PAD IP payload IP header AAL5 header	- 对于 LLC 封装: $= \text{AAL5 header} + \text{AAL5 tail}$ $- \text{PPP header} - \text{PPPoE header} - \text{Eth header}$ $= 8 + 8 - 2 - 6 - 14$ $= -6$ - 对于 VC 封装: $= 0 + 8 - 2 - 6 - 14$ $= -14$

场景	配置补偿值(字节)
	- 对于 LLC 封装: $\text{= AAL5 header + AAL tail - QinQ header - Eth header}$ $\text{= } 8 + 8 - 8 - 14$ $\text{= } -6$ - 对于 VC 封装: $\text{= } 0 + 8 - 8 - 14$ $\text{= } -14$
	$\text{= VLAN header - QinQ header}$ $\text{= } -4$
	$\text{= } 0 - \text{QinQ header}$ $\text{= } -8$

4.3 流量监管和流量整形的比较

相同点

流量监管和流量整形的相同点主要有：

- 作用都是监控网络流量。
- 都是用令牌桶算法评估流量速率。
- 主要都用于网络边缘。

差异点

流量监管	流量整形
丢弃超额流量或将超额流量重标记为低优先级	缓存超出策略/协定 SLA 规定的超额流量
不需要额外的内存资源，不会带来延迟	需要内存去缓存超额流量，可能会带来

流量监管	流量整形
和抖动	延迟和抖动
丢包可能引发重传	较少的丢包，因而较少导致重传
可以重标记流	不能重标记

4.4 单板实现差异

4.4.1 流量监管和整形的单板实现差异

CAR 的实现差异

差异项	单板类型	差异描述
基于 CAR 令牌桶测量结果的流行为	Type-B	- 如果测量结果为 green，则支持对报文执行 pass 动作，不支持 discard 和重标记。 - 如果测量结果为 yellow，则支持对报文执行 pass 和重标记，不支持 discard。 - 如果测量结果为 red，则支持对报文执行 pass、discard 和重标记。 支持的命令行格式： <pre>qos car { cir cir-value [pir pir-value] [cbs cbs-value pbs pbs-value] [green pass } yellow pass [service-class class color color] red { discard pass [service-class class color color] } }</pre>
	Type-C	- 如果测量结果为 green，则支持对报文执行 pass 和重标记，不支持 discard。 - 如果测量结果为 yellow 或者 red，则支持对报文执行 pass、discard 和重标记。 支持的命令行格式： <pre>qos car { cir cir-value [pir pir-value] [cbs cbs-value pbs pbs-value] [green pass [service-class class color color] yellow { discard pass [service-class class color color] } red { discard pass [service-class class color color] } }</pre>
	Type-A	上行不论测量结果是 green、yellow 还是 red，都支持对报文执行 pass、discard 和重标记。 上行支持的命令行格式： <pre>qos car { cir cir-value [pir pir-value] [cbs cbs-value pbs pbs-value] [green { discard pass [service-class class color color] } yellow { discard pass [service-class class color color] } red { discard pass [service-class class color color] } }</pre>

差异项	单板类型	差异描述
		class class color color] }] • 下行不论测量结果是 green、yellow 还是 red，支持对报文执行 pass 和 discard ，不支持重标记。 下行支持的命令行格式： qos car { cir cir-value [pir pir-value] [cbs cbs-value pbs pbs-value] [green { discard pass } yellow { discard pass } red { discard pass }] }
	Type-D	不论测量结果是 green、yellow 还是 red，都持对报文执行 pass 、 discard 和重标记。 支持的命令行格式： qos car { cir cir-value [pir pir-value] [cbs cbs-value pbs pbs-value] [green { discard pass [service-class class color color] } yellow { discard pass [service-class class color color] } red { discard pass [service-class class color color] }] }
二层流量限速	Type-B	只支持入方向流量。
	Type-C	支持入方向和出方向流量。
	Type-A	
	Type-D	
对同一个接口入方向配置 CAR 和 HQoS 模板 CAR	Type-B	不支持。
	Type-C	支持。
	Type-A	
	Type-D	
对同一接口同时配置基于接口的 CAR 和基于流的 CAR	Type-B	基于流的 CAR 只对匹配复杂流分类的流量生效。
	Type-C	基于接口的 CAR 对不匹配复杂流分类的流量生效。
	Type-A	基于流的 CAR 只对匹配复杂流分类的流量生效。
	Type-D	基于接口的 CAR 对所有流量生效。
CAR 模式	Type-B	只支持色盲模式。
	Type-C	支持色盲和色敏。
	Type-A	
	Type-D	

流量整形的实现差异

请参见 5.6 单板实现差异。

4.5 流量监管和整形支持列表

表4-3 流量监管和整形支持列表

下表中，“Y”表示支持；“N”表示不支持。

粒度大类	粒度子类		CAR		流量整形		备注
			入方向	出方向	入方向	出方向	
基于接口	三层主接口	包括 GE、POS、IP-Trunk 和 Eth-Trunk 类型	Y	N	Y	Y	-
基于接口	VE 接口	包括二/三层 Virtual-Ethernet 类型	N	N	N	N	-
基于接口	二层接口	包括 GE 和 Eth-Trunk 类型	Y	Y	Y	Y	二层接口不支持 user-queue 命令。
基于接口	VLANIF 接口	VLANIF 接口类型	N	N	N	N	VLANIF 的成员接口支持 CAR 和整形。
基于接口	Dot1Q 子接口	包括 GE、Eth-Trunk 类型	Y	Y	Y	Y	-
基于接口	Dot1Q 终结子接口	包括 GE、Eth-Trunk 类型	Y	Y	Y	Y	-
基于接口	QinQ 终结子接口	包括 GE、Eth-Trunk 类型	Y	Y	Y	Y	-
基于接口	QinQ/Dot1Q 终结主接口	包括 GE、Eth-Trunk 类型	Y	Y	Y	Y	Type-B 单板，主接口的配置对子接口流量也生效。
基于流	二层以太网帧头信息	以太网类型/长度域	Y	Y	Y	N	-
基于流	二层以太网	外层 802.1p	Y	Y	Y	N	• Type-A 支持入

粒度大类	粒度子类		CAR		流量整形		备注
			入方向	出方向	入方向	出方向	
	帧头信息						方向； • Type-B 只支持出方向； • 其他类型单板支持入、出方向。
基于流	二层以太帧头信息	内层 802.1p	Y	Y	Y	N	• Type-A 和 Type-B 类型单板不支持。 • Type-C 类型单板只支持出方向； • 其他类型单板支持入、出方向。
基于流	二层以太帧头信息	目的 MAC	Y	Y	Y	N	-
基于流	二层以太帧头信息	源 MAC	Y	Y	Y	N	-
基于流	MPLS 头信息	最外层标签的 EXP 字段	Y	N	Y	N	Type-B 类型单板不支持。
基于流	MPLS 头信息	第 2 层标签的 EXP 字段	Y	N	Y	N	• Type-A 和 Type-B 类型单板不支持。 • Type-C 类型单
基于流	MPLS 头信息	第 3 层标签的 EXP 字段	Y	N	Y	N	
基于流	MPLS 头信息	第 4 层标签的 EXP 字段	Y	N	Y	N	

粒度大类	粒度子类		CAR		流量整形		备注
			入方向	出方向	入方向	出方向	
基于流	MPLS 头信息	最外层标签值	Y	N	Y	N	板只支持出方向。 • 其他类型单板支持入、出方向。
基于流	MPLS 头信息	第 2 层标签值	Y	N	Y	N	
基于流	MPLS 头信息	第 3 层标签值	Y	N	Y	N	
基于流	MPLS 头信息	第 4 层标签值	Y	N	Y	N	-
基于流	MPLS 头信息	最外层标签的 TTL 字段	Y	N	Y	N	-
基于流	MPLS 头信息	第 2 层标签的 TTL 字段	Y	N	Y	N	-
基于流	MPLS 头信息	第 3 层标签的 TTL 字段	Y	N	Y	N	-
基于流	MPLS 头信息	第 3 层标签的 TTL 字段	N	N	N	N	-
基于流	IP 头信息	DSCP	Y	Y	Y	N	-
基于流	IP 头信息	IP Precedence	Y	Y	Y	N	-
基于流	IP 头信息	ToS	Y	Y	Y	N	-
基于流	IP 头信息	协议号	Y	Y	Y	N	-
基于流	IP 头信息	所有 IPv4 信息	Y	Y	Y	N	-
基于流	IP 头信息	分片类型	Y	Y	Y	N	-
基于流	IP 头信息	源 IP 地址	Y	Y	Y	N	-
基于流	IP 头信息	目的 IP 地址	Y	Y	Y	N	-
基于流	IP 头信息	TCP 标记	Y	Y	Y	N	-
基于流	IP 头信息	TCP/UDP 源端口	Y	Y	Y	N	-
基于流	IP 头信息	TCP/UDP 目的端口	Y	Y	Y	N	-
基于流	IP 头信息	ICMP 类型	Y	Y	Y	N	-

粒度大类	粒度子类		CAR		流量整形		备注
			入方向	出方向	入方向	出方向	
基于流	IP 头信息	Time-range	Y	Y	Y	N	-
基于流	IPv6 头信息	DSCP (TC 字段的高 6 位)	Y	Y	Y	N	Type-B 类型单板只支持入方向。
基于流	IPv6 头信息	Precedence (TC 字段的高 3 位)	Y	Y	Y	N	
基于流	IPv6 头信息	ToS (TC 字段的高位第 4 - 7 位)	Y	Y	Y	N	
基于流	IPv6 头信息	协议号	Y	Y	Y	N	
基于流	IPv6 头信息	源 IPv6 地址	Y	Y	Y	N	Type-A 和 Type-B 类型单板只支持匹配 96bit 的源 IP 地址。假设 IPv6 的 IP 地址为 0~127, 这 96bit 是由 0~31 + 64~127 组成的。 Type-B 类型单板只支持上行 (入方向) CAR。
基于流	IPv6 头信息	目的 IPv6 地址	Y	Y	Y	N	Type-B 类型单板只支持上行 (入方向) CAR。
基于流	IPv6 头信息	分片	Y	Y	Y	N	
基于流	IPv6 头信息	ICMPv6 类型	Y	Y	Y	N	
基于流	IPv6 头信息	time-range	Y	Y	Y	N	

粒度大类	粒度子类		CAR		流量整形		备注
			入方向	出方向	入方向	出方向	
基于流	IPv6 头信息	next-header 字段	Y	Y	Y	N	
基于流	IPv6 头信息	所有 IPv6 头信息	Y	Y	Y	N	
基于用户	UCL		Y	Y	Y	Y	• 只在 V600R002 及后续单板支持。 • Type-B 类型单板只支持入方向。 • 其他类型单板支持入、出方向。
基于用户	基于 PPPoE/IPoE 用户		Y	Y	Y	Y	只在 V600R002 及后续单板支持。
基于用户	基于家庭用户		Y	Y	Y	Y	
基于用户	基于专线用户		Y	Y	Y	Y	
基于 MPLS L3VPN	基于 VPN 实例		N	N	Y	Y	-
基于 MPLS L3VPN	基于 BGP 对等体		N	N	Y	Y	-
基于 VPLS	基于 VSI		N	N	Y	Y	-
基于 VPLS	基于 VPLS 对等体		N	N	Y	Y	-
基于 VLL/PWE 3	基于 VC		N	N	Y	Y	-
基于队列	基于 CQ（端口队列）		N	N	N	Y	-
基于队列	基于 FQ（流队列）		N	N	Y	Y	-

粒度大类	粒度子类	CAR		流量整形		备注
		入方向	出方向	入方向	出方向	
基于队列	多个 FQ 联合整形	N	N	Y	Y	只在 V600R002 及后续单板支持。
基于队列	基于 SQ（用户队列）	N	N	Y	Y	-
基于队列	基于 GQ（用户组队列）	N	N	Y	Y	-
基于队列	基于 VI（父 GQ 队列）	N	N	N	Y	• 只在 V600R007 及后续单板支持。 • 只在 eTM 子卡支持。

4.6 流量监管和整形常见问题解答

4.6.1 流量监管和整形分别在什么情况下执行？

问题

流量监管 CAR 在什么情况下执行？整形什么情况下执行？

解答

流量监管通常采用 CAR 技术；**port shaping** 或者 **port-queue shaping** 命令行是用于流量整形。

对于上行，CAR 是在流量整形之前执行，且是入队列之前执行。而流量整形是在报文在队列中，正要离开队列的时候执行。

对于下行，如果出接口板没有 eTM 子卡，则 CAR 是在整形之后执行；流量整形是在报文正在离要队列的时候执行，而 CAR 是在报文已经离开了队列之后执行。

对于下行，如果出接口有 eTM 子卡，CAR 是在整形之前执行，且是入队列之前执行；而整形则是在报文入队列之后，正要离开队列的时候执行。

详细信息请参见 8 路由器 QoS 转发全流程。

4.6.2 基于端口和基于流的流量整形有什么区别？

问题

基于端口的流量整形和基于流的流量整形有什么区别？通常推荐采用哪个？为什么？

解答

基于端口的流量整形和基于流的流量整形都是使用令牌桶技术测量流量，以便确定流量是否符合 QoS 要求，且两者都使用队列缓存，当网络拥塞时都会引入时延。

两者不同在于：

- 基于端口的流量整形用于限制一个端口发送的所有报文的整体速率。基于端口的整形对整个出接口的流量生效，不论报文的优先级是多少。
- 基于流的流量整形用于一个队列的报文输出速率。

如果要限制一个端口的带宽，则推荐使用基于端口的流量整形；如果要限制一个队列的带宽，或限制某个优先级的流量的带宽，则推荐使用基于流的整形。

例如，如果要限制 GE1/0/0 的带宽，则在 GE1/0/0 接口下配置 **port shaping** 命令；如果要限制 GE1/0/0 接口下的 EF 流量的带宽，则在 GE1/0/0 接口下配置 **port-queue ef shaping** 命令。

4.6.3 流量整形是否会影响设备的其他功能？

问题

如果配置了基于端口的流量整形，或者基于队列的流量整形，是否影响设备其他功能？

解答

不会。因为队列缓存都是专门预留的，和设备本身的控制/管理等信号流量隔离。

4.6.4 使用流量整形，最大时延是多少？

问题

当流量拥塞时，流量整形会增加时延。那么，最大时延可能达到多少？

解答

时延的大小取决于队列的缓存大小和队列的输出带宽。

计算公式为：

队列时延 = (队列缓存字节数 × 8) / 队列整形速率

所以，当队列满时，时延达到最大值。

详细信息请参见 5.4 队列缓存对时延和抖动的影响。

4.6.5 队列缓存的缺省长度是多少？

问题

队列缓存长度的缺省值是多少？

解答

本文档涉及的华为路由器，队列缓存的缺省长度取决于接口板的类型及其物理接口卡 PIC（Physical Interface Cards）的类型。

4.6.6 如果出接口不配置流量监管和整形，其缺省行为是什么？

问题

如果出接口不配置流量监管和整形，其缺省行为是什么？

解答

如果出接口不配置流量监管和整形，且 HQoS 也没有配置的情况下：

- 缺省情况下，下行单板有 8 个端口队列（CQ 队列），分别是 BE、AF1、AF2、AF3、AF4、EF、CS6 和 CS7，且没有流队列 FQ（Flow Queue）。当流量拥塞时，流量被缓存到 CQ 队列中。
- 缺省情况下，不同接口板不同物理接口卡 PIC（Physical Interface Cards），其缓存队列的缺省长度不同。
- 八个 CQ 队列的缺省调度顺序请参见[三种队列的调度顺序](#)。缺省情况下，CS7、CS6 和 EF 是 PQ 队列，AF4、AF3AF2AF1 和 BE 为 WFQ 队列，WFQ 队列的权重为 10:10:10:15:15。
- 缺省情况下，8 个 CQ 队列的丢弃策略为尾丢弃。CQ 队列缓存满了之后，新到的报文将被丢弃。
- 缺省情况下，不对 8 个 CQ 队列执行基于队列的流量整形，出接口也不执行基于端口的流量整形。队列的输出带宽因不受限制，可能达到接口物理带宽。同理，一个接口的输出报文的带宽因不受限制，其带宽可能达到接口物理带宽。

5 拥塞管理和避免

关于本章


- 5.1 网络拥塞及其对策
- 5.2 队列及拥塞管理
- 5.3 拥塞避免
- 5.4 队列缓存对时延和抖动的影响
- 5.5 HQoS
- 5.6 单板实现差异

5.1 网络拥塞及其对策

拥塞的产生

拥塞是在共享网络上多个用户竞争相同的资源（带宽、缓冲区等）时发生的问题。例如，由于广域网的带宽通常要比局域网的带宽小，当一个局域网的用户向另一个局域网的用户发送数据时，由于广域网的带宽小于局域网的带宽，数据将不可能按局域网发送的速度在广域网上传输。此时，处在局域网和广域网之间的路由器将发生拥塞，如图 5-1 所示。


图5-1 网络拥塞



拥塞经常发生于图 5-2 所示的情况：

- 速率不匹配：分组从高速链路进入设备，再由低速链路转发出去。
- 汇聚问题：分组从多个接口同时进入设备，由一个没有足够带宽的接口转发出去。

图5-2 链路带宽瓶颈




不仅仅是链路带宽的瓶颈会导致拥塞，任何用于正常转发处理的资源的不足（如可分配的处理器时间、缓冲区、内存资源的不足）都会造成拥塞。此外，在某个时间内对所到达的流量控制不力，使之超出了可分配的网络资源，也是引发网络拥塞的一个因素。

拥塞的位置

如图 5-3，根据设备所处网络位置及报文的收发方向，可以一台设备的报文转发途径划分为：

- 接入侧上行
- 接入侧下行
- 网络侧上行
- 网络侧下行

图5-3 上下行方向图



一般情况下，上行方向不会发生拥塞，因为上行方向还未涉及到速率不匹配、汇聚问题，也不涉及转发处理的资源。拥塞一般发生在下行方向。

拥塞的影响

拥塞有可能会引发一系列的负面影响：

- 拥塞增加了报文传输的延迟和延迟抖动。
- 过高的延迟会引起报文重传。
- 拥塞使网络的有效吞吐率降低，造成网络资源的损害。
- 拥塞加剧会耗费大量的网络资源（特别是存储资源），不合理的资源分配甚至可能导致系统陷入资源死锁而崩溃。

可见，拥塞使流量不能及时获得资源，是造成服务性能下降的源头。然而在分组交换以及多用户业务并存的复杂环境下，拥塞又是常见的。因此采取有效的避免拥塞以及防止拥塞加剧的方法是必需的。

拥塞的管理和对策

任何一个实用的电信网都需要解决网络拥塞的管理问题，也就是解决有限的网络资源与用户需求间的矛盾，在满足用户对服务质量要求的前提下尽可能地充分利用网络资源。

通常用如下两种策略来缓解网络拥塞：

- 拥塞管理：指网络在发生拥塞时，如何进行管理和控制。处理的方法是使用队列技术，将从一个接口发出的所有报文放入多个队列，按照各个队列的优先级进行处理。不同的队列调度算法用来解决不同的问题，并产生不同的效果。
- 拥塞避免：通过监视网络资源（如队列或内存缓冲区）的使用情况，在拥塞有加剧的趋势时，主动丢弃报文，通过调整网络的流量来解除网络过载的一种流量控制机制。拥塞避免用于防止因为线路拥塞而使设备的队列溢出。

5.2 队列及拥塞管理

拥塞管理的中心内容是当拥塞发生时如何制定一个策略，用于决定报文转发的处理次序和丢弃原则，一般采用队列技术。

队列指的是在缓存中对报文进行排序的逻辑。当流量的速率超过接口带宽或超过为该流量设置的带宽时，报文就以队列的形式暂存在缓存中。报文离开队列的时间、顺序，以及各个队列之间报文离开的相互关系则由队列调度算法决定。

说明

路由器转发平面的流量管理器 TM（Traffic Manager）上有一些高速缓存，用于报文的缓冲和转发，缓存由所有端口共享，各端口竞争使用。为了避免有的端口长时间抢不到缓存而出现断流，路由器给每个端口分配了一块最小可用缓存，并且分配到端口的各个队列上，保证每个队列均有缓存可用。

当 TM 收到报文时，将报文放入缓存，网络不拥塞时，报文能被及时转发，不会在缓存中产生堆积。这种情况下报文在缓存中的时间为 μs 级，延迟时间可以忽略不计。


当网络拥塞时，报文在缓存中产生堆积，被延迟处理，延迟时间会大幅增加。延迟时间的大小主要取决于队列的缓存长度以及该队列获得的输出带宽，可以使用如下公式计算时延：

队列时延 = 队列缓存长度 / 队列输出带宽

华为路由器设备的每个端口上都有 8 个下行队列，称为 CQ（Class Queue）队列，也叫端口队列（Port-queue），分别为 BE、AF1、AF2、AF3、AF4、EF、CS6 和 CS7。

单个队列的报文采用 FIFO（First In First Out）原则入队和出队。

图5-4 报文入队出队方式



队列调度算法

本文介绍几种常见队列调度算法：

- 先进先出 FIFO（First In First Out）
- 严格优先级 SP（Strict Priority）

- 轮询 RR (Round Robin)
- 加权轮询 WRR (Weighted Round Robin)
- 差分轮询 DRR (Deficit Round Robin)
- 差分加权轮询 DWRR (Deficit Weighted Round Robin)
- 加权公平队列 WFQ (Weighted Fair Queuing)

FIFO

FIFO 不对报文进行分类。FIFO 按报文到达接口的先后顺序让报文进入队列，在队列的出口让报文按进队的顺序出队，先进的报文将先出队，后进的报文将后出队，如图 5-4。

SP

SP (Strict Priority) 调度就是严格按照队列优先级的高低顺序进行调度。只有高优先级队列中的报文全部调度完毕后，低优先级队列才有调度机会。

假设端口有 3 个采用 SP 调度算法的队列，分别为高优先 (High) 队列、中优先 (Medium) 队列、和低优先 (Low) 队列，它们的优先级依次降低。如图 5-5，其中报文编号表示报文到达顺序。

图5-5 SP 调度



在报文出队的时候，首先让高优先队列中的报文出队并发送，直到高优先队列中的报文发送完，然后发送中优先队列中的报文，直到发送完，接着是低优先队列。在调度低优先级队列时，如果高优先级队列又有报文到来，则会优先调度高优先级队列。这样，较高优先级队列的报文将会得到优先发送，而较低优先级的报文后发送。

SP 调度的缺点是：拥塞发生时，如果较高优先级队列中长时间有报文存在，那么低优先级队列中的报文就会由于得不到服务而“饿死”。

RR

RR 调度采用轮询的方式，对多个队列进行调度。RR 以环形的方式轮询多个队列。如果轮询的队列不为空，则从该队列取走一个报文；如果该队列为空，则直接跳过该队列，调度器不等待。

图5-6 RR 调度




WRR

加权轮询 WRR (Weighted Round Robin) 调度主要解决 RR 不能设置权重的不足。在轮询的时候，WRR 每个队列享受的调度机会和该队列的权重成比例。RR 调度相当于权重为 1 的 WRR 调度。

WRR 的实现方法是为每个队列设置一个计数器 Count，根据权重进行初始化。每次轮询到一个队列时，该队列输出一个报文且计数器减一。当计数器为 0 时停止调度该队列，但继续调度其他计数器不为 0 的队列。当所有队列的计数器都为 0 时，所有计数器重新根据权重初始化，开始新一轮调度。在一个循环中，权重大的队列被多次调度。

图5-7 WRR 调度



假设某端口有 3 个队列采用 WRR 调度，为每个队列配置一个权值，依次为 50%、25%、25%，详细的调度过程如下：

首先计数器初始化：Count[1]=2，Count[2]=1，Count[3]= 1。

- 第 1 个轮询：
从队列 1 取出报文 1 发送，Count[1]=1；从队列 2 取出报文 5 发送，Count[2]=0；
从队列 3 取出报文 8 发送，Count[3]=0。
- 第 2 个轮询：
从队列 1 取出报文 2 发送，Count[1]=0；由于 Count[2]=0，Count[3]=0，队列 2 和队列 3 不参与此轮调度。
此时，Count[1]=0，Count[2]=0，Count[3]=0，将计数器重新初始化：Count[1]=2，Count[2]=1，Count[3]= 1。
- 第 3 个轮询：
从队列 1 取出报文 3 发送，Count[1]=1；从队列 2 取出报文 6 发送，Count[2]=0；
从队列 3 取出报文 9 发送，Count[3]=0。

- 第 4 个轮询：

从队列 1 取出报文 4 发送，Count[1]=0；由于 Count[2]=0，Count[3]=0，队列 2 和队列 3 不参与此轮调度。

此时，Count[1]=0，Count[2]=0，Count[3]=0，将计数器重新初始化：Count[1]=2，Count[2]=1，Count[3]=1。

从统计上看，各队列中的报文流被调度的次数与该队列的权值成正比，权值越大被调度的次数相对越多。如果该端口为 100Mbps，则可以保证最低权重的队列至少获得 25Mbps 带宽，避免了采用 SP 调度时低优先级队列中的报文可能长时间得不到服务的缺点。

WRR 对于空的队列直接跳过，循环调度的周期变短，因此当某个队列流量小的时候，剩余带宽能够被其他队列按照比例占用。

WRR 调度有两个缺点：

- WRR 调度按照报文个数进行调度，因此每个队列没有固定的带宽，同等调度机会下大尺寸报文获得的实际带宽要大于小尺寸报文获得的带宽。而用户一般关心的是带宽。当每个队列的平均报文长度相等或已知时，通过配置 WRR 权重，用户能够获得想要的带宽；但是，当队列的平均报文长度变化时，用户就不能通过配置 WRR 权重获取想要的带宽。
- 低延时需求业务（如语音）得不到及时调度。

DRR


差分轮询 DRR（Deficit Round Robin）调度实现原理与 RR 调度基本相同。

DRR 与 RR 的区别是：RR 调度是按照报文个数进行调度，而 DRR 是按照报文长度进行调度。

DRR 为每个队列设置一个计数器 Deficit，Deficit 初始化为一次调度允许的最大字节数，一般为接口 MTU。每次轮询到一个队列时，该队列输出一个报文且计数器 Deficit 减去报文长度。如果报文长度超过了队列的调度能力，DRR 调度允许 Deficit 出现负值，以保证长报文也能够得到调度。但下次轮循调度时该队列将不会被调度。当计数器为 0 或负数时停止调度该队列，但继续调度其他计数器为正数的队列。当所有队列的 Deficit 都为 0 或负数时，将所有队列的 Deficit 计数器加上初始值，开始新一轮调度。

假设某端口 MTU=150Bytes，有 2 个队列 Q1 和 Q2 采用 DRR 调度，Q1 队列中有多个 200Bytes 的长报文，Q2 队列中有多个 100Bytes 的端报文，则调度过程如图 5-8。

图5-8 DRR 调度



由上图可以看出, 经过第 1~6 轮 DRR 调度, Q1 队列被调出了 3 个 200Bytes 的报文, Q2 队列被调出了 6 个 100Bytes 的报文。从长期的统计看, Q1 和 Q2 的实际输出带宽比是 1:1, 为公平的比例。

DRR 调度避免了采用 SP 调度时低优先级队列中的报文可能长时间得不到服务的缺点。但是, DRR 调度不能设置权重, 且也具有低延时需求业务 (如语音) 得不到及时调度的缺点。


DWRR

差分加权轮询 DWRR (Deficit Weighted Round Robin) 调度主要解决 DRR 不能设置权重的不足。DRR 调度相当于权值为 1 的 DWRR 调度。

DWRR 为每个队列设置一个计数器 Deficit, Deficit 初始化为 $\text{Weight} \times \text{MTU}$ 。每次轮询到一个队列时, 该队列输出一个报文且计数器 Deficit 减去报文长度。当计数器为 0 时停止调度该队列, 但继续调度其他计数器不为 0 的队列。当所有队列的计数器都为 0 时, 所有计数器的 Deficit 都加上 $\text{Weight} \times \text{MTU}$, 开始新一轮调度。

假设某端口 MTU=150Bytes, 有 2 个队列 Q1 和 Q2 采用 DRR 调度, Q1 队列中有多个 200Bytes 的长报文, Q2 队列中有多个 100Bytes 的端报文, Q1 和 Q2 配置权重比为 $\text{weight1}:\text{weight2}=2:1$ 。则 DWRR 调度过程如图 5-9。

图5-9 DWRR 调度



- 第一次调度

$\text{Deficit}[1] = \text{weight1} * \text{MTU} = 300$, $\text{Deficit}[2] = \text{weight2} * \text{MTU} = 150$, 从 Q1 队列取出 200Bytes 报文发送, 从 Q2 队列取出 100Bytes 发送; 发送后, $\text{Deficit}[1] = 100$, $\text{Deficit}[2] = 50$ 。

- 第二次调度

从 Q1 队列取出 200Bytes 报文发送, 从 Q2 队列取出 100Bytes 发送; 发送后, $\text{Deficit}[1] = -100$, $\text{Deficit}[2] = -50$ 。

- 第三次调度

此时两个队列都为负, 因此, $\text{Deficit}[1] = \text{Deficit}[1] + \text{weight1} * \text{MTU} = -100 + 2 * 150 = 200$, $\text{Deficit}[2] = \text{Deficit}[2] + \text{weight2} * \text{MTU} = -50 + 1 * 150 = 100$ 。

从 Q1 队列取出 200Bytes 报文发送, 从 Q2 队列取出 100Bytes 发送; 发送后, $\text{Deficit}[1] = 0$, $\text{Deficit}[2] = 0$ 。

由上图可以看出, 经过第 1~3 轮 DWRR 调度, Q1 队列被调出了 3 个 200Bytes 的报文, Q2 队列被调出了 3 个 100Bytes 的报文。从长期的统计看, Q1 和 Q2 的实际输出带宽比是 2:1, 与权重比相符。

DWRR 调度避免了采用 SP 调度时低优先级队列中的报文可能长时间得不到服务的缺点, 也避免了各队列报文长度不等或变化较大时, WRR 调度不能按配置比例分配带宽资源的缺点。

但是, DWRR 调度也具有低延时需求业务 (如语音) 得不到及时调度的缺点。

WFQ

加权公平队列 WFQ (Weighted Fair Queuing) 调度是按队列权重来分配每个流应占有出口的带宽。同时, 为了使得带宽分配更加“公平”, WFQ 以 bit 为单位进行调度, 类似于图 5-10 的 bit-by-bit 调度模型。

图5-10 Bit-by-bit 调度模型



Bit-by-bit 调度模型可以完全按照权重分配带宽，防止长报文比短报文获得更多带宽，从而减少大小报文共存时的时延抖动。

但 Bit-by-bit 调度模型只是理想化的模型，实际上，华为路由器实现的 WFQ 是按照一定的粒度，例如 256B、1KB，或其他粒度，具体按何种粒度，与单板类型相关。

WFQ 的优点：

- 不同的队列获得公平的调度机会，从总体上均衡各个流的延迟。
- 短报文和长报文获得公平的调度：如果不同队列间同时存在多个长报文和短报文等待发送，让短报文优先获得调度，从而在总体上减少各个流的报文间的抖动。
- 从统计上看，权重越小，所分得的带宽越少。权重越大，所分得的带宽越多。

端口队列调度方式

对于华为路由器设备每个接口上的 8 个端口队列，用户可以为都配置成 SP 调度，或者是基于权重的调度。根据队列调度算法，8 个端口队列可以分为三组：

- PQ 队列

PQ 队列之间采用 SP 调度算法，当从队列调度报文时，先从高优先级的队列调度报文。这样，可对不同业务数据提供绝对的优先，对时间敏感的实施应用如 VoIP 的延时可以得到保证，对优先业务的报文带宽占用可以绝对优先。

PQ 的缺点：如果不对高优先级的报文带宽加限制，会造成低优先级报文得不到带宽，可能出现“饿死”现象。

华为路由器允许将 8 个端口队列都配置成 PQ 队列，但不建议这么配置。通常情况下，只时延敏感的业务入 PQ 队列。

- WFQ 队列

WFQ 队列是按权重进行调度的，调度算法可以是 WRR、DWRR 或 WFQ 调度算法中的其中一种，这些算法都是按权重进行剩余带宽的分配。P40-E 子卡使用的是 DWRR；其他类型单板使用 WFQ 或 WRR。

- LPQ 队列

LPQ 队列是在高速链路（以太网）接口上实现的队列调度机制。低速链路（如 Serial、MP-Group）上不支持 LPQ 队列。

LPQ 队列之间的调度方式与 PQ 队列一样，也采用 SP 调度。不同在于拥塞时 PQ 可以抢占 WFQ 的带宽，而 LPQ 不可以抢占 WFQ 的带宽。在 PQ 和 WFQ 队列调度结束后，如果还有剩余带宽则分配给 LPQ。

实际应用中，可以将 BE 流用 LPQ 进行调度。这样，在网络负载较重时，BE 流可以完全被限制，优先满足其它业务。

所有的 8 个端口队列可以全部配置成 WFQ，也可以全部配置成 PQ，也可以全部配置成 LPQ，也可以组合。

三种队列的调度顺序

PQ、WFQ、LPQ 之间采用 SP 调度算法，优先调度 PQ 队列，再调度 WFQ 队列，最后调度 LPQ 队列，如图 5-11。详细流程如图 5-12。

图5-11 端口队列调度顺序





图5-12 队列间的调度流程



- 在调度出队的时候，若 PQ 队列中有报文，则总是优先发送 PQ 队列中的报文，直到 PQ 队列中没有报文时才调度发送 WFQ 队列中的报文。只要 PQ 队列中有报文，系统就会优先发送 PQ 队列中的报文。

- 若 PQ 队列中没有报文时，则调度 WFQ 队列。如果在调度 WFQ 队列过程中，PQ 队列又有报文到来，则会优先调度 PQ 队列。
- 直到 WFQ 中的报文被发送完毕，才调度 LPQ 队列中的报文。

上述调度的结果是：首先保证 PQ 队列的 PIR 带宽，剩余带宽在各 WFQ 队列间按权重分配；如果某些队列没有用完带宽（即已满足 PIR 带宽且还有剩余），则剩余带宽在未满足 PIR 的队列之间按权重分配；如果还有剩余带宽再在未满足 PIR 的队列间分配……如此反复，直到满足所有 WFQ 队列的 PIR 带宽；如果此时还有剩余带宽，则分配给 LPQ。



说明

这里的 PIR 是指使用 port-queue 命令配置的整形速率。

队列带宽分配示例 1

假设某端口整形速率为 100Mbps（缺省情况下，接口的整形速率是接口带宽），该接口各业务的输入带宽及配置的 PIR 如下。

队列类型	队列类型	输入带宽(bps)	PIR(bps)
CS7	PQ	65M	55M
CS6	PQ	30M	30M
EF	WFQ, 权重 5	10M	5M
AF4	WFQ, 权重 4	10M	10M
AF3	WFQ, 权重 3	10M	15M
AF2	WFQ, 权重 2	20M	25M
AF1	WFQ, 权重 1	20M	20M
BE	LPQ	100M	未配置

则带宽分配过程如下：

- 首先进行 PQ 调度。100Mbps 先供 CS7 使用，CS7 输出带宽 = $\text{Min}(\text{端口整形速率}, \text{CS7 输入带宽}, \text{CS7 的 PIR 带宽}) = \text{Min}(100\text{M}, 65\text{M}, 55\text{M}) = 55\text{M}$ ，剩余 45Mbps 供 CS6 使用，CS6 输出带宽 = $\text{Min}(\text{剩余带宽}, \text{CS6 输入带宽}, \text{CS6 的 PIR 带宽}) = \text{Min}(45\text{Mbps}, 30\text{Mbps}, 30\text{Mbps}) = 30\text{Mbps}$ 。PQ 调度后，剩余带宽 = $100\text{Mbps} - 55\text{Mbps} - 30\text{Mbps} = 15\text{Mbps}$ 。
- 接着进行第一轮 WFQ 调度，剩余带宽在各 WFQ 队列中按权重分配。计算公式：
分给某 WFQ 队列的带宽 = $\text{剩余带宽} \times \text{本队列权重} / \text{所有 WFQ 队列权重之和}$
= $15\text{Mbps} \times \text{本队列权重} / 15$ ，因此，
 - 本轮分配给 EF 的带宽 = $15\text{Mbps} \times 5 / 15 = 5\text{Mbps} = \text{PIR}$ ，分配给 EF 的带宽没有剩余
 - 本轮分配给 AF4 的带宽 = $15\text{Mbps} \times 4 / 15 = 4\text{Mbps} < \text{PIR}$ ，分配给 AF4 的带宽没有剩余

- 本轮分配给 AF3 的带宽=15Mbps*3/15=3Mbps <PIR，分配给 AF3 的带宽没有剩余
- 本轮分配给 AF2 的带宽=15Mbps*2/15=2Mbps <PIR，分配给 AF2 的带宽没有剩余
- 本轮分配给 AF1 的带宽=15Mbps*1/15=1Mbps <PIR，分配给 AF1 的带宽没有剩余
- 此时剩余带宽为 0，BE 流量没有获得调度，输出带宽为 0。

各队列输出带宽如下：

队列类型	队列类型	输入带宽(bps)	PIR(bps)	输出带宽(bps)
CS7	PQ	65M	55M	55M
CS6	PQ	30M	30M	30M
EF	WFQ，权重 5	10M	5M	5M
AF4	WFQ，权重 4	10M	10M	4M
AF3	WFQ，权重 3	10M	15M	3M
AF2	WFQ，权重 2	20M	25M	2M
AF1	WFQ，权重 1	20M	20M	1M
BE	LPQ	100M	未配置	0

队列带宽分配示例 2

假设某端口整形速率为 100Mbps，该接口各业务的输入带宽及配置的 PIR 如下。

队列类型	队列类型	输入带宽(bps)	PIR(bps)
CS7	PQ	15M	25M
CS6	PQ	30M	10M
EF	WFQ，权重 5	90M	100M
AF4	WFQ，权重 4	10M	10M
AF3	WFQ，权重 3	10M	15M
AF2	WFQ，权重 2	20M	25M
AF1	WFQ，权重 1	20M	20M
BE	LPQ	100M	未配置

则带宽分配过程如下：

- 首先进行 PQ 调度，保证 PQ 流队列的 PIR 带宽。PQ 调度后，剩余带宽 = $100\text{Mbps} - 15\text{Mbps} - 10\text{Mbps} = 75\text{Mbps}$ 。
- 接着进行第一轮 WFQ 调度，剩余带宽在各 WFQ 队列中按权重进行分配。计算公式：分给某 WFQ 队列的带宽 = $\text{剩余带宽} \times \text{本队列权重} / \text{所有 WFQ 队列权重之和}$ = $75\text{Mbps} \times \text{本队列权重} / 15$ ，因此，
 - 本轮分配给 EF 带宽 = $75\text{Mbps} \times 5 / 15 = 25\text{Mbps} < \text{PIR}$ ，分配给 EF 的带宽没有剩余
 - 本轮分配给 AF4 带宽 = $75\text{Mbps} \times 4 / 15 = 20\text{Mbps} > \text{PIR}$ ，AF4 实际获得带宽 = $\text{PIR} = 10\text{Mbps}$ ，分配给 AF4 的带宽剩余 10Mbps
 - 本轮分配给 AF3 带宽 = $75\text{Mbps} \times 3 / 15 = 15\text{Mbps} = \text{PIR}$ ，AF3 实际输入带宽只有 10Mbps ，因此分配给 AF3 的带宽剩余 5Mbps
 - 本轮分配给 AF2 带宽 = $75\text{Mbps} \times 2 / 15 = 10\text{Mbps} < \text{PIR}$ ，分配给 AF2 的带宽没有剩余
 - 本轮分配给 AF1 带宽 = $75\text{Mbps} \times 1 / 15 = 5\text{Mbps} < \text{PIR}$ ，分配给 AF1 的带宽没有剩余
- 此时，端口剩余带宽 15Mbps ，因此在未满足 PIR 的队列（EF、AF2 和 AF1）之间按权重分配剩余带宽。
 - 本轮分配给 EF 的带宽 = $15\text{Mbps} \times 5 / 8 = 9.375\text{Mbps}$ ，此时 EF 获得带宽共 34.375Mbps ，依然小于 PIR，因此分配给 EF 的带宽没有剩余
 - 本轮分配给 AF2 保证带宽 = $15\text{Mbps} \times 2 / 8 = 3.75\text{Mbps}$ ，此时 AF2 获得带宽共 13.75Mbps ，依然小于 PIR，因此分配给 AF2 的带宽没有剩余
 - 本轮分配给 AF1 保证带宽 = $15\text{Mbps} \times 1 / 8 = 1.875\text{Mbps}$ ，此时 AF1 获得带宽共 6.875Mbps ，依然小于 PIR，分配给 AF1 的带宽没有剩余
- 此时剩余带宽为 0，BE 流量没有获得调度，输出带宽为 0。

各队列输出带宽如下：

队列类型	队列类型	输入带宽(bps)	PIR(bps)	调度输出带宽(bps)
CS7	PQ	15M	25M	15M
CS6	PQ	30M	10M	10M
EF	WFQ，权重 5	90M	100M	34.375M
AF4	WFQ，权重 4	10M	10M	10M
AF3	WFQ，权重 3	10M	15M	10M
AF2	WFQ，权重 2	20M	25M	13.75M
AF1	WFQ，权重 1	20M	20M	6.875M
BE	LPQ	100M	未配置	0

队列带宽分配示例 3

假设某端口整形速率为 100Mbps，该接口各业务的输入带宽及配置的 PIR 如下。

队列类型	队列类型	输入带宽(bps)	PIR(bps)
CS7	PQ	15M	25M
CS6	PQ	30M	10M
EF	WFQ, 权重 5	90M	10M
AF4	WFQ, 权重 4	10M	10M
AF3	WFQ, 权重 3	10M	15M
AF2	WFQ, 权重 2	20M	10M
AF1	WFQ, 权重 1	20M	10M
BE	LPQ	100M	未配置

则带宽分配过程如下：

- 首先进行 PQ 调度，保证 PQ 流队列的 PIR 带宽。PQ 调度后，剩余带宽 = $100\text{Mbps} - 15\text{Mbps} - 10\text{Mbps} = 75\text{Mbps}$ 。
- 接着进行第一轮 WFQ 调度，剩余带宽在各 WFQ 队列中按权重进行分配。计算公式：分给某 WFQ 队列的带宽 = $\text{剩余带宽} \times \text{本队列权重} / \text{所有 WFQ 队列权重之和}$ = $75\text{Mbps} \times \text{本队列权重} / 15$ ，因此，
 - 本轮分配给 EF 带宽 = $75\text{Mbps} \times 5 / 15 = 25\text{Mbps} > \text{PIR}$ ，EF 实际获得带宽 = $\text{PIR} = 10\text{Mbps}$ ，分配给 AF4 的带宽剩余 15Mbps
 - 本轮分配给 AF4 带宽 = $75\text{Mbps} \times 4 / 15 = 20\text{Mbps} > \text{PIR}$ ，AF4 实际获得带宽 = $\text{PIR} = 10\text{Mbps}$ ，分配给 AF4 的带宽剩余 10Mbps
 - 本轮分配给 AF3 带宽 = $75\text{Mbps} \times 3 / 15 = 15\text{Mbps} = \text{PIR}$ ，AF3 实际输入带宽只有 10Mbps，因此分配给 AF3 的带宽剩余 5Mbps
 - 本轮分配给 AF2 带宽 = $75\text{Mbps} \times 2 / 15 = 10\text{Mbps} = \text{PIR}$ ，分配给 AF2 的带宽没有剩余
 - 本轮分配给 AF1 带宽 = $75\text{Mbps} \times 1 / 15 = 5\text{Mbps} < \text{PIR}$ ，分配给 AF1 的带宽没有剩余
- 此时，端口剩余带宽 30Mbps，因此在未满足 PIR 的队列（AF1）之间按权重分配剩余带宽。因此本轮调度 AF1 可获得的带宽为 5Mbps。
- 此时剩余带宽为 25Mbps，全部分配给 BE。

各队列输出带宽如下：

队列类型	队列类型	输入带宽(bps)	PIR(bps)	调度输出带宽(bps)
CS7	PQ	15M	25M	15M

队列类型	队列类型	输入带宽(bps)	PIR(bps)	调度输出带宽(bps)
CS6	PQ	30M	10M	10M
EF	WFQ, 权重 5	90M	10M	10M
AF4	WFQ, 权重 4	10M	10M	10M
AF3	WFQ, 权重 3	10M	15M	10M
AF2	WFQ, 权重 2	20M	10M	10M
AF1	WFQ, 权重 1	20M	10M	10M
BE	LPQ	100M	未配置	25M

5.3 拥塞避免

拥塞避免是指通过监视网络资源（如队列或内存缓冲区）的使用情况，在拥塞有加刷的趋势时，主动丢弃报文，通过调整网络的流量来解除网络过载的一种流控机制。

华为路由器支持两种丢弃策略：

- 尾丢弃
- WRED（Weighted Random Early Detection）

尾丢弃

拥塞避免传统的处理方法是尾丢弃（Tail Drop），当网络发生拥塞时，所有新到来的报文都被丢弃。

这种丢弃策略会引发 TCP 全局同步现象——对于 TCP 报文，如果大量的报文被丢弃，将造成 TCP 超时，从而引发 TCP 慢启动，使得 TCP 减少报文的发送。当队列同时丢弃多个 TCP 连接的报文时，将造成多个 TCP 连接同时进入拥塞避免和慢启动状态以降低并调整流量，称之为“TCP 全局同步”。这样多个 TCP 连接发往队列的报文将同时减少，而后又会在某个时间同时出现流量高峰，如此反复，使网络资源利用率低。

WRED


加权随机早期检测 WRED（Weighted Random Early Detection）是在队列拥塞前进行报文丢弃的一种拥塞避免机制。WRED 通过随机丢弃报文避免了 TCP 的全局同步现象——当某个 TCP 连接的报文被丢弃，开始减速发送的时候，其他的 TCP 连接仍然有较高的发送速度。这样，无论何时总有 TCP 连接在进行较快的发送，提高了线路带宽的利用率。

WRED 为每个队列都设定一对低门限和高门限值，并规定：

- 当队列长度小于低限时，不丢弃报文，丢弃概率为 0%。


- 当队列长度超过高限时，丢弃所有新到来的报文，即进行尾丢弃，丢弃概率为 100%。
- 当队列长度在低限和高限之间时，开始随机丢弃新到来的报文，且设定了一个最大丢弃概率，队列越长，丢弃概率越大。如果以报文长度为横坐标，丢弃概率为纵坐标，则丢弃概率曲线如图 5-13。

图5-13 WRED 丢弃概率曲线




WRED 详细实现过程如图 5-14，WRED 为每个到来的报文赋予一随机数 i ($0 < i\% \leq 100\%$)，并用该随机数与当前队列的丢弃概率比较，小于丢弃概率则新到的报文被丢弃。假设最大丢弃概率为 $a\%$ ，当前队列长度为 m ，对应的丢弃概率为 $x\%$ ，如果随机数 $0 < i \leq x$ ，则丢弃新到的报文；如果随机数 $x < i \leq 100\%$ ，则不丢弃新到的报文。

图5-14 WRED 实现过程




如图 5-15，假设队列长度为 m (低门限 $< m <$ 高门限) 时丢弃概率为 $x\%$ ，则当随机数落入区间 $[0, x]$ 时新到的报文被丢弃；长度为 n ($m < n <$ 高门限) 时丢弃概率为 $y\%$ ，则当随机数落入区间 $[0, y]$ 时报文被丢弃。区间 $[0, y]$ 比 $[0, x]$ 的范围大，随机数落入区间 $[0, y]$ 比落入区间 $[0, x]$ 的可能性大，因此，队列越长，新到的报文被丢弃的可能性越高。

图5-15 队列越长，丢弃可能性越高



假设有两个队列 Q1 和 Q2，对应的最大丢弃概率分别为 a% 和 b%，则两个队列的丢弃概率曲线图如图 5-16。假设当队列长度为 m 时，Q1 的丢弃概率为 x%，Q2 的丢弃概率为 y%，则当随机数落入区间 [0, x] 时 Q1 新到的报文被丢弃；当随机数落入区间 [0, y] 时 Q2 新到的报文被丢弃。区间 [0, y] 比 [0, x] 的范围大，随机数落入区间 [0, y] 比落入区间 [0, x] 的可能性大，因此，相同队列长度时，最大丢弃概率配置得越大，丢弃可能性越高。

图5-16 最大丢弃概率值越大，丢弃可能性越高



华为路由器支持为每个流队列 FQ 和每个类队列 CQ 配置 WRED 丢弃策略，且 WRED 区分三种丢弃优先级（对应红、黄、绿三种报文颜色），允许用户对每种丢弃优先级设定高低门限百分比和丢弃概率，因此 WRED 可以对各种业务流以及同一业务流内部不同的丢弃级别报文进行不同概率的丢弃。

丢弃策略的选择

对于实时性要求比较高的业务一般使用的是尾丢弃。因为这种报文要提供最大限度的带宽保证。采用尾丢弃是只有当报文队列达到最大长度时才会丢弃，由于使用 PQ 调


度，抢占其他业务的带宽，所以当发生拥塞时，实时性的业务带宽能够得到最大的保证。

对于 WFQ 队列，一般采用 WRED。由于 WFQ 队列是按权重分享带宽，容易发生拥塞，采用 WRED 策略有效的避免了 TCP 全局同步现象。

WRED 高低门限及丢弃概率的设置

实际应用时，WRED 低门限百分比建议从 50%开始取值，根据不同颜色的丢弃优先级逐级调整。一般推荐绿色报文设置的丢弃概率比较小，高、低门限值比较大；黄色报文次之；红色报文设置的丢弃概率最大，高、低门限值最小，如图 5-17。这样，在网络趋近拥塞时，红色报文由于设置的低门限值比较小，丢弃概率比较大，红色报文最先开始被丢弃；随着队列的长度逐渐增长，最后才开始丢弃绿色报文。如果队列长度达到相应颜色的最大门限，这种颜色的报文开始作尾丢弃。

图5-17 三种丢弃优先级的 WRED 丢弃概率曲线



WRED 队列最大长度的设置

华为路由器允许在配置 WRED 时修改队列最大长度（`queue-depth` 命令）。“5.2 队列及拥塞管理”中介绍过，当网络拥塞时，报文在缓存中产生堆积，被延迟处理，延迟时间的大小主要取决于队列的缓存长度以及该队列获得的输出带宽。因此，在队列输出带宽一定的情况下，队列越短，时延越小；队列越长，时延越大。

队列不能设置过短。如果某队列过短，缓存空间过小，容易造成丢包，流量即使速率不大也容纳不下。队列越短，容忍的突发量越小。队列越大，容忍的突发量越大。

队列也不能设置过长。如果队列太长，时延过大。尤其对于 TCP 应用，通信两端会预测网络拥塞情况，在发送完一个报文后，启动超时定期器等待对方应答，如果在定时器超时前没有等到应答，发送方会重发报文。如果报文在网络中被缓存的时间过长，不丢弃与丢弃没有区别。

因此推荐高优先级队列（CS7、CS6、EF）的长度设置为 $10\text{ms} \times \text{队列输出带宽}$ ；低优先级队列的长度设置为 $100\text{ms} \times \text{队列输出带宽}$ 。

5.4 队列缓存对时延和抖动的影响

队列缓存

路由器转发平面的流量管理器 TM (Traffic Manager) 上有一些高速缓存, 用于报文的缓冲和转发, 缓存由所有端口共享, 各端口竞争使用。为了避免有的端口长时间抢不到缓存而出现断流, 路由器给每个端口分配了一块最小可用缓存, 并且分配到端口的各个队列上, 保证每个队列均有缓存可用。

队列缓存对时延的影响

当 TM 收到报文时, 将报文放入缓存, 网络不拥塞时, 报文能被及时转发, 不会在缓存中产生堆积。这种情况下报文在缓存中的时间为 μs 级, 延迟时间可以忽略不计。

当网络拥塞时, 报文在缓存中产生堆积, 被延迟处理, 延迟时间会大幅增加。从报文进入缓存到报文被调度出去的时间间隔称为缓存时延 (也称为队列时延)。

缓存时延的大小主要取决于队列的缓存长度以及该队列获得的输出带宽, 可以使用如下公式计算缓存时延的最大值:

缓存时延最大值 = 队列缓存长度 ÷ 队列输出带宽

队列缓存长度单位是 Byte; 队列输出带宽即队列整形速率, 单位是 bit/s, 因此上述公式可表达为:

缓存时延最大值 = 队列缓存长度 × 8 ÷ 队列整形速率

从上述公式可以看出, 缓存越大, 缓存时延越大。

队列缓存对抖动的影响

抖动, 也叫做延时的变化, 是指同一业务流中不同分组所呈现的时延不同。数据包离开发送端时, 是按照一定的间隔均匀发送, 然而在通过网络时, 这一均匀的间隔因数据包经历不同的延迟而遭到破坏, 从而产生抖动。抖动会对语音、视频流等实时业务造成影响, 分组到达时间的差异将在语音或视像中造成断续。为了解决抖动问题, 通常语音/视频的接收终端会有去抖动缓存机制, 但如果网络抖动过于严重, 超出了接收终端的容忍度, 依然会导致语音或视像的失真和断续。

网络抖动严重的原因主要是 IP 网络路由状态频繁变化, 使得各数据包分别经由不同物理路由到达; 或者网络节点流量拥塞, 数据包在各节点缓存时间过长, 使得数据包到达接收端的时间差较大。其中, 后者是较为常见的原因。

根据抖动的定义可知: 抖动=时延差。时延差越大, 则抖动越大。那么, 如果把时延都控制的很小, 那时延差也就得到控制。即, 通过控制时延, 可间接控制抖动。例如, 把时延控制在 $5 \mu s$ 之内, 那么时延差也就控制在 $5 \mu s$, 即抖动也控制在 $5 \mu s$ 之内。

在“[队列缓存对时延的影响](#)”中介绍过, 缓存越大, 缓存时延越大。那么, 适当控制缓存长度, 可控制时延, 从而控制抖动。

队列缓存的设置

华为路由器允许在配置 WRED 时修改队列缓存长度 (使用 `queue-depth` 命令)。

队列不能设置过短。如果某队列过短，缓存空间过小，流量即使速率不大也容纳不下，容易造成丢包。

对时延、抖动敏感的实时性业务，队列也不能设置过长。如果队列太长，时延过大。

“[队列缓存对时延的影响](#)”中介绍过：

缓存时延最大值 = 队列缓存长度 × 8 ÷ 队列整形速率

此公式可推断出：

队列缓存长度(Byte) = 队列整形速率(bit/s) × 业务能容忍的最大时延(s) ÷ 8

低优先级业务的时延通常要求 ≤ 100ms，高优先级业务的时延要求 ≤ 10ms。结合上述公式，推荐高优先级队列（CS7、CS6、EF）的长度设置为 10ms × 队列整形速率；低优先级队列的长度设置为 100ms × 队列整形速率。

5.5 HQoS

HQoS 即层次化 QoS（Hierarchical Quality of Service），是一种通过多级队列调度机制，解决 Diffserv 模型下多用户多业务带宽保证的技术。

传统的 QoS 采用一级调度，单个端口只能区分业务优先级，无法区分用户。只要属于同一优先级的流量，使用同一个端口队列，不同用户的流量彼此之间竞争同一个队列资源，无法对端口上单个用户的单个流量进行区分服务。

HQoS 采用多级调度的方式，可以精细区分不同用户和不同业务的流量，提供区分的带宽管理。

基本调度模型

调度模型分为两部分：



- **调度器：**对多个队列进行调度。调度器执行某种调度算法，决定各个队列之间报文发送的先后顺序。调度算法包括按优先级调度 SP（Strict Priority），或按权重调度（DRR、WRR、DWRR、WFQ 算法的其中一种）。调度算法详细介绍请参见“5.2 队列及拥塞管理”。

调度器就一个动作：选择队列。队列被调度器选中时，队列最前面的报文被发送。

- **被调度对象：**即**队列**。报文根据一定的映射关系进入不同的队列。

队列被赋予 3 种属性：

- 1) 根据调度算法，队列被赋予优先级或权重。
- 2) 队列整形速率 PIR。
- 3) 报文丢弃策略，包括尾丢弃（Tail-drop）或 WRED。

队列有两个动作：


- 1) 入队：当系统收到报文时，根据报文丢弃策略决定是否丢弃报文。如果报文未被丢弃，则报文入队尾。
- 2) 出队：队列被调度器选中时，队列最前面的报文出队。出队时，先执行队列整形，之后报文被发送。

HQoS 层次化调度模型

为了实现分层调度，HQoS 采用树状结构的层次化调度模型，如图 5-18。树状结构有三种节点：

- 叶子节点：处于最底层，表示一个队列。叶子节点是被调度对象，而且只能被调度。
- 中间节点：处于中间层，既是调度器又是被调度对象。当作为被调度对象时，一个中间节点可以看成是一个虚队列。所谓虚队列，是指仅作为调度结构中的一个层次，不是实际占用缓存的队列。
- 根节点：处于最高层，表示最高级别的调度器。根节点只是调度器，不是调度对象。根节点通常被赋予 PIR 属性，用于限制输出总带宽。

图5-18 层次化调度模型




调度器可以对多个队列进行调度，也可以对多个调度器进行调度。其中，调度器可以看成父节点，被调度的队列/调度器看成子节点。父节点是多个子节点的流量汇聚点。

每个节点可以指定分类规则和控制参数，对流量进行一次分类和控制。不同层次的节点，其分类规则可以面向不同的分类需求（如用户、业务类型等），并且在不同的节点上可以对流量做不同的控制动作，从而实现了流量进行多层次、多用户、多业务的管理。

HQoS 的层次划分

HQoS 层次化调度中，可以只有一层中间节点，实现三层调度结构；也可以有多层中间节点，实现多层调度结构。甚至可以将两个或多个层次化调度模型叠加，通过制定映射规则，将一个调度模型输出的报文映射到另一个调度模型的叶子节点，如图 5-19，从而实现更加灵活的调度需求。

图5-19 灵活的调度层次划分




不同厂家、不同芯片，实现的调度层次不同。

华为路由器的调度结构

在华为路由器上，没有配置 HQoS 的情况下，只有类队列 CQ (Class Queue) 和 Port 调度器，其调度结构如图 5-20。

图5-20 没有配置 HQoS 时的队列调度结构



CQ 队列的属性包括：

- 队列优先级、队列权重
- 队列整形速率 PIR
- 报文丢弃策略，尾丢弃（Tail-drop）或 WRED


Port 调度器可以是按优先级调度 SP（Strict Priority），或按权重调度（WRR、DWRR、WFQ 算法的其中一种）。

说明

WRR、DWRR、WFQ 都是按权重调度，为方便，本文将按权重的调度统称为 WFQ。

在配置 HQoS 的情况下，路由器另外划分缓存，用于缓存需要层次化调度的业务流队列，并对这些流队列先进行一轮多层次调度，再将 HQoS 流与非 HQoS 流统一入 CQ 队列，进行统一调度，如图 5-21。

图5-21 HQoS 流队列调度



- 叶子节点：FQ（Flow Queue）队列

用于暂存一个用户各个优先级中的一个优先级的数据流。每个用户的数据流都可以划分为 1~8 个优先级，即每个用户可以使用 1~8 个 FQ。不同用户之间不能共享 FQ。每个 FQ 可以配置 shaping 值来限制该队列的最大带宽。

FQ 队列与 CQ 队列具有相同属性：

- 队列优先级、队列权重
- 队列整形速率 PIR
- 报文丢弃策略，尾丢弃（Tail-drop）或 WRED

- 中间节点：SQ（Subscriber Queue）

一个 SQ 代表一个用户（例如，一个 VLAN，或一个 LSP，或一个 PVC），每个 SQ 可定义其 CIR 和 PIR。

每个 SQ 固定对应 8 种 FQ 业务优先级，这 1~8 个 FQ 共享该 SQ 的带宽。如果哪个 FQ 空闲，则其他 FQ 可以占用空闲出来的带宽，但是受限于 FQ 自己的 PIR，最大不能超过 FQ 自己的 PIR。

SQ 既是调度器，又是虚队列作为被调度对象。

- 作为调度器：对多个 FQ 队列进行调度。FQ 队列可以配置为 PQ、WFQ 和 LPQ。优先级为 EF、CS6 和 CS7 的 FQ 队列默认采用 SP 调度算法；优先级为 BE、AF1、AF2、AF3、AF4 的流队列默认采用 WFQ 调度算法，调度权重为 10:10:10:15:15。
- 作为被调度对象的虚队列：被赋予了两个属性，CIR 和 PIR。通过流量测速 (Metering)，将输入流量分流成 “ $\leq \text{CIR}$ ” 与 “ $> \text{CIR}$ ” 两部分；“ $\leq \text{CIR}$ ” 的部分是指用户付费的部分，“ $> \text{CIR}$ ” 的那部分流量称为 EIR， $\text{EIR} = \text{PIR} - \text{CIR}$ 。EIR 是指突发量，允许用户流量突发至最大值 PIR。

- 根节点：GQ (Group Queue)

为了简便处理，可以把多个用户定义为一个用户组 GQ，类似于在配置 BGP 对等体时把多个具有共同特点的对等体配置为一个组。例如，可以把相同总带宽需求的用户归为一个 GQ，或把所有金牌级用户归为一个 GQ。

一个 GQ 可以绑定多个 SQ，但一个 SQ 最多只能绑定到一个 GQ 内。

GQ 作为调度器，对多个 SQ 队列进行调度。先采用 DRR 算法在 SQ 之间调度小于 CIR 的那部分流量，不同 SQ 之间采用 DRR 调度。如果有剩余带宽，再采用 DRR 算法调度超过 CIR 但小于 PIR 的那部分流量（即 EIR）。CIR 和 EIR 之间采用 SP 调度算法，优先保证 CIR 的带宽；超过 PIR 的流量会被丢弃。因此，如果 GQ 能获得 PIR 带宽，则 GQ 下每个 SQ 的 CIR 带宽都可以得到保证，且 SQ 最大可以获得 PIR 带宽。

此外，GQ 作为根节点，可以赋予最大带宽 PIR 属性，用于对多个用户的流量进行整体限速。该 GQ 下的所有用户都受限于这个最大带宽。GQ 的 PIR 值只是用于整体限速，并不用来保证带宽，GQ 的 PIR 值建议不小于 GQ 中所有 SQ 的 CIR 之和，否则单个用户 (SQ) 的流量无法得到保证。



说明

对 GQ 的 PIR 的补充说明：当设备支持 SQ 动态调整带宽特性时，

- 如果所有 SQ 的 CIR 之和超过 GQ 带宽，按 CIR:CIR 的比例分配带宽。如果所有 SQ 的 PIR 之和超过 GQ 带宽时，先满足各 SQ 的 CIR 带宽，再按 EIR:EIR 的比例分配剩余带宽 ($\text{EIR} = \text{PIR} - \text{CIR}$)。
- 如果所有 SQ 的 CIR 之和超过 GQ 带宽，按 CIR:CIR 的比例分配带宽。例如，SQ1 的 CIR = 100Mbps，SQ2 的 CIR = 50Mbps，而 GQ 带宽只有 100Mbps，则最终 SQ1 和 SQ2 按照 100M:50M 的比例输出。
- 如果所有 SQ 的 PIR 之和超过 GQ 带宽，先满足各 SQ 的 CIR 带宽，再按 EIR:EIR 的比例分配剩余带宽。例如，SQ1 的 CIR = 100Mbps，PIR = 150Mbps；SQ2 的 CIR = 0Mbps，PIR = 100Mbps；GQ 带宽是 200Mbps。首先，SQ1 获得 100M 的 CIR，剩余 100M 带宽按 SQ1、SQ2 的 EIR 比例分配。SQ1 的 EIR = 50M；SQ2 的 EIR = 100M，两者会近似按照 1:2 的比例分配剩余的 100M。最终，SQ1 获得 133Mbps，SQ2 获得 66Mbps。

为了帮助理解，下面举例说明 FQ、SQ、GQ 及其关系。

假设一栋楼有 20 个家庭，每个家庭购买的带宽是 20M，则只需要为每个家庭创建一个 SQ，设置 CIR 和 PIR 均为 20M 即可，满足了保证每个家庭 20M 带宽的要求，同时这里的 PIR 也是限定用户最大可使用的带宽为 20M。但随着 VoIP、IPTV 业务的开通，加上已有的个人上网 HSI 业务，运营商实时推出了新的带宽套餐，带宽仍然为 20M，其中包含了 VoIP、IPTV 等增值业务。这样，每个家庭可以使用 VoIP 电话，机顶盒看电视 (IPTV)，同时还使用电脑上网冲浪 (HSI)。

此需求的 HQoS 配置方法是：

- 配置 3 个 FQ，对应 3 种业务（VoIP、IPTV、HSI）；
- 配置 20 个 SQ，分别对应 20 个家庭用户。每个 SQ 配置 CIR 和 PIR，CIR 保证带宽，PIR 限定最大带宽。
- 配置 1 个 GQ 对应一栋楼，将 20 个用户的带宽汇总，将 20 个用户视为“用户组”，整合 20 个用户的总带宽作为 GQ 的 PIR，让这 20 个用户实现带宽共享。20 个用户相对独立，但是总带宽又受到 GQ 的限制。

分层模型为：

- FQ 用于对用户各种业务进行细分，控制用户的业务类型和带宽在各个业务之间的分配；
- SQ 用于区分用户，对每个用户的带宽进行限速；
- GQ 用于区分用户组，对 5 个 SQ 的流量进行整体限速。


FQ 的作用是保证各类业务的带宽分配关系；SQ 的作用是将每一个用户单独标识出来；而 GQ 的作用是使得各个用户之间的 CIR 能够得到保证，同时又达到带宽共享的目的。

超过 CIR 部分的带宽是不保证的，这是合理的，因为超过 CIR 部分的带宽实际上是用户并未付费的部分，是属于额外的。而重要的是，必须保证 CIR，因为 CIR 的带宽是客户购买的。按照图 5-21 的 SQ 调度可以看到，用户的 CIR 总是可以保证的，因为用户的 CIR 是被单独标识出来优先被调度的，因此不会被其它用户超过 CIR 部分的流量抢占。

华为路由器上，HQoS 可实现上、下行方向的调度，且上、下行的调度结构不同。

HQoS 上行队列调度

图5-22 HQoS 上行调度结构




HQoS 的上行队列调度，HQoS 流经过 FQ->SQ->GQ 的调度之后，与非 HQoS 流会合，统一进行如下两层调度：


- **目的板 TB (Target Blade) 调度**

TB 调度也称为 VOQ (Virtual Output Queue) 调度。

TB 调度的作用可以借用比喻来理解：如下图为一个十字路口，A 路口来了 3 辆车（汽车、铲车和卡车），分别去往 B、C、D。如果此时 B 路口堵车，则汽车不能动，由于它排在前面，后面的铲车和卡车也不能动，尽管 C、D 路口是畅通的。



如果在 A 路口针对目的地 B、C、D 路口分别设立三条车道，则上面的问题就可以解决了。



同理，对于路由器的交换网板，上面的 A、B、C、D 路口相当于不同的单板。如果每块单板都为去往的不同目的单板的报文分配队列，这种队列称为 VOQ，可以预防因某块目的单板拥塞而影响去往其他目的单板的报文。

VOQ 是设备自动划分的，用户无法更改 VOQ 队列属性和调度器属性。



说明

组播报文上行还没有复制，还不确定去往哪个目的单板，所以组播报文单独一个 VOQ 队列。

对于单播，有多少个目的单板，就有多少个单播 VOQ 队列。

VOQ 调度中，先在单播 VOQ 队列之间进行 DRR 调度，再在单播和组播两者之间进行 DRR 调度。

- 类队列 CQ (Class Queue) 调度

对于上行调度，有 4 个 CQ 队列，分别叫做 COS0（对应 CS7、CS6 和 EF）、COS1（对应 AF4 和 AF3）、COS2（对应 AF2 和 AF1）和 COS3（对应 BE）。

COS0 为 PQ 队列，优先调度 COS0 队列，再在 COS1~COS3 队列之间进行 WFQ 调度，WFQ 权值为 1:2:4。

用户无法更改上行 CQ 队列属性和调度器属性。

对于非 HQoS 的流量，则直接进入 4 个上行 CQ 队列，不经过 FQ 队列。对于 HQoS 的流量，则经过 FQ 队列和 CQ 队列。

上行调度过程如下：

1. 报文入队：报文首先入 FQ 队列。报文入 FQ 队列时，系统检查队列状态，确定是否进行尾丢弃或 WRED 丢弃，如果报文未被丢弃，则入 FQ 队尾。
2. 请求调度：报文入 FQ 队列后，向 SQ 调度器报告队列状态变化并请求调度。SQ 调度器再向其上一级 GQ 调度器报告队列状态变化并请求调度；请求调度的过程是 FQ-->SQ-->GQ。
3. 逐级调度：GQ 调度器收到请求后开始向下选择 SQ，被选中的 SQ 则选择 FQ，调度过程是 GQ-->SQ-->FQ。
4. 报文出队：FQ 被选中后，FQ 队列最前面的报文出队，进入 VOQ 队尾。VOQ 向 CQ 调度器报告队列状态变化并请求调度。CQ 收到请求向下选择 VOQ，被选中的 VOQ 队列最前面的报文出队，送入交换网板。

因此整体调度过程是 (FQ-->SQ-->GQ) + (VOQ-->CQ)。

表5-1 HQoS 上行各级调度汇总

队列/调度器	队列属性	调度器属性
FQ 队列	• 队列优先级、队列权重，可配置 • 队列整形速率 PIR，可配置，缺省情况，不设置 PIR • 报文丢弃策略，缺省为尾丢弃，可配置为 WRED	-
SQ	• CIR，可配置 • PIR，可配置	• 可配置 • 可采用 PQ 或 WFQ 对 FQ 进行调度。缺省情况下，EF、CS6 和 CS7 采用 PQ，AF2、AF3 和 AF4 采用 WFQ，BE 和 AF1 采用 LPQ
GQ	• PIR，可配置。只是用于整体限速，并不用来保证带宽	• 不可配置 • 先在 SQ 之间调度 CIR 流量，不同 SQ 之间采用 DRR 调度。如果有剩余带宽，再调度 EIR 流量，SQ 之间也是采用 DRR。

队列/调度器	队列属性	调度器属性
		CIR 和 EIR 之间采用 SP 调度算法，优先保证 CIR 的带宽；超过 PIR 的流量会被丢弃
VOQ	不可配置	- 不可配置 - 先在单播 VOQ 队列之间进行 DRR 调度，再在单播和组播两者之间进行 DRR 调度
CQ	不可配置	- 不可配置 - COS0 为 PQ 队列，优先调度 COS0 队列，再在 COS1~COS3 队列之间进行 WFQ 调度，WFQ 权值为 1:2:4

HQoS 下行队列调度

在华为路由器上，有些单板的物理接口卡（PIC, Physical Interface Card）可能嵌了一个 TM（Traffic Manager）芯片，称为 eTM（egress Traffic Manager）子卡。有些单板的物理接口卡没有 eTM 子卡。

如果 PIC 卡嵌了 eTM，下行调度在 eTM 上进行；如果 PIC 卡未嵌 eTM，则下行调度在下行 TM 上进行，这两种方式的调度过程有差异。

说明

V600R002 及之后版本才支持 eTM 子卡。


在任意视图下执行 **display device pic-status** 命令，可查看对应的单板是否嵌有 eTM 子卡。如果显示信息中“Type”字段值包含“_T_CARD”，则表示对应的是 eTM 子卡。例如：

```
<HUAWEI> display device pic-status
Pic-status information in Chassis 1:
```

```
-----
SLOT PIC Status      Type                               Port_count Init_result  Logic_down
1    1  Registered ETH_20XGF_NB_CARD      20         SUCCESS    SUCCESS
2    0  Registered LAN_WAN_2x10GF_T_CARD  2          SUCCESS    SUCCESS
-----
```

• 下行 TM 调度

图5-23 HQoS 下行 TM 调度结构



下行 TM 调度，除了 FQ->SQ->GQ 调度，还包括 CQ->Port 的调度。下行有 8 个 CQ 队列，分别为 CS7、CS6、EF、AF4、AF3、AF2、AF1 和 BE，其队列参数及调度参数允许用户修改。

下行 TM 调度过程：

- 报文入队：**报文首先入 FQ 队列。
- 请求调度：**下行整体请求调度的过程是 (FQ-->SQ-->GQ) + (CQ-->目的端口)。

- c. **逐级调度**：下行整体调度过程是（目的端口-->CQ）+（GQ-->SQ-->FQ）。
- d. **报文出队**：FQ 被选中后，FQ 队列最前面的报文出队，进入 CQ 队列。CQ 队列报文出队后送入目的端口。


对于非 HQoS 的报文，则直接进入 8 个下行 CQ 队列，不经过 FQ 队列。

表5-2 HQoS 下行 TM 各级调度汇总

队列/调度器	队列属性	调度器属性
FQ 队列	- 队列优先级、队列权重，可配置 - 队列整形速率 PIR，可配置，缺省情况，不设置 PIR - 报文丢弃策略，缺省为尾丢弃，可配置为 WRED	-
SQ	- CIR，可配置 - PIR，可配置	- 可配置 - 可采用 PQ 或 WFQ 对 FQ 进行调度。缺省情况下，EF、CS6 和 CS7 采用 PQ，AF2、AF3 和 AF4 采用 WFQ，BE 和 AF1 采用 LPQ
GQ	PIR，可配置。只是用于整体限速，并不用来保证带宽	- 不可配置 - 先在 SQ 之间调度 CIR 流量，不同 SQ 之间采用 DRR 调度。如果有剩余带宽，再调度 EIR 流量，SQ 之间也是采用 DRR。CIR 和 EIR 之间采用 SP 调度算法，优先保证 CIR 的带宽；超过 PIR 的流量会被丢弃
CQ 队列	- 队列优先级、队列权重，可配置 - 队列整形速率 PIR，可配置，缺省情况，不设置 PIR - 报文丢弃策略，缺省为尾丢弃，可配置为 WRED	-
Port	PIR，可配置（端口限速）。	- 可配置 - 可采用 PQ 或 WFQ 对 FQ 进行调度。缺省情况下，EF、CS6 和 CS7 采用 PQ，AF2、AF3 和 AF4 采用 WFQ，BE 和 AF1 采用 LPQ

- 下行 eTM 调度

图5-24 HQoS 下行 eTM 调度结构



与下行 TM 调度相比，下行 eTM 调度是一个五级调度结构，不是两个多级调度结构的叠加。下行 eTM 调度只有 FQ 一种实体队列，没有 CQ 队列。对 FQ 队列，除了 FQ->SQ->GQ 调度外，还进行父 GQ 调度，也称为虚端口 VI (Virtual Interface) 调度。



说明

此处的虚端口只是调度器的名称，并不是通常说的“虚拟端口”。具体应用时，虚端口可以对应子接口，也可以对应物理接口或其他。不同应用，虚端口所指的对象不同。

下行 TM 调度和下行 eTM 调度的区别在于：

- 下行 TM 是两个调度结构的叠加，其五级调度可划分为 (FQ->SQ->GQ) + (CQ->Port) 两部分。HQoS 流量先经过 (FQ->SQ->GQ)，再与非 HQoS 流量在 CQ 队列会合，进行 (CQ->Port) 的调度。

- 下行 eTM 是一级实体队列的调度，其五级调度为 FQ->SQ->GQ->VI->Port。
对于非 HQoS 流量的 8 个 CQ 队列，系统设置了一个默认的 SQ 队列。该 SQ 队列直接参与最高级的 Port 调度。

表5-3 HQoS 下行 eTM 各级调度汇总

队列/调度器	队列属性	调度器属性
FQ 队列	• 队列优先级、队列权重，可配置 • 队列整形速率 PIR，可配置，缺省情况，不设置 PIR • 报文丢弃策略，缺省为尾丢弃，可配置为 WRED	-
SQ	• CIR，可配置 • PIR，可配置	• 可配置 • 可采用 PQ 或 WFQ 对 FQ 进行调度。缺省情况下，EF、CS6 和 CS7 采用 PQ，AF2、AF3 和 AF4 采用 WFQ，BE 和 AF1 采用 LPQ
GQ	• PIR，可配置。只是用于整体限速，并不用来保证带宽	• 不可配置 • 先在 SQ 之间调度 CIR 流量，不同 SQ 之间采用 DRR 调度。如果有剩余带宽，再调度 EIR 流量，SQ 之间也是采用 DRR。CIR 和 EIR 之间采用 SP 调度算法，优先保证 CIR 的带宽；超过 PIR 的流量会被丢弃
父 GQ/VI	• PIR，可配置。只是用于整体限速，并不用来保证带宽	• 不可配置 • 在不同 GQ 之间进行 DRR 调度
Port	• PIR，可配置（端口限速）。	• 不可配置 • 在不同父 GQ/VI 之间进行 DRR 调度

• 下行 TM 调度和 eTM 调度的差异

表5-4 下行 TM 调度和 eTM 调度的差异

差异项	下行 TM 调度	下行 eTM 调度
port-queue 命令	针对整个端口某个优先级的流量。	针对非流队列的某个优先级的流量。
GQ 带宽共享	GQ 带宽可以基于 TM 共享，只	GQ 带宽只能基于接口共享，即

差异项	下行 TM 调度	下行 eTM 调度
	要 GQ 模板名字相同。	使 GQ 模板名字相同。
SQ 带宽共享	同一 GQ 下的多个 SQ 跨物理口共享。	只能同一 GQ 下的多个 SQ 跨子接口共享，不能实现跨物理口共享。
Trunk 和成员口	Trunk 接口及其成员接口都可以配置 port-queue，成员口的配置优先生效。成员口的配置对该成员口的所有流量进行调度。	Trunk 接口及其成员接口都可以配置 port-queue，但 port-queue 只对所有成员口的非流队列生效，不对流队列生效。

下文以端口整形为例详细说明下行 TM 调度和 eTM 调度的差异。假设某接口的主接口配置对 port-queue 的整形，子接口配置对 flow-queue/user-queue 整形：

```
flow-queue FQ
  queue ef shaping 10M

interface gigabitethernet1/0/0
  port-queue ef shaping 100M

interface gigabitethernet1/0/0.1
  user-queue cir 50m pir 50m flow-queue FQ

interface gigabitethernet1/0/0.2
  //注: gigabitethernet1/0/0.3 不配置 user-queue 和 qos-profile
```

- 对于下行 TM 调度，port-queue 配置的 shaping 值即为物理接口的总带宽，包括 HQoS 和非 HQoS 流量。以上配置表示：
 - 从子接口 GE1/0/0.1 输出的 EF 流不超过 10Mbps；
 - 从物理接口 GE1/0/0 输出的 EF 不超过 100Mbps，包括从主接口 GE1/0/0、子接口 GE1/0/0.1、GE1/0/0.2 的 EF 流。
- 对于下行 eTM 调度，port-queue 配置的 shaping 值仅为非 HQoS 流量的总带宽，即默认 SQ 的带宽。上述配置表示：
 - 从主端口 GE1/0/0 和子接口 GE1/0/0.2 输出的 EF 流为非 HQoS 流，一共不超过 100Mbps；
 - 从子接口 GE1/0/0.1 输出的 EF 流不超过 10Mbps；
 - 从物理端口 GE1/0/0 输出的 EF 最大可到 110Mbps。

HQoS 优先级映射

HQoS 上、下行调度体系都有 2 种实体队列，上行有 8 个 FQ 队列和 4 个 CQ 队列，下行有 8 个 FQ 队列和 8 个 CQ 队列。报文是根据服务等级进入 FQ 队列的，而 FQ 调度后，FQ 队列最前面的报文出队，入 CQ 队列，此时需要有优先级映射关系，以便确定报文入到哪个 CQ 队列。

FQ->CQ 队列的映射关系有两种模型：

- Uniform 模型：系统固定的映射关系。上行采用 Uniform 模型。
- Pipe 模型：可以由用户自行配置指定映射关系。Pipe 模型不会改变报文中自身携带的优先级。


缺省情况下，FQ 的 8 个优先级队列与 8 个 CQ 队列是一一对应关系。

联合流量整形

联合流量整形（share-shaping），也称为 FGQ（Flow Group Queue）shaping，是指把同一 SQ 下的两个或多个 FQ 作为一个组，对这个组进行整形，限制这个组的总带宽。避免 SQ 的其它业务流量饿死。


例如，假设某用户有 HSI、IPTV 和 VoIP 三种业务，其中 IPTV 业务包含 IPTV 单播和 IPTV 组播两种。如果要保证 IPTV 业务的 CIR 带宽，同时保证 HSI 和 VoIP 业务不因 IPTV 流量过大而得不到带宽，可以配置 4 个 FQ 分别对应 HSI、IPTV 单播、IPTV 组播和 VoIP，先对 IPTV 单播和组播业务进行联合流量整形，再对所有业务进行 HQoS 调度，如图 5-25。

图5-25 联合流量整形



目前，每个 SQ 下的 8 个 FQ 只能有 1 组联合流量整形。图 5-26 所示的几种联合整形方式在华为路由器上目前暂未实现。

图5-26 暂未实现的联合流量整形方式



在华为路由器上，联合流量整形有如下两种实现方式：

- 方式 A：在华为路由器大多数单板上，联合流量整形只进行整形不进行调度，且不要求参与联合整形的队列具有相同调度算法。
- 方式 B：有的单板，参与联合流量整形的队列必须具有相同调度算法，且先在联合流量整形的队列之间调度，再将其作为一个整体与 SQ 的其他队列一起调度。
与 SQ 的其他队列一起调度时，联合流量整形的流量作为一个整体，其调度优先级等于联合整形的队列中的最高优先级，调度权重等于联合整形所有队列的调度权重之和。




说明

目前只有 P20-E 和 P40-E 子卡支持联合流量整形，P20-E 采用方式 A，P40-E 采用方式 B。

示例 1 假设某 SQ 有 5 个队列，如图 5-27，EF 和 AF1~AF3 队列整形速率都是 90Mbps，SQ 总带宽为 100Mbps，所有队列采用 SP 调度。配置联合流量整形，将 AF3 和 AF1 的总带宽限制为 80Mbps。

图5-27 联合流量整形示例



假设某时刻，SQ 得到 PIR 带宽，到达流量速率 EF 为 10Mbps，其他队列都为 70Mbps 时，联合流量整形两种实现方式的带宽分配过程分别为：

- 方式 A：所有队列一起按优先级调度。
 - EF 获得 10Mbps，剩余带宽为 90Mbps。
 - AF3 可获得带宽 = $\text{Min}\{\text{AF3 PIR, share-shaping PIR, SQ PIR, 剩余带宽}\} = \text{Min}\{90\text{Mbps, } 80\text{Mbps, } 100\text{Mbps, } 90\text{Mbps}\} = 80\text{Mbps}$ ，但 AF3 只有 70Mbps，因此 AF3 实际获得带宽 70Mbps，剩余带宽变为 20Mbps。
 - AF2 可获得带宽 = $\text{Min}\{\text{AF2 PIR, SQ PIR, 剩余带宽}\} = \text{Min}\{90\text{Mbps, } 100\text{Mbps, } 20\text{Mbps}\} = 20\text{Mbps}$ 。剩余带宽为 0。
 - AF1 和 BE 未获得带宽。
- 方式 B：先调度 EF 队列，再对 AF3 和 AF1 进行调度，最后调度 BE。
 - EF 获得 10Mbps，剩余带宽为 90Mbps。
 - AF3 可获得带宽 = $\text{Min}\{\text{AF3 PIR, share-shaping PIR, SQ PIR, 剩余带宽}\} = \text{Min}\{90\text{Mbps, } 80\text{Mbps, } 100\text{Mbps, } 90\text{Mbps}\} = 80\text{Mbps}$ 但 AF3 只有 70Mbps，因此 AF3 实际获得带宽 70Mbps，剩余带宽变为 20Mbps。
 - AF1 可获得带宽 = $\text{Min}\{\text{AF1 PIR, share-shaping PIR-AF3 带宽, SQ PIR, 剩余带宽}\} = \text{Min}\{90\text{Mbps, } 10\text{Mbps, } 20\text{Mbps}\} = 10\text{Mbps}$ 。剩余带宽变为 10Mbps。
 - AF2 可获得带宽 = $\text{Min}\{\text{AF2 PIR, SQ PIR, 剩余带宽}\} = \text{Min}\{90\text{Mbps, } 100\text{Mbps, } 10\text{Mbps}\} = 10\text{Mbps}$ 。剩余带宽为 0。
 - BE 未获得带宽。

带宽分配结果汇总如下：

队列	调度方式	输入带宽 (Mbps)	PIR (Mbps)	调度输出带宽 (Mbps)	
				方式 A	方式 B
EF	SP	10	90	10	10
AF3	SP	70	90	70	70

队列	调度方式	输入带宽 (Mbps)	PIR (Mbps)	调度输出带宽 (Mbps)	
				方式 A	方式 B
AF2	SP	70	90	20	10
AF1	SP	70	90	0	10
BE	SP	70	未配置	0	0

示例 2：假设示例 1 中，EF 和 AF1~AF3 队列采用 WFQ 调度，其调度权重为：EF:AF3:AF2:AF1=1:1:1:2。BE 配置为 LPQ 队列。假设某时刻，SQ 能得到 PIR 带宽 100Mbps，到达流量速率 EF 和 AF3 为 10Mbps，其他队列都为 70Mbps 时，联合流量整形两种实现方式的带宽分配过程分别为：

- 方式 A：所有队列一起进行 WFQ 调度。

第 1 轮 WFQ 调度：

- EF 可获得带宽= $1/(1+1+1+2) \times 100\text{Mbps} = 20\text{Mbps}$ ，但 EF 只有 10Mbps，因此 EF 实际获得 10Mbps，剩余带宽为 90Mbps。
- AF3 可获得带宽= $1/(1+1+1+2) \times 100\text{Mbps} = 20\text{Mbps}$ ，但 EF 只有 10Mbps，因此 EF 实际获得 10Mbps，剩余带宽为 80Mbps。
- AF2 可获得带宽= $1/(1+1+1+2) \times 100\text{Mbps} = 20\text{Mbps}$ ，剩余带宽变为 60Mbps。
- AF1 可获得带宽= $2/(1+1+1+2) \times 100\text{Mbps} = 40\text{Mbps}$ ，剩余带宽变为 20Mbps。

第 2 轮 WFQ 调度：

- AF2 可获得带宽= $1/(1+2) \times 20\text{Mbps} = 6.7\text{Mbps}$ 。
- AF1 可获得带宽= $2/(1+2) \times 20\text{Mbps} = 13.3\text{Mbps}$ 。

剩余带宽变为 0Mbps，BE 未获得带宽。

- 方式 B：AF3 和 AF1 作为一个整体，与 EF、AF2 一起做 WFQ 调度，权重为：EF:(AF3+AF1):AF2=1:(1+2):1=1:3:1。

第 1 轮 WFQ 调度：

- EF 可获得带宽= $1/(1+3+1) \times 100\text{Mbps} = 20\text{Mbps}$ ，但 EF 只有 10Mbps，因此 EF 实际获得 10Mbps，剩余带宽为 90Mbps。
- (AF3+AF1) 可获得带宽= $3/(1+3+1) \times 100\text{Mbps} = 60\text{Mbps}$ ，未超过联合整形带宽，因此 (AF3+AF1) 实际可获得 60Mbps，剩余带宽变为 30Mbps。这 60Mbps 带宽在 AF3 和 AF1 之间按 1:2 分配 AF3 获得 20Mbps，但 AF3 实际只有 10Mbps，剩余的 50Mbps 全部分给 AF1。
- AF2 可获得带宽= $1/(1+3+1) \times 100\text{Mbps} = 20\text{Mbps}$ ，剩余带宽变 10Mbps。

第 2 轮 WFQ 调度：

- (AF3+AF1) 可获得带宽= $3/(3+1) \times 10\text{Mbps} = 7.5\text{Mbps}$ ，(AF3+AF1) 此时一共可获得 67.5M 带宽，仍未超过联合整形带宽，因此 7.5Mbps 可全部分给 (AF3+AF1)，且而 AF3 的 PIR 已满足，因此 7.5Mbps 全部分给 AF1。
- AF2 可获得带宽= $1/(3+1) \times 10\text{Mbps} = 2.5\text{Mbps}$ 。

剩余带宽变为 0Mbps，BE 未获得带宽。


带宽分配结果汇总如下：

队列	调度方式	输入带宽 (Mbps)	PIR (Mbps)	调度输出带宽 (Mbps)	
				方式 A	方式 B
EF	SP	10	90	10	10
AF3	SP	70	90	10	70
AF2	SP	70	90	26.7	22.5
AF1	SP	70	90	53.3	57.5
BE	SP	70	未配置	0	0


HQoS 的应用及分类

为方便理解，列举几个简单的 HQoS 应用：

- 无任何 QoS 配置时：如果一个出接口的流量不做任何 QoS 配置，则调度过程是：1 个 Port 队列，Port 下只有 1 个 VI 队列，VI 下只有 1 个 GQ 队列，GQ 下只有 1 个 SQ 队列，SQ 下只有 1 个 FQ 队列有流量，由于各层都只有 1 个队列，最终可以看成是一个 FIFO 队列。
- 只区分业务优先级：如果一个出接口的流量只区分优先级，则对应 HQoS 队列为：1 个 Port 队列，Port 下只有 1 个 VI 队列，VI 下只有 1 个 GQ 队列，GQ 下只有 1 个 SQ 队列，SQ 下只有 8 个 FQ 队列，由于各层都只有 1 个队列，最终可以看成是一个 FQ-->Port 的调度。
- 区分业务优先级+区分用户：如下图，L3 Gateway 连接一个 RTN，RTN 汇聚了 3 个基站，如果在 GE1/0/0 出口区分这三个基站，同时区分 3 个基站内部的不同优先级业务，则层次化结构为：基站业务->基站->Port；对应 HQoS 队列为 FQ->SQ->Port，即 1 个 Port 队列，Port 下只有 1 个 VI 队列，VI 下只有 1 个 GQ 队列，GQ 下有 3 个 SQ 队列，SQ 下有 8 个 FQ 队列。



- 区分优先级+区分用户+区分汇聚设备：如下图，L3 Gateway 连接 2 个 RTN 汇聚设备，每个 RTN 汇聚了 3 个基站，如果在 GE1/0/0 出口区分这 2 个 RTN 汇聚设备，每个汇聚设备下区分三个基站，并且区分 3 个基站内部的不同优先级业务。则层次化结构为：基站业务->基站->RTN->Port；对应 HQoS 队列为 FQ->SQ->GQ->Port，即 1 个 Port 队列，Port 下只有 1 个 VI 队列，VI 下只有 2 个 GQ 队列，GQ 下有 3 个 SQ 队列，SQ 下有 8 个 FQ 队列。



HQoS 从配置角度分类，可分为如下三种：


- **基于接口的 HQoS**

将一个接口或接口下创建的一个子接口作为一个用户，即一个接口/子接口的所有报文都属于一个 SQ 队列。用户队列 SQ 直接配置在接口上。

基于接口的 HQoS 支持上行和下行调度。

如图 5-28，路由器的 GE1/0/0.1 和 GE1/0/0.2 子接口上分别接入 VLAN1 和 VLAN2。如果要使 VLAN1 的 EF、AF 流量带宽分别为 10Mbps 和 30Mbps，总带宽保证为 100Mbps，允许突发至 120Mbps；VLAN2 的 EF 流量带宽为 50Mbps，总带宽保证为 200Mbps，允许突发至 220Mbps。VLAN1 和 VLAN2 的带宽总和限制为 320Mbps。

图5-28 基于接口的 HQoS 应用



此需求可以应用基于接口的 HQoS。一个接口只有一个 VLAN 用户，一个 VLAN 用户有多种业务，其层次化结构为：业务类型-->VLAN-->端口，对应 HQoS 队列为：FQ-->SQ-->端口。

- **基于类的 HQoS**


采用复杂流分类对需要进行 HQoS 调度的报文流进行分类，然后把所有匹配上分类规则的报文作为一个用户。

用户队列 SQ 配置在流行为下，然后在接口上应用引用该流行为的流量策略。

目前基于类的 HQoS 只支持在上行生效。

如图 5-29，路由器有两个接口接入 RTN，每个 RTN 都汇聚了 3 个基站，每个基站都有不同优先级业务。路由器作为基站的三层网关，要求区分这三个基站，同时区分 3 个基站内部的优先级业务。

图5-29 基于类的 HQoS 应用



此需求可用基于类的 HQoS 实现。一个端口有两个用户组（两个 RTN），一个用户组有 3 个用户（3 个基站），一个基站有多种业务，其层次化结构为：基站业务-->基站-->RTN-->端口，对应 HQoS 队列为：FQ-->SQ-->GQ-->目的端口。

• 基于模板的 HQoS

实现多个接口接入的流量作为一个用户进行统一调度，即多个接口的流量进入同一个 SQ 队列进行调度，满足了不同接口接入的同一用户的流量控制要求。


基于模板的 HQoS 通过定义不同的 QoS 模板（qos-profile）并应用到接口来实现对接入用户的 QoS 调度管理。QoS 模板是 QoS 调度参数的集合，用于指定用户队列的调度参数（用户队列的带宽、用户的流队列等）。

基于模板的 HQoS 支持上行和下行调度。

例如图 5-30，路由器作为 ISP 边缘设备，使用 E-Trunk1 接口接入某局域网，该局域网有 1000 个用户都开通了 VoIP、IPTV 和普通上网业务。使用 QinQ 终结子接口 Eth-Trunk1.1000 接入 VoIP 业务，QinQ 终结子接口 Eth-Trunk1.2000 接入 IPTV

业务，QinQ 终结于接口 Eth-Trunk1.3000 接入其他业务。使用外层 Q 的 802.1p 标记业务类型（VoIP 的 802.1p=5，IPTV 的 802.1p=4），内层 Q 的 VID 标记用户，其中，内层 Q 的 VID 为 1~1000，Eth-Trunk 1.1000 的外层 Q 的 VID=1000，Eth-Trunk 1.2000 的外层 Q 的 VID=2000；要求对每个用户的总带宽限制在 120Mbps 以内，保证带宽为 100Mbps，每个用户的 VoIP 和 IPTV 的带宽保证分别为 60Mbps 和 40Mbps，其他业务不做带宽保证。

图5-30 基于模板的 HQoS 应用



此需求可用基于模板的 HQoS 实现。内层 Q 不同的流量进不同的 SQ，内层 Q 相同的流量进同一个 SQ，因此创建 1000 个 SQ，内层 Q 相同但外层 Q 不同的流量进入同一个 SQ 的不同 FQ 队列。

配置例：

```
flow-queue test
queue ef pq shaping 60000
queue af4 wfq shaping 40000

qos-profile qpl
user-queue cir 100 pir 120 flow-queue test

interface Eth-Trunk1.1000
trust 8021p
control-vid 1000 qinq-termination
vlan-group 1
qinq termination pe-vid 1000 ce-vid 1 to 1000 vlan-group 1
ip binding vpn-instance voip
ip address 168.0.1.1 255.255.255.0
qos-profile qpl inbound pe-vid 1000 ce-vid 1 to 1000 identifier ce-vid group
group1
qos-profile qpl outbound pe-vid 1000 ce-vid 1 to 1000 identifier ce-vid group
group1

interface Eth-Trunk1.2000
control-vid 2000 qinq-termination
vlan-group 1
```

```
qinq termination pe-vid 2000 ce-vid 1 to 1000 vlan-group 1
ip binding vpn-instance iptv
ip address 168.0.2.1 255.255.255.0
qos-profile qp1 inbound pe-vid 2000 ce-vid 1 to 1000 identifier ce-vid group
group1
qos-profile qp1 outbound pe-vid 2000 ce-vid 1 to 1000 identifier ce-vid group
group1

interface Eth-Trunk1.3000
control-vid 3000 qinq-termination
vlan-group 1
qinq termination pe-vid 3000 ce-vid 1 to 1000 vlan-group 1
ip binding vpn-instance others
ip address 168.0.1.1 255.255.255.0
qos-profile qp1 inbound pe-vid 3000 ce-vid 1 to 1000 identifier ce-vid group
group1
qos-profile qp1 outbound pe-vid 3000 ce-vid 1 to 1000 identifier ce-vid group
group1
```



说明

identifier ce-vid: 表示相同的 CE-VID 共享一个 SQ 带宽。

group group1: 默认情况下，系统基于接口分配 SQ 资源，不同接口的 SQ 不能共享资源。而基于模板的 HQoS 中，同一用户的流量分布在不同接口上，因此需要指定 group，使不同接口的 SQ 按照相同 group 共享同一块单板的资源。本例中，同一 SQ 的流量分布在多个接口上，因此需要指定相同 group。

上述配置中，还需要在该设备上对用户回程流量的入接口配置 trust 8021p。

5.6 单板实现差异

差异项	单板类型	差异描述
eTM 子卡调度（TM 调度和 eTM 调度的详细实现差异请参见表 5-4）	Type-A	部分单板支持
	Type-B	部分单板支持
	Type-C	不支持
	Type-D	部分单板支持
	确认一块 PIC 子卡是否为 eTM 子卡，可在任意视图下执行 display device pic-status 命令。如果显示信息中 Type 字段包含了 “_T_CARD” 字符串，则表示该 PIC 子卡是 eTM 子卡。	
<pre><HUAWEI> display device pic-status Pic-status information in Chassis 1: - - - - - - - - - - SLOT PIC Status Type Port count Init result Logic down 1 1 Registered ETH 20XGF NB CARD 20 SUCCESS SUCCESS 2 0 Registered LAN WAN 2x10GF T CARD 2 SUCCESS SUCCESS - - - - - - - - - -</pre>		

差异项	单板类型	差异描述
流队列长度	Type-B	可配置的最大值是 1000 Kbytes。 例如： [HUAWEI] flow-wred test [HUAWEI-flow-wred-test] queue-depth 1000
	Type-A	可配置的最大值是 32768 Kbytes。
	Type-C	例如：
	Type-D	[HUAWEI] flow-wred test [HUAWEI-flow-wred-test] queue-depth 32768
端口队列（CQ 队列）长度	Type-B	可配置的最大值是 8000 Kbytes。 例如： [HUAWEI] port-wred test [HUAWEI-port-wred-test] queue-depth 1000
	Type-A	可配置的最大值是 131072 Kbytes。
	Type-C	例如：
	Type-D	[HUAWEI] port-wred test [HUAWEI-port-wred-test] queue-depth 131072
CQ 队列的拥塞避免	Type-A	缺省采用尾丢弃。
	Type-B	缺省采用尾丢弃。
	Type-C	缺省采用 WRED。 WRED 丢弃的低门限和高门限缺省值都是 64 Mbit，丢弃概率缺省值为 98%。
	Type-D	缺省采用 WRED。 WRED 丢弃的低门限和高门限缺省值都是 1 Mbit，丢弃概率缺省值为 100%。

6 MPLS QoS

关于本章

- 6.1 MPLS QoS 简介
- 6.2 MPLS DiffServ
- 6.3 MPLS DiffServ 配置解析
- 6.4 MPLS-TE
- 6.5 MPLS DiffServ-Aware TE
- 6.6 MPLS VPN QoS
- 6.7 单板实现差异

6.1 MPLS QoS 简介

MPLS 使用标签转发替代了传统的路由转发，路由功能强大、灵活，可以满足各种新应用对网络的要求，而且其核心技术可扩展到多种网络协议（IPv4、IPv6 等）。MPLS 可以在多种物理媒质上实施，例如 Ethernet、PPP、ATM 和帧中继 FR（Frame Relay）。

因此，目前 MPLS 被广泛地应用于大规模网络的组建，在 MPLS 网络中实现服务质量（QoS）成为必须考虑的问题。

MPLS 通过建立 LSP（Labeled Switch Path）实现面向连接的转发。如果针对 LSP 实施 QoS，就有可能实现 LSP 上的数据流的 QoS。按照这个思路，DiffServ/IntServ 模型被运用到 MPLS 中。其中，MPLS 同 IntServ 的结合，产生了 MPLS 流量工程（Traffic Engineering）技术——MPLS-TE；MPLS 同 DiffServ 结合，产生了 MPLS DiffServ 技术。

MPLS 与 IntServ 结合——MPLS-TE

IntServ 模型使用 RSVP 进行端到端的资源预留，为每一个流维持一个转发状态，可扩展性较差，因此 IntServ 模型没有得到广泛应用。但 RFC 3209 对 RSVP 进行了扩展，使 RSVP 的 PATH 消息支持发起标签请求，使 RESV 消息支持标签分配。扩展后的 RSVP 称为 RSVP-TE。RSVP-TE 的出现，使 MPLS 在建立 LSP 过程中能控制流量流经

的路径同时进行资源预留，使网络流量绕开拥塞节点，达到平衡网络流量的目的，这就是 MPLS 流量工程——MPLS-TE。

MPLS-TE 虽然可以精确控制流量流经的路径，保证流量带宽，但没有识别业务的能力，在 LSP 中各种业务流量是不分优先级的，因此 LSP 内一旦发生实际流量超出预约流量的情况，对 QoS 敏感的业务将直接受到影响。因此，MPLS-TE 也无法单独解决 QoS 保证问题。

MPLS 与 DiffServ 结合——MPLS DiffServ

DiffServ 模型可以根据报文内容区分各种业务的流量，分配优先级，保证高优先级业务优先转发。因此 DiffServ 模型广泛使用于 MPLS 网络中。

但 DiffServ 模型只能在单个节点上预留资源，无法事先约定带宽，在流量超出带宽允许范围的情况下，只能通过对低优先级业务增大延时、提高丢包率来保证关键业务的高优先级转发。在网络极端拥塞的情况下，高优先级的关键业务甚至也无法幸免延时和丢包。因此，单纯应用 MPLS DiffServ 技术很难提供基于流的端到端的 QoS，无法彻底满足服务等级协议 SLA (Service Level Agreement)。

MPLS-TE 和 MPLS DiffServ 的结合——MPLS DS-TE

如果把 DiffServ 和 RSVP-TE 技术结合起来，就可以让 MPLS 网络既能识别业务类型，又能根据优先级为关键业务预留资源和优先转发，这两种技术的结合点就是 MPLS DS-TE。MPLS DS-TE 可以通过为不同业务类型分别建立保证一定带宽的 LSP 隧道，来保证高优先级业务的带宽需求。

MPLS QoS 在 MPLS VPN 的应用——VPN QoS

针对需要在 VPN 内承载多种不同优先级的业务流量的场合，可以把 MPLS QoS 和 MPLS VPN 技术结合起来，形成 VPN QoS 技术。VPN QoS 技术将 VPN 内传输的多种流量区分优先级，保证高优先级业务优先转发，从而为 VPN 内的关键业务提供了 QoS 保证。

DiffServ、RSVP-TE、MPLS VPN 三者按需组合，可以达到隔离业务流量、区分优先级、保证关键业务流量或者关键 VPN 的带宽资源、在 VPN 或 MPLS-TE 隧道中按优先级转发等多种效果，为运营商开展语音、视频类业务运营，或者提供有 SLA 的 VPN 服务提供了技术保障。

6.2 MPLS DiffServ

MPLS DiffServ 流分类方案


IP QoS 实现 DiffServ 的方法是：在网络的边缘进行流量分类，将流量划分为多个优先级或多个服务类，如使用 IP 报文头的 IP Preference 来标记报文，可以将报文最多分成 $2^3 = 8$ 类；若使用 DSCP，则最多可分成 $2^6 = 64$ 类。在报文发送途径中的每一跳通过检查报文的 DSCP 或 IP Preference 字段，确定该数据包要求的 QoS。

而在 MPLS 网络中，路由器不会检查 IP 报文头的内容，因此无法通过 ToS 或 DSCP 字段来进行流量分类。RFC3270 定义了两种方案实现 MPLS 网络的流量分类。

第一种方案：E-LSP

第一种方案是使用 MPLS 报文首部的 3bit 的 Exp 字段（如图 6-1）来承载 DiffServ 信息。转发时报文根据标签转发，而由 Exp 字段决定 PHB。

图6-1 MPLS 报文首部结构




EXP 可以从承载在 LSP 中的 IP 数据包的 DSCP 或 IP Preference 拷贝，也可以由 MPLS 网络运营商设置。这种从 EXP 位推导出 PHB 的 LSP 称为 E-LSP（EXP-Inferred-PSC（PHB Scheduling Class） LSP）。

这种方案适用于不超过 8 个 PHB 的网络。由于 IP 报文的优先级字段是 3bits，与 EXP 的长度相同，可以直接形成一对一的映射。但 IP 报文的 DSCP 字段是 6bits，与 EXP 的长度不一样，因此 E-LSP 与 IP QoS 不能完全映射。在 IEEE 标准的实现中，将 DSCP 的前 3bits（即 CSCP）与 EXP 进行映射，而忽略 DSCP 的后 3bits。

E-LSP 方案中，在 MPLS 报文进设备时进行流分类，将报文携带的 EXP 统一映射到设备内部的服务等级和丢弃优先级。流量分类后，流量整形、流量监管、拥塞避免等 QoS 实现方法就和 IP 网络中的完全相同了。

图6-2 E-LSP



在报文出设备时，再将内部的服务等级和丢弃优先级映射为 EXP，以便后续网络设备根据 EXP 提供相应的服务质量。



说明

在华为路由器上，EXP 与设备内部的服务等级和颜色之间存在默认的映射关系，详细信息请参见“3.3.2 QoS 优先级映射”章节。

第二种方案：L-LSP

第二种解决方案适用于超过 8 个 PHB 的网络。由于 Exp 只有 3bit，不能仅用 Exp 来区分超过 8 个的 PHB，而 MPLS 报头其他字段中，可用于区分 PHB 的唯一一个字段只有标签。标签有 20bit，可以与 IP QoS 完全映射。这种使用标签来传输所需 PHB 信息的 LSP 被称为 L-LSP（Label-Only-Inferred-PSC LSP）。

L-LSP 转发期间，标签决定数据包转发路径，并为其分配调度行为（Scheduling Treatment）；而 Exp 位则携带分配给数据包的丢弃优先级（Drop Precedence）信息，因此 PHB 由标签和 EXP 位共同来决定。由于标签与 PHB 之间存在联系，因此当建立 LSP 信令时需要传输 PHB 信息。L-LSP 可传输来自单一 PHB 的数据包，也可以传输采用相同调度策略但丢弃优先级不同的多个 PHB 的数据包。

两种方案的比较

采用 L-LSP 方案，必须为入口 LSR 和出口 LSR 所支持的不同服务类型分别建立 LSP，即一个 L-LSP 只能提供一种服务类型。

采用 E-LSP 方案，在入口 LSR 和出口 LSR 之间只需要一条 LSP 便可以支持多达 8 种服务类型。

表6-1 E-LSP 与 L-LSP 的比较

E-LSP	L-LSP
通过 Exp 域决定 PHB（包括丢弃优先级）	通过标签或 Exp 决定 PHB
不需要附加的信令	需要用信令建立 LSP
在 ATM 链路上不支持	支持 ATM 链路
每条 LSP 可以支持多达 8 个 BA	每条 LSP 只能支持 1 个 BA


L-LSP 与 E-LSP 的使用选择取决于需要的服务种类、丢弃优先级以及是否是 ATM 节点。

- 基于链路层的考虑：在 PPP 与 LAN 上，可以根据需要，选用 E-LSP、L-LSP 或者两者结合起来使用。而在 ATM 网络上，由于 EXP 域不可见，只能使用 L-LSP。
- 基于服务类型多少的考虑：仅仅使用 E-LSP，最多只能支持 8 个 PHB。如果需要支持多于 8 个的 PHB，必须使用 L-LSP，或者 E-LSP 与 L-LSP 混合使用。
- 基于网络负荷的考虑：使用 E-LSP，节省了 LSP 的数量、标签资源、信令的负荷；使用 L-LSP，相对来说耗费资源。

一般目前网络上提供最多 4 种类型的服务，E-LSP 就可以满足了。只有对于 ATM 节点，或者有着大量的服务类型与丢弃优先级需求的 QoS 网络部署需求，才需要利用 L-LSP。因此，华为路由器只实现 E-LSP。

MPLS DiffServ COS 处理模式

DiffServ 体系结构允许 DS 域内的中间节点检查并修改 IP Preference、DSCP 或 Exp 值，统称 COS（Class of Service）值，这会导致报文的 COS 值在 IP 网络和 MPLS 网络传输过程中都可能发生变化。




因此，在报文进入 MPLS 网络或从 MPLS 网络离开进入 IP 网络时，运营商需要在 MPLS 边缘路由器对 COS（Class of Service）处理做出选择：是否信任 IP/MPLS 报文已经携带的 COS 信息。RFC3270 中定义了三种 COS 处理模式：Uniform、Pipe 和 Short Pipe。

Uniform 模式


当运营商认为可以完全信任 IP 网络流量携带过来的 COS（IP Preference/DSCP）时，可以采用 Uniform 模式：MPLS 入节点将报文携带上来的 COS 直接复制到 MPLS 外层标签的 EXP 字段中，从而保证在 MPLS 中给予同样的 QoS 保证。报文离开 MPLS 网络时，出口节点再将 EXP 字段值复制回 IP 报文的 IP Preference/DSCP。

图6-3 Uniform 模式



Uniform 模式，顾名思义，报文在 IP 网和 MPLS 网中的优先级标识是统一的，即报文进入 MPLS 域和出 MPLS 域都作优先级映射。但这样做的缺点是，如果报文在 MPLS 网络中改变了 EXP 字段的值，会导致报文离开 MPLS 网络后采用的 PHB 也发生改变，无法保留用户初始设置的 COS 值。


图6-4 Uniform 模式无法保留初始的 COS 值



Pipe 模式

当运营商认为 IP 网络流量携带过来的 COS 不可信任时，可以采用 Pipe 模式：忽略用户携带的 COS，在 MPLS 域入节点为 MPLS 外层标签的 EXP 字段重新赋值，从 MPLS 入节点到出节点，流量都按照运营商的意愿进行 QoS 调度，直到流量出 MPLS 域之后再根据其原来携带的 COS 值转发。

图6-5 Pipe 模式




在 Pipe 模式中，报文在进入 MPLS 域时，入节点不拷贝 IP Precedence/DSCP 到 Exp。报文出 MPLS 域时，出节点也不拷贝 Exp 到 IP Precedence/DSCP。如果报文在 MPLS

网络中改变了 EXP 字段的值，只在 MPLS 网络中有效。当报文离开 MPLS 网络后，报文之前携带的 COS 继续有效。

Short Pipe 模式

Short Pipe 模式是对 Pipe 模式的改进，报文在 MPLS 入节点的处理和 Pipe 模式相同，但在 MPLS 网络的出节点上，出节点先执行标签弹出操作，再进行 QoS 调度。即，在 MPLS 出节点上按照报文之前携带的初始的 COS 值进行调度，而从报文进入 MPLS 开始到 MPLS 倒数第二跳按照运营商的意愿进行 QoS 调度。


图6-6 Short Pipe 模式



使用 Pipe 或 Short Pipe 模式，在运营商内部网络，运营商可以根据自己的自身情况来规划 QoS，而不改变客户侧的 QoS。

Pipe 模式和 Short Pipe 模式的区别在于：PE 上 CE 侧出方向的 QoS 调度，Pipe 模式运营商用自己的 QoS 标记，Short Pipe 则采用用户的 QoS 标记，如图 6-7。

图6-7 Pipe 和 Short Pipe 的区别



6.3 MPLS DiffServ 配置解析

BA 和 PHB 详解

了解本节之情，请先了解 BA 和 PHB 的解析，详细信息请参见 3.3.3 BA 和 PHB 详解。

MPLS DiffServ 场景的 BA、PHB 动作剖析

在 MPLS diffserv 场景中，有三种模式：Uniform，Pipe，Short-Pipe。

- Uniform：按照报文原始标记设置穿越 MPLS 网络的优先级标记。从 MPLS 网出来的时候，用户报文的优先级标记按照要求重标记。
- Pipe 和 short-pipe：不关心报文原始标记，在穿越骨干网络时，统一打一个固定的优先级标记。从骨干网出来的时候，用户报文的优先级标记要保持不变。
 - Pipe：骨干网尾节点不按照报文原始优先级标记进行调度。
 - short-pipe：尾节点按照报文原始优先级标记进行调度。

图6-8 PE 节点的 BA、PHB 动作剖析





图6-9 P 节点的 BA、PHB 动作剖析



- 在 PE 的网络侧接口要同时做 BA 和 PHB，因此要配置 **trust upstream** 命令。
- P 节点两侧接口要同时做 BA 和 PHB，因此要配置 **trust upstream** 命令。
- 在 PE 的用户侧接口，上行要做 BA，下行方向：
 - Uniform 模式：需执行 PHB。即，Uniform 模式，PE 的用户侧接口要同时做 BA 和 PHB，因此要配置 **trust upstream** 命令。
 - Pipe 和 short-pipe 模式：PE 的用户侧接口只做 BA 不做 PHB，因此配置命令行 **diffserv-mode { pipe service-class color | short-pipe service-class color }**，只做 BA。且 **diffserv-mode** 命令与 **trust upstream** 命令互斥。

说明

- V600R002 及之前版本，PHB 开关默认为打开状态，对于 Pipe 和 short-pipe 模式，PE 的用户侧接口要配置 **qos phb disable** 命令，将 PHB 开关关闭。
- V600R003 及后续版本，PHB 开关默认为关闭状态。

PHB 动作是否修改 DSCP 字段，取决于单板类型和接口配置

对于 VLL/VPLS 出、入隧道场景，因是二层转发，不修改 DSCP；

对于 MPLS 转发，DSCP 值也不会被修改；

对于 MPLS L3VPN 出、入隧道场景，因涉及到 IP 转发，因此，DSCP 值可能会被修改（但出隧道时，如果是 Pipe 或 Short-Pipe，DSCP 值不会被修改），详细情况请参见下表。

表6-2 L3VPN 的出/入隧道场景 DSCP 值的设置规则

出接口配置（●表示配置，○表示不配置）	DSCP 值设置规则	说明
○trust upstream 命令 ○qos phb enable 命令	不变	此表中，“根据<Service-Class, color>和下行指定 DS 域反射表进行设置”的前提是在下行做 PHB 反射；如果下行未做 PHB 反射，则 DSCP 不变。 下行单板是否做 PHB 反射的相关信息请参见 BA 和 PHB 开关 和 PHB 动作的控制 。
●trust upstream 命令 ○trust 8021p 命令	• MPLS L3VPN 入隧道：下行单板为 Type-B 和 Type-C 时，根据 <Service-Class, color>和下行指定 DS 域反射表进行设置；下行单板为其他类型时，DSCP 不变。 • MPLS L3VPN 出隧道 Pipe 和	
●qos phb enable 命令 ○trust 8021p 命令		

出接口配置（●表示配置，○表示不配置）	DSCP 值设置规则	说明
	Short-pipe 模式：DSCP 不变 ● MPLS L3VPN 出隧道 Uniform 模式：根据<Service-Class, color>和下行指定 DS 域反映射表进行设置。	对于 Pipe/Short-pipe 模式，MPLS L3VPN 入隧道 Ingress PE 节点上： ● 如果网络侧接口是 Type-C，可在网络侧接口配置带 vpn-mode 参数的 trust upstream 命令使 DSCP 保持不变。 ● 如果网络侧接口是 Type-B，可在网络侧配置 qos phb disable 命令使 DSCP 保持不变（配了此命令，从网络侧接口来的普通 IP 流量到用户侧接口时也无法做 PHB 反映射，所以这个方法只应用于纯 MPLS 流量，对于 MPLS 和 IP 混跑的网络侧接口没有完美的解决方案）。
● trust upstream 命令 ● trust 8021p 命令	● 下行单板为 Type-B ：根据<Service-Class, color>和下行指定 DS 域反映射表进行设置（如果是 L3VPN 出隧道的 Pipe 和 Short-pipe 模式时，DSCP 不变）。 ● 下行单板为其他类型：不变。	
● qos phb enable 命令 ● trust 8021p 命令	● MPLS L3VPN 入隧道：下行单板为 Type-B 和 Type-C 时，根据<Service-Class, color>和下行指定 DS 域反映射表进行设置；下行单板为其他类型时，DSCP 不变。 ● MPLS L3VPN 出隧道 Pipe 和 Short-pipe 模式：DSCP 不变 ● MPLS L3VPN 出隧道 Uniform 模式：下行单板为 Type-A 时 DSCP 不变；下行为其他单板时，根据<Service-Class, color>和下行指定 DS 域反映射表进行设置。	



说明

上述不考虑 802.1p 优先级的变化。如果要考虑 802.1p，需要根据实际需求和单板差异，灵活应用 **qos phb { disable | enable } vlan** 命令。

相关参考

- 如果报文同时携带了 DSCP、802.1p 和 MPLS EXP，用于做优先级映射的 QoS 优先级字段是哪个
- 报文哪些优先级字段会在反映射动作中被修改
- 新增 MPLS 头的 EXP 值设置

6.4 MPLS-TE

MPLS-TE 简介


MPLS-TE (Multiprotocol Label Switching-Traffic Engineering) 结合了 MPLS 技术与流量工程, 通过建立到达指定路径的 LSP (Label Switched Path) 隧道进行资源预留, 使网络流量绕开拥塞节点, 达到平衡网络流量的目的。

MPLS-TE 除了能携带流量参数进行资源预留, 提供端到端的带宽保证外, 还具有丰富的特性, 如显式路径, 优先级与抢占, 亲和属性, 快速重路由等, 丰富了 QoS 和可靠性解决方案。

MPLS-TE 的产生

传统的 IP 网络中, 节点选择最短的路径作为路由, 不考虑带宽等因素。这样, 容易出现流量集中于最短路径而出现拥塞。其他可选的路径则较为空闲。

图6-10 传统路由的困难




如图 6-10, 假设每个链路的 metric 值相同。R1 (R8) 到 R5 的最短路径为 R1 (R8) → R2 → R3 → R4 → R5, 尽管存在其他到达 R5 的路径, 数据转发也走 R1 (R8) → R2 → R3 → R4 → R5 这条最短路径。这样, 就可能出现一条链路 R1 (R8) → R2 → R3 → R4 → R5 过载而出现拥塞, 而另外一条链路 R1 (R8) → R2 → R6 → R7 → R4 → R5 空闲的情况。

为解决该问题, 传统的流量工程通常采取如下的方法:

- 通过调整路径 Metric 而控制网络流量

将 R2 → R3 → R4 段的 metric 值调整, 使其大于 R2 → R6 → R7 → R4 段的 metric 值。这样, 可以将流量引到链路 R1 (R8) → R2 → R6 → R7 → R4 → R5 上来。

图6-11 调整 Metric 值之后



这种解决方法解决了一条链路上的拥塞（R1（或 R8）→R2→R3→R4→R5），但是可能会引起另外的链路拥塞（R1（R8）→R2→R6→R7→R4→R5）。另外，在拓扑结构复杂的网络上，metric 值的调整比较困难，往往一条链路的改动会影响多个路由，难以把握和权衡。

- 采用叠加的网络模型，建立虚连接引导部分流量

现有的 IGP 协议都是拓扑驱动的，只考虑网络的连接情况，不能灵活反映带宽和流量特性这类动态状况。

解决 IGP 缺点的一种方法是使用重叠模型（Overlay），如 IP over ATM、IP over FR 等。重叠模型在网络的物理拓扑结构上提供一个虚拟拓扑结构，从而容易实现流量的合理调配和良好的 QoS 功能。然而，重叠模型的额外开销大，可扩展性差。

为了在大型骨干网络中部署流量工程，必须采用一种可扩展性好、简单的解决方案。MPLS（Multiprotocol Label Switching）作为一种叠加模型，可以方便地在物理的网络拓扑上建立一个虚拟的拓扑，然后将流量映射到这个拓扑上。因此，MPLS 与流量工程相结合的技术——MPLS TE（Traffic Engineering）应运而生。

MPLS TE 在解决网络拥塞问题有着自己的优势。通过 MPLS-TE，运营商可以精确地控制流量流经的路径，从而避开拥塞的节点，解决一部分路径过载而另一部分路径空闲的问题，充分利用现有的带宽资源。同时，MPLS-TE 在建立 LSP 隧道的过程中，可以预留资源，保证服务质量。

MPLS-TE 基本实现原理

- 信息发布

流量工程解决的是由于负载不均衡导致的拥塞，因此，除了网络的拓扑信息外，流量工程还需要知道网络的负载信息。为此，MPLS-TE 通过对现有的 IGP 进行扩展，在 IS-IS 协议中引入新的 TLV，在 OSPF 中引入新的 LSA，来发布链路状态信息，包括最大链路带宽、最大可预留带宽、当前预留带宽、链路颜色等 QoS 相关属性。

通过 IGP 扩展，在每个节点上，维护网络的链路属性和拓扑属性，形成流量工程数据库 TEDB（TE DataBase）。

- 路径选择

通过信息发布形成 TEDB 后，MPLS-TE 各节点掌握了网络的负载信息，接着，就需要从源到目的地址计算一条合适的路径。MPLS-TE 允许运营商在每个入口节点

上指定 LSP 隧道经过的路径，例如，可以指定必须经过某个节点，或者不经过某个节点，可以逐跳指定，也可以指定部分跳。此外，还可以指定带宽等约束条件。

接着，MPLS-TE 利用 TEDB 中的数据，使用基于约束的最短路径优先算法 CSPF（Constraint Shortest Path First）来计算满足指定约束的最短路径。

- **RSVP-TE 信令**

在获得从 LSP 的入口到 LSP 出口的最短路径后，MPLS-TE 使用扩展的 RSVP（Resource Reservation Protocol）信令——RSVP-TE 来动态地建立带约束的 LSP。带约束的 LSP 被称为 CR-LSP（Constraint-based Routed LSP）。


RSVP-TE 对 RSVP 扩展的内容主要有：

- 扩展了 PATH 消息和 RESV 消息：在 PATH 消息中引入 Label Request 对象，支持发起标签请求；在 RESV 消息中引入 Label 对象支持标签分配。这样就可以建立带约束的 LSP 了。
- 扩展的消息除了可以携带标签绑定信息外，还可以携带 LSP 的带宽、部分显式路由、颜色等约束参数，从而支持约束路由的功能。
- 此外，RSVP-TE 通过摘要刷新和 Hello 机制来维持资源预留状态，减少了维持 RSVP 软状态所需传输及处理的信息量，减轻了设备负担。

- **LSP 建立过程**

一条基于约束的 LSP 的过程如图 6-12。

图6-12 LSP 建立过程



- Ingress 使用 CSPF 计算从 Ingress 到 Egress 的满足一定约束参数（如带宽、部分显式路由、颜色等）的最短路径，并构造 PATH 消息。PATH 消息携带了约束参数。
- PATH 消息是从 Ingress 节点沿着 CSPF 计算的最短路径发送到 Egress 节点，途经的节点上根据 PATH 消息建立路径状态块 PSB（Path State Block）。
- 当 Egress 节点收到 PATH 消息时，将发送一个 RESV 消息作为回应。RESV 消息携带了资源预留信息，从 Egress 节点逐跳发送给前一跳节点。沿途的每跳会创建和维护资源预留状态块 RSB（Reserved State Block）并分配标签。
- 当 RESV 消息到达 Ingress 时，一条 LSP 就建立成功了。这样，数据流就可以沿着这条 LSP 基于标签进行转发。

MPLS-TE 丰富的特性


- **显式路径**

MPLS-TE 能够按照指定的路径建立 LSP，该路径称为显式路径。显式路径可以分为如下两种：

- 严格显式路径

所谓的严格显式路径，就是下一跳与前一跳必须直接相连。通过严格显式路径，可以最精确地控制 LSP 所经过的路径。

图6-13 严格显式路径




在图 6-13 中，LSRA 作为 LSP 的入节点，LSRF 作为出节点，从 LSRA 到 LSRF 用严格显式路径建立一条 LSP。“B strict”表示该 LSP 必须经过 LSRB，并且 LSRB 的前一跳是 LSRA，“C strict”表示该 LSP 必须经过 LSRC，并且 LSRC 的前一跳是 LSRB，依此类推，就可以精确控制该条 LSP 所经过的路径。

– 松散显式路径

松散方式可以指定路径上必须经过哪些节点，但是列出的节点之间可以有其他节点。

图6-14 松散显式路径



在图 6-14 中，从入节点 LSRA 到出节点 LSRF 用松散显式路径建立一条 LSP。“D loose”表示该 LSP 必须经过 LSRD，但是 LSRD 与 LSRA 之间可以存在其他节点，不必直接相连。

MPLS TE 信令能够携带显式路径及其严格或松散属性，按照指定的路径建立 LSP。

• LSP 优先级与抢占

MPLS-TE 在建立 LSP 的过程中, 如果无法找到满足所需带宽要求的路径, 则拆除另外一条已经建立的路径, 占用为它分配的带宽资源, 这种处理方式称为抢占 (Preemption)。抢占由 RSVP-TE 的 RESV 消息发起。

MPLS-TE 使用两个优先级属性来决定是否可以抢占: 建立优先级 (Setup Priority)、保持优先级 (Holding Priority)。每种优先级都有 8 个级别, 范围从 0 到 7, 7 为最低优先权。

优先级和抢占属性共同决定隧道之间的资源抢占关系。当多条 CR-LSP 需要建立时, 建立优先级高的 LSP 隧道优先占有资源、优先建立。当带宽等资源不够时, 保持优先级低的、已建成的 LSP 隧道的带宽资源可能被一个建立优先级高的并且资源不够的 LSP 隧道抢占。

例如, 当新建一条路径 Path1 时, 如果需要与已建立的路径 Path2 争夺资源, 只有当 Path1 的建立优先级高于 Path2 的保持优先级时, Path1 才能抢占成功。

为保证 LSP 能够正确建立, 同一条 LSP 的建立优先级不能高于保持优先级, 否则可能会导致 LSP 间无穷尽的互相抢占, 造成振荡。

- **链路管理组和亲和属性**

链路管理组是一个表示链路属性的 32 位向量。在 RFC3209 中, 链路管理组被称为链路属性 (Link-attr)。

亲和属性是一个 32 位向量, 表示链路的颜色。为隧道配置亲和属性后, 隧道选择链路时, 将亲和属性和链路的管理组属性进行比较, 决定选择还是避开某些属性的链路。MPLS-TE 使用一个 32 位的掩码表示需要比较的位, 比较的规则如下:

- 在所有掩码为 1 的位中, 管理组中至少有 1 位与亲和属性中的相应位都为 1; 且亲和属性为 0 的位, 对应的管理组属性位不能为 1。
举例说明: 假设亲和属性为 0x0000FFFF, 掩码为 0xFFFFFFFF, 则可用链路的管理组属性高 16 位只能取 0, 低 16 位至少有 1 位为 1。即, 可以使用的链路管理组属性取值范围是 0x00000001~0x0000FFFF。
- 对于掩码为 0 的位, 则不对管理组的相应位进行检查。
举例说明: 假设亲和属性为 0xFFFFFFFF, 掩码为 0xFFFF0000, 则可用链路的管理组属性高 16 位至少有 1 位为 1, 低 16 位则可以任意取 0 或 1, 即, 可以使用的管理组属性取值范围是 0x00010000~0xFFFFFFFF。

在 Ingress 节点配置隧道亲和属性后, 亲和属性将通过信令协议 (RSVP-TE) 传递给各节点。

- **Make-before-break**

Make-before-break 就是在原有路径被拆除前先建立新路径(也称为 Modify LSP), 在流量切换时尽可能不丢失数据、也不占用额外带宽的前提下改变 MPLS TE 隧道属性 (例如, 带宽和路径) 的机制。Make-before-break 是通过 SE 风格实现的。

新路径建立时, 可能会与原路径在某些共同链路上竞争带宽资源, 这会导致新路径竞争失败而无法建立。通过 Make-before-break 机制, 新路径需要预留的带宽不被重复计算, 即采用原路径使用的带宽。路径重合的地方不额外占用带宽, 路径不重合的地方还是额外占用带宽。

图6-15 Make-before-break




图 6-15 中，假设所有链路最大可预留带宽为 60Mbps。新建一条 R1 到 R4 的 CR-LSP，带宽为 40Mbps，路径是 R1→R2→R3→R4。

现在希望将路径改为 R1→R5→R3→R4，通过负载较轻的 R5 进行数据转发。但是 R3→R4 上剩余的可预留带宽只有 20Mbps，不足 40Mbps。这时可以通过 Make-before-break 机制来解决。

通过 Make-before-break，新建立的路径 R1→R5→R3→R4 在 R3→R4 上进行资源预留时采用原路径使用的带宽。新隧道建立成功后，流量转到新路径上后拆除原路径。

与此类似的是增加隧道的带宽，只要共用链路的可预留带宽满足增量要求，新的 CR-LSP 就可以建立成功。

仍以图 6-15 为例，假设所有链路最大可预留带宽为 60Mbps。新建一条 R1 到 R4 的 CR-LSP，带宽为 30Mbps，路径是 R1→R2→R3→R4。

现在希望将路径改为 R1→R5→R3→R4，通过负载较轻的 R5 进行数据转发，并将带宽增大为 40Mbps。但是 R3→R4 上剩余的可预留带宽只有 30Mbps，不足 40Mbps。这时可以通过 Make-before-break 机制来解决。

通过 Make-before-break，新建立的 CR-LSP 的路径 R1→R5→R3→R4 在 R3→R4 上进行资源预留时采用原路径使用的带宽，并追加增量带宽。新的 CR-LSP 建立成功后，流量转到新路径上后拆除原路径。

- **自动带宽调节**

LSP 在建立时可以根据 SLS/TCS 分配一定的带宽。在基于以往该 LSP 隧道上的流量统计的基础上，自动带宽分配技术允许对该隧道占用的带宽进行调节，这种调节不会影响当前通过隧道的流量。

通过定时（比如 5 分钟）的采样，可以获得通过该隧道在一个采样周期的平均带宽。通过在一段时间（比如 24 小时）的多次采样后，根据采样值统计平均值计算新带宽，发起建立一条带宽不同的隧道。建立成功后，将流量切换到新的 LSP 隧道上，同时拆除原来的 LSP 隧道；如果建立不成功，则流量继续走原来的 LSP 隧道，在下一个采样周期结束后再做下一次调节。

为了减少不必要的调节，可以配置调节阈值。只有本次的最大平均带宽与上次的最大平均带宽变化百分比达到一定的阈值，才发起调节。同时，还可以配置带宽的最小值和最大值，所调节的带宽必须在这个范围之内。

- **MPLS-TE 快速重路由 FRR**

为了保证服务的连续性，MPLS-TE 还引入路径备份和快速重路由 FRR（Fast ReRoute）的机制，可以在链路出现问题时及时进行切换。

MPLS-TE FRR 通过预先建立绕过故障的链路或者节点的旁路（Bypass）隧道达到保护主 LSP 的目的。当 LSP 链路或节点故障时，允许流量继续从旁路隧道传输，同时头节点可以在数据传输不受影响的同时继续发起主路径的重建。

MPLS-TE FRR 有两种保护机制，如图 6-16 和图 6-17：

图6-16 MPLS-TE FRR 链路保护





图6-17 MPLS-TE FRR 节点保护




- 链路保护：本地修复节点 PLR（Point of Local Repair）和汇聚点 MP（Merge Point）之间有直接链路连接，主 CR-LSP 经过这条链路。当这条链路失效时，流量可以切换到 Bypass CR-LSP 上。
- 节点保护：PLR 和 MP 之间存在节点，主 CR-LSP 经过该节点。当该节点失效或 PLR 和该节点之间的链路故障时，流量可以切换到 Bypass CR-LSP 上。

• CR-LSP 备份

对于重要的 LSP 隧道，需要进行备份。作为流量保护的一个重要组成部分，在主 CR-LSP 隧道失败后，流量需要及时被切换到备份隧道上。

同一条隧道下对主 CR-LSP 进行路径备份的 CR-LSP 称为备份 CR-LSP。当入节点感知到主 CR-LSP 不可用时，将流量切换到备份路径上，当主 CR-LSP 路径恢复后再将流量切换回来，以实现主 CR-LSP 路径的备份保护。

图6-18 CR-LSP 备份



CR-LSP 的备份方法:

- 热备份 (Hot-standby): 创建主 CR-LSP 后随即创建备份 CR-LSP。主 CR-LSP 失效时, 将业务切换至备份 CR-LSP。当主 CR-LSP 恢复时, 将业务切回到主 CR-LSP。
- 普通备份: 指主 CR-LSP 失效后创建备份 CR-LSP。主 CR-LSP 失效时, 将业务切换至备份 CR-LSP。当主 CR-LSP 恢复时, 将业务切回到主 CR-LSP。
- 逃生路径 (Best-effort path): 在主、备 CR-LSP 都故障时触发建立一条临时的 CR-LSP, 将流量切换到逃生路径上, 只是逃生路径没有带宽保证。

CR-LSP 备份属于端到端的隧道保护技术。


• 隧道保护组

隧道保护组是指用一个隧道 (备用隧道 Protection tunnel) 保护另一个隧道 (主隧道 Working tunnel), 主隧道和备用隧道形成一个保护组。

隧道保护组有以下几种保护模式:


- 1:1 保护模式: 每条主隧道都有自己的备用隧道, 正常情况下, 流量通过主隧道传输, 备用隧道上没有流量。主隧道故障时, 流量切换到备用隧道上。

图6-19 1:1 隧道保护模式



- N:1 保护模式: 将一条隧道作为多条主隧道的备用隧道, 当任何一条主隧道故障时, 将其流量倒换到共享的备用隧道上。

图6-20 N:1 隧道保护模式



同 CR-LSP 备份一样，隧道保护组也属于端到端的隧道保护技术。隧道保护组与 CR-LSP 备份的区别在于：

- 隧道保护组内的各隧道的属性没有联系，例如，带宽为 10Mbit/s 的保护隧道可以保护 100Mbit/s 带宽要求的主隧道。CR-LSP 备份中，除了 TE FRR 属性外，主、备 CR-LSP 的属性（例如带宽，建立优先级，保持优先级）一致。
- 隧道保护组使用一条隧道保护另一条隧道，而 CR-LSP 备份是在同一条隧道中创建主、备两条 CR-LSP，用备份 CR-LSP 保护主 CR-LSP。

6.5 MPLS DiffServ-Aware TE


MPLS DS-TE 的产生背景

- MPLS TE 的优点和不足

MPLS-TE 技术利用可用资源沿链路建立标签交换路径（LSP），从而确保始终为特定数据流提供有保证的带宽，以避免在稳定或故障情况下出现拥塞。MPLS-TE 可以精确控制流量流经的路径，从而使现有的带宽资源被充分利用。

MPLS-TE 的不足在于：无法基于每个流量类型提供有区别的 QoS 保证。例如，网络中有两类流量，分别为语音数据流和视频数据流。视频数据帧可能会出现长时间的重复，因此视频数据可能要求比语音数据具有更高的丢弃优先级。MPLS-TE 并不区分流量类型，而是将语音和视频流量都聚合在同一个丢弃优先级上。

图6-21 MPLS-TE 组网



- MPLS Diff-Serv 模型的优点和不足

MPLS Diff-Serv 模型对将客户的业务划分到不同的服务类型，然后针对不同的服务类型对流量进行转发，是一种可以满足多种 QoS 需求的服务模型。MPLS Diff-Serv 模型可以根据业务的不同服务等级，有差别地进行流量的控制和转发；将多

种业务的数据流映射到有限的几个类型，所需维护的信息量正比于数据流的类型，而不是数据流的数量，因此 MPLS Diff-Serv 可扩展性较好。

但是 MPLS Diff-Serv 模型只能在单个节点上预留资源，无法在整个路径上保证服务质量。


- MPLS Diff-Serv 和 MPLS-TE 同时使用的问题

有些应用场景中，单独使用 MPLS Diff-Serv 和 MPLS-TE，都不能满足要求。

例如，某条路径同时承载语音业务和数据业务。为保证语音业务的质量，需要降低语音流的总延迟。总延迟=设备处理延迟的总和+传输延迟的总和；设备处理延迟=转发延迟+队列延迟。当路径固定时，传输延迟的总和固定不变。因此要降低语音流的总延迟，需要降低语音流的在每一跳设备上的处理延迟的总和。拥塞情况下，报文越多，队列越长，转发延迟+队列延迟越大。所以需要限制每一条链路上语音流量不超过一定的比例。

如果对上述场景使用 MPLS Diff-Serv 模型，区分出业务的类型；再对每类业务使用单独的 MPLS-TE LSP 承载，则当网络发生链路/节点故障、网络拓扑变化或者 LSP 抢占，则链路上的语音流量仍可能超过一定比例，使语音业务的延迟得不到保证。


图6-22 同时部署 MPLS TE 和 MPLS Diff-Serv



如图 6-22，假设所有链路的带宽均为 100Mbit/s，且链路开销同。R1 到 R4、R2 到 R4 都有语音流，分别为 60Mbit/s 和 40Mbit/s。R1 到 R4 的语音通过 R1→R3→R4 的 TE LSP 传输，此时 R3→R4 链路上的语音流带宽百分比为 60%；R2 到 R4 的语音流通过 R2→R3→R7→R4 的 TE LSP 传输，此时 R7→R4 上的语音流带宽百分比为 40%。

如图 6-23，当 R3 和 R4 之间的链路故障时，R1 和 R4 之间的 LSP 路径改为 R1→R3→R7→R4，因为此路径是带宽足够的最短路径。此时，R6→R4 上的语音流带宽比为 100%，导致语音流的总延时过长。

图6-23 链路故障后



使用 MPLS DS-TE (DiffServ-Aware Traffic Engineering) 可解决以上问题。

什么是 MPLS DS-TE

MPLS DS-TE 是将 MPLS-TE 和 MPLS DiffServ 相结合的一种提供有效的 QoS 保证的技术。


为了使 MPLS-TE 能基于流量类型分配资源，提供差分服务，MPLS DS-TE 引入了 CT (Class Type) 的概念。MPLS DS-TE 将 LSP 的带宽划分为 1~8 个部分，每部分被赋予不同的服务等级。这样一条或一组 LSP 的相同服务等级的带宽集合称为一个 CT。这样就可以将具有相同 PHB 的流量映射到同一个 CT 上，并为每个 CT 单独分配资源。

如果一条 LSP 划分了多个 CT，同时承载不同服务等级的流量，这种 LSP 称为多 CT LSP。IETF 规定 DS-TE 最多支持 8 个 CT，可以记为 CT_i，其中 i 的取值范围是 0~7。

如果一条 LSP 只有一个 CT，则称该 LSP 为单 CT LSP。


对于图 6-22 描述的场景，可以使用多 CT LSP。R1→R4 的 VoIP 和 HSI 使用同一条 MPLS-TE 隧道的不同 CT 承载；R2→R4 的 VoIP 和 HSI 使用另一条 MPLS-TE 隧道的不同 CT 承载，这样，就可以维持各类流量的相对比例，使链路上语音流的带宽百分比控制在合理范围内，如图 6-24。

图6-24 MPLS DS-TE



当 R3→R4 链路故障，则 R1→R4 的 VoIP 和 HSI 同时切换到 R1→R3→R5→R6→R4，如图 6-25。这样，R1→R4 上的语音流带宽百分比依然可控制在合理范围内。

图6-25 链路故障后



MPLS DS-TE 实现原理

- DS-TE 对协议的扩展

MPLS DS-TE 的 LSP 是基于 CT 建立的。MPLS DS-TE 在路径计算过程中，将 CT 及每个 CT 可获得的带宽作为约束条件；在进行资源请求和预留过程中，也考虑 CT 及其带宽需求。为此，IEEE 对 IGP 和 RSVP 进行了扩展：

- RFC4124 对 IGP 进行了扩展，引入了新的可选子 TLV（Bandwidth Constraints sub-TLV），并重新定义了原有子 TLV（Unreserved bandwidth sub-TLV）的含

义，用于通告和收集链路上各优先级的每个 CT 的可预留带宽，详细描述请参见 RFC4124。

- 为了 RSVP 在资源请求和预留过程能携带 DS-TE 的 CT 信息，RFC4124 为 Path 消息定义了 CLASSTYPE 对象；IETF 草案（draft-minei-diffserv-te-multi-class）定义了 EXTENDED_CLASSTYPE 对象。关于 CLASSTYPE 和 EXTENDED_CLASSTYPE 对象的详细描述请参考 RFC4124 和 draft-minei-diffserv-te-multi-class。
- LSP 抢占与 TE-Class 映射

同 MPLS-TE 一样，DS-TE 中在建立 LSP 的过程中，如果无法找到满足所需带宽要求的路径，则拆除另外一条已经建立的路径，抢占为它分配的带宽资源。

DS-TE 也是使用两个优先级属性来决定是否可以进行抢占——建立优先级（setup-priority）和保持优先级（hold-priority），可统称为抢占优先级。抢占优先级的取值范围是 0~7，数值越小，优先级越高。

DS-TE 为每个 CT 指定一个抢占优先级，形成组合<CT,优先级>，称为 TE-Class，用于统一管理 LSP 抢占关系。

CT 和抢占优先级可以任意组合，因此理论上 TE-Class 共有 8*8=64 个。华为路由器最多支持 8 个 TE-Class 这 8 个 TE-Class 可以用 TE-Class[i]表示，其中 i 的取值范围是 0~7。一组 TE-Class 形成 TE-Class 映射表（Mapping）。华为路由器预先设置了缺省的 TE-Class 映射表，见下表。TE-Class 映射表允许运营商修改。

表6-3 缺省的 TE-Class 映射表

TE-Class	CT	优先级
TE-Class[0]	0	0
TE-Class[1]	1	0
TE-Class[2]	2	0
TE-Class[3]	3	0
TE-Class[4]	0	7
TE-Class[5]	1	7
TE-Class[6]	2	7
TE-Class[7]	3	7

DS-TE 规定：只有当一条 LSP 的 CT 和建立优先级的组合<CT, setup-priority>以及 CT 和保持优先级的组合<CT, hold-priority>同时存在于 TE-Class 映射表中，该 LSP 才能建立成功。

例如，假设某节点的 TE-Class 映射表中仅有 TE-Class[0]=<CT0, 6>和 TE-Class[1]=<CT0, 7>，则只有以下三类 LSP 能建立成功：

- Class-Type=CT0, setup-priority=6, hold-priority=6;
- Class-Type=CT0, setup-priority=7, hold-priority=6;
- Class-Type=CT0, setup-priority=7, hold-priority=7。


对于有带宽约束的 LSP 来说，在 Ingress 结点配置时需要考虑满足 TE-Class 映射表，其在沿途各节点预留资源时同样需要考虑满足 TE-Class 映射表，否则就不能建立成功，建议 MPLS 网络中所有的 LSR 都配置相同的 TE-Class 映射表。

- DS-TE LSP 的建立过程

DS-TE LSP 的建立同 MPLS-TE LSP 的建立过程类似，不同之处在于：

- RSVP 的 PATH 消息携带了 CT 信息。
- 当沿途的 LSR 收到带有 CT 信息的 PATH 消息，会检查<CT,优先级>组合是否在本地 TE-Class Mapping 中，且所有 CT 带宽是否满足。如果这两个条件都满足，则接受建立新的 LSP；
- LSP 建立成功后，各节点重新计算各优先级的每 CT 的可预留带宽。这些预留信息会反馈给 IGP，向网络中的其它节点通告。

图6-26 DS-TE LSP 建立过程




带宽约束模型

对于 MPLS DS-TE 隧道，存在几个与带宽相关的概念：

- 链路的实际带宽：隧道经过的实际链路的带宽，即接口速率，例如 GE 电接口的缺省速率为 1000Mbit/s，则表示其实际带宽为 1000Mbit/s。
- 链路最大可预留带宽：一条链路为所有经过它的 MPLS-TE 隧道所预留的带宽。链路最大可预留带宽不能大于链路的实际带宽。
- CT 带宽：每条 DS-TE 隧道中各类业务流量的带宽。
- BC_i 带宽：为经过该链路的所有 CT_i 预留的带宽（0 ≤ i ≤ 7）。BC 是链路上的带宽约束，而 CT 带宽则对应 DS-TE 隧道中各类业务流量的带宽约束。

图6-27 带宽相关的概念




带宽约束模型用来定义 BC 的最大数目和每个 BC 的带宽可被哪些 CT 使用，以及 CT 如何使用 BC 带宽。

目前，IETF 定义了如下几种带宽约束模型：

- MAM 模型

RFC4125 定义的最大分配模型 MAM (Maximum Allocation Model)：将一个 BC 映射到一个 CT，CT 间不共享带宽。

图6-28 MAM 模型示意图




$$\text{Max Reservable Bandwidth} \geq \text{BC0} + \text{BC1} + \text{BC2}$$

MAM 模型中，CT_i 所有 LSP 的带宽总和不超过 BC_i (0 ≤ i ≤ 7)；所有 CT 的所有 LSP 带宽总和不超过链路最大可预留带宽。

例如，假设某链路的带宽是 100Mbit/s，带宽模型为 MAM，且支持 3 个 CT (CT₀、CT₁ 和 CT₂)。BC₀ 为 20Mbit/s，用于承载 CT₀ (假设为 BE 流)；BC₁ 为 50Mbit/s，用于承载 CT₁ (假设为 AF 流)；BC₂ 为 30Mbit/s，用于承载 CT₂ (假设为 EF 流)。则承载 BE 流的所有 LSP 的带宽总和不能够超过 20Mbit/s；承载 AF 流的所有 LSP 的带宽总和不能够超过 50Mbit/s；承载 EF 流的所有 LSP 的带宽总和不能够超过 30Mbit/s。

图6-29 MAM 模型应用举例




MAM 模型优点是不存在 CT 间的带宽抢占，能全面隔离各个 CT；缺点是可能存在带宽浪费。

- RDM 模型

RFC4127 定义的俄罗斯套娃模型 RDM (Russian Dolls Model)：允许 CT 间共享带宽。

$BC0 \leq$ 链路的最大可预留带宽。各 BC 之间存在不同的包含关系，如图 6-30：BC2 的带宽固定不变；BC1 包含 BC2 的带宽；BC0 包含所有 BC 的带宽。这种模型与俄罗斯玩偶类似：一个大娃娃套一个小娃娃，小娃娃又套一个更小的娃娃，依此类推。

图6-30 RDM 模型示意图




俄罗斯套娃



例如，假设某链路的带宽是 100Mbit/s，带宽模型为 RDM，且支持 3 个 CT (CT0、CT1 和 CT2)。其中，CT0 用于承载 BE 流；CT1 用于承载 AF 流，CT2 用于承载 EF 流。BC0 为 100Mbit/s；BC1 为 50Mbit/s；BC2 为 20Mbit/s。那么承载 EF 流的所有 LSP 带宽总和不超过 20Mbit/s；承载 EF 流和 AF 流的所有 LSP 带宽总和不超过 50Mbit/s；所有 LSP 的带宽总和不超过 100Mbit/s。

图6-31 RDM 模型应用举例



RDM 模型允许存在 CT 间的带宽抢占。各 CT 的抢占关系是：如果 $0 \leq m < n \leq 7$, $0 \leq i < j \leq 7$, 则优先级为 m 的 CT_i 可以抢占优先级为 n 的 CT_i 的带宽和优先级为 n 的 CT_j 的带宽。但是 CT_i 的所有 LSP 带宽总和不超过 BC_i 的带宽值。

RDM 模型的优点是有效利用带宽，确定是不能隔离各个 CT，必须采用抢占机制以确保每个 CT 的带宽。

- Extended-MAM
扩展的最大分配模型 Extended-MAM：为了支持 E-LSP 而提出的一种带宽分配模式。
- Extended-MAM 与 MAM 的区别在于，Extended-MAM 比 MAM 模型多支持了 8 个隐式 TE-Class（CT0 和 8 个优先级的组合）。这 8 个隐式 CT 使用 IGP 的 Unreserved BW TLV 进行泛洪。

带宽约束模型的比较

RDM	MAM/Extended-MAM
将 BC 映射到一个或多个 CT，不直观	BC 与 CT 间一对一映射，易于理解和管理
无法分隔不同 CT，需要抢占以保证为 CT 提供足够带宽	可以分隔不同 CT 并为 CT 提供有保证的带宽，不存在抢占
有效带宽利用	可能造成带宽浪费
不建议在不允许抢占的网络中使用	适用于不允许抢占的网络

IETF 模式与 Non-IETF 模式

- 在按照 IETF 标准实现 DS-TE（称之为 IETF 模式 DS-TE）之前，华为路由器已经实现了自己的 DS-TE，称之为 Non-IETF 模式 DS-TE。
- IETF 模式：IETF 定义的模式，实现 8 个 CT 和 8 个优先级的组合，共 64 种 TE-Class。华为路由器上，可配置最多 8 个 TE-Class。

- **Non-IETF 模式：**非 IETF 定义的模式，实现两个 CT 和 8 个优先级的组合，共 16 种 TE-Class。这种模式的 MPLS-TE 隧道即普通的 MPLS-TE 隧道，仅支持这种模式的设备通常被称为非 DS-TE 设备。

不同 DS-TE 模式的设备互通

在实际网络部署或者设备版本升级中，可能出现仅支持 Non-IETF 模式 DS-TE 的设备与支持 IETF 模式 DS-TE 的设备共存。因此，在按照 IETF 标准实现 DS-TE 时保留了 Non-IETF 模式，使不同 DS-TE 模式的设备之间可以互通，目前支持如下情况的设备互通：

- **DS-TE 设备与非 DS-TE 设备互通：**
 - 支持从非 DS-TE 设备建立普通 TE 隧道至 DS-TE 设备；
 - 支持从 DS-TE 设备建立普通 TE 隧道至非 DS-TE 设备。
- 与其他厂商的不支持 CLASSTYPE 对象的 DS-TE 设备互通，可以解析携带如下 CT 信息的 Path 消息：
 - 由 EXTENDED_CLASSTYPE 对象携带 L-LSP 的 CT 信息；
 - 由 EXTENDED_CLASSTYPE 对象携带 CT0 信息。

DS-TE 模式切换

华为设备支持 Non-IETF 模式向 IETF 模式的切换，也支持 IETF 模式向 Non-IETF 模式的切换。模式切换的处理如下表所示。

比较项	Non-IETF 模式-->IETF 模式	IETF 模式-->Non-IETF 模式
带宽模型变化情况	带宽模型不变。	Extended-MAM-->MAM。
TE-Class 映射表变化情况	如果已配置 TE-Class 映射表，则使用配置的 TE-Class 映射表，否则采用缺省的 TE-Class 映射表。	不使用 TE-Class 映射表。 如果用户配置了 TE-Class 映射表，则不删除映射表； 如果用户没有配置 TE-Class 映射表，则删除缺省的 TE-Class 映射表。
LSP 删除情况	在 Ingress 节点和 Transit 节点删除<CT,set-priority>组合和<CT,hold-priority>组合不在 TE-Class 映射表中的 LSP。	在 Ingress 节点和 Transit 节点删除以下类型的 LSP： • 多 CT LSP； • CT2~CT7 的单 CT LSP。

IETF 模式和 Non-IETF 模式的区别

比较项	Non-IETF 模式	IETF 模式
带宽模型	支持 MAM 和 RDM	支持 RDM、MAM 和 Extended MAM
CT 类型	支持 CT0 和 CT1，CT 配置为单 CT，允许的其中一种 CT	支持 CT0~CT7，CT 配置为多 CT，支持 8 种 CT 类型同时配置
BC 类型	支持 BC0 和 BC1	支持 BC0~BC7
TE-Class 映射表	可以配置 TE-Class 映射表，但不生效。仅用于 Non-IETF 模式向 IETF 模式切换时保证已经建立好的 LSP 的 CT 落在某个 TE-Class 中，使 LSP 不被删除。	支持配置和使用 TE-Class 映射表
IGP 消息	由 Unreserved bandwidth sub-TLV 携带基于优先级的可预留带宽	同时由 Unreserved bandwidth sub-TLV 和 Bandwidth Constraints sub-TLV 携带 CT 信息
RSVP 消息	由 ADSPEC 对象携带 CT 信息	- 单 CT：由 CLASSTYPE 对象携带 CT 信息； - 多 CT：由 EXTENDED_CLASSTYPE 对象携带 CT 信息

DS-TE 隧道保护机制

DS-TE 是将 MPLS-TE 和 MPLS DiffServ 相结合的一种技术，因此 DS-TE 可继承 MPLS-TE 的隧道保护机制。MPLS-TE 有三种隧道保护机制：

- TE FRR
- CR-LSP 备份
- 隧道保护组

这三种隧道保护机制详细介绍请参见本文“6.4 MPLS-TE”。下面介绍 DS-TE 对这三种隧道保护机制的扩展实现。

表6-4 DS-TE 对三种隧道保护机制的扩展实现

保护方式	DS-TE 的扩展实现
TE FRR	分为两种情况： • 需要带宽保护：手工 FRR 通过手工配

保护方式	DS-TE 的扩展实现
	置 Bypass 隧道的 CT 及其带宽来保证业务的 QoS，支持 1:1 保护和 N:1 保护；Auto FRR 则通过 Bypass 隧道继承主隧道的 CT 及带宽来保证业务的 QoS，只支持 1:1 保护，不支持 N:1 保护。 不需要带宽保护：不考虑 Bypass 隧道的 CT 及其带宽，不论手工 FRR 还是 Auto FRR，都支持 1:1 保护和 N:1 保护。
CR-LSP 备份	备份隧道从主隧道继承 CT 类型及其带宽。逃生路径不保证 QoS，因此不继承主隧道的 CT 类型及其带宽。
隧道保护组	隧道保护组将两条独立配置的隧道进行绑定，使两条隧道形成主备关系。因此，备份隧道的 DS-TE 特性由配置决定。为保证业务的 QoS，备份隧道的 CT 类型及其带宽应该与主隧道相同。 另外，MPLS OAM 的检测报文通过 TE 隧道优先级最高的队列发送。

同 MPLS-TE 一样，实际网络部署时，可以单独使用一种 DS-TE 隧道保护机制，也可以将多种 DS-TE 保护方式配合使用。

DS-TE 中每跳的 QoS 机制

DS-TE 是将 MPLS-TE 和 MPLS DiffServ 相结合的一种技术，DS-TE 实现 DiffServ 并没有使用新的报文字段来承载 DiffServ 信息，以实现流分类，而是继承 MPLS DiffServ 的流分类方法。MPLS DiffServ 的流分类方法有两种：E-LSP 和 L-LSP。华为路由器目前只实现 E-LSP，因此 MPLS DS-TE 采用的是 E-LSP——将调度类型和丢弃优先级都由 MPLS 标签的 EXP 字段表示。

本章节的前文介绍过，MPLS DS-TE 将 LSP 的带宽划分为 1~8 个 CT，将具有相同 PHB 的流量映射到同一个 CT 上，并为每个 CT 单独分配资源。而 PHB 在设备内部体现为队列调度类型和丢弃优先级，因此，需要将 CT 与队列关联起来。

华为路由器上有 2 种实体队列——8 个 CQ 队列（或称为端口队列）和 8 个 FQ 队列，刚好与 8 个 CT 形成一一对应关系。华为路由器已预先设置了默认的 CT 和 CQ/FQ 队列的映射关系模板，见下表，并允许用户创建 8 个映射关系模板（包括一个默认的映射模板）。

表6-5 默认的 CT 与 FQ/CQ 队列的映射表

CT 类型	队列	调度方式
-------	----	------


CT 类型	队列	调度方式
CT7	CS7	PQ
CT6	CS6	PQ
CT5	EF	WFQ
CT4	AF4	WFQ
CT3	AF3	WFQ
CT2	AF2	WFQ
CT1	AF1	WFQ
CT0	BE	LPQ

除了 CT 和 CQ/FQ 队列的映射外，DS-TE 在流量分类、流量整形、流量监管、拥塞避免等 QoS 实现方法与 MPLS DiffServ 中的完全相同，此处不再赘述。

MPLS DS-TE 典型组网应用

- DS-TE 应用场景 1：同一 VPN 不同业务接入
在使用 MPLS TE 作为隧道的 VPN 环境中，同一个 VPN 可能同时承载 EF（Expedited Forwarding）、AF（Assured Forwarding）及 BE（Best-Effort）业务。这意味着同一条隧道需要同时承载不同类型的业务。
为了防止同一条隧道中的不同业务之间相互干扰，可以创建多个 VPN 和 TE 隧道，不同的隧道承载不同的业务。但如果网络上存在多个 VPN 同时承载多种业务，则需要创建大量的 VPN 和隧道，造成资源浪费。
另一种方案是部署 DS-TE，使用一条多 CT 类型的 LSP 承载一个 VPN 的业务。一条多 CT LSP 可以预留多达 8 个 CT，每个 CT 对应一个 VPN 的一种业务，且业务之间互不干扰。
例如图 6-32，VPN1 同时接入三种业务：BE、AF 和 EF。只需要创建一条 TE 隧道，该隧道上配置 CT0（带宽 100Mbps）、CT1（带宽 50Mbps）、和 CT2（带宽 10Mbps），然后在 Ingress 节点上将 VPN1 与隧道绑定，VPN1 的所有流量经过分类后进入对应 CT 的队列进行处理。

图6-32 同一 VPN 不同业务接入同一条 LSP 组网



- DS-TE 应用场景 2：不同 VPN 接入

在使用 MPLS TE 作为隧道的 VPN 环境中，可能存在多个 VPN 共用一条 TE 隧道的情况。这些 VPN 有着不同的 QoS 需求，会导致 VPN 之间竞争资源，使得 VPN 各个业务的 QoS 要求得不到保证。上述场景分为三种情况，下面对每种情况描述其解决方案：

- 不同 VPN，业务类型完全不同

这种情况下，只要所有 VPN 的业务数的总和不超过 8，则可以使用一条 TE 隧道承载。

例如 VPN1 和 VPN2 同时接入。VPN 的业务有 EF、BE 类型，VPN2 的业务为 AF 类型，则只需建立一条 TE 隧道，为每个 VPN 的不同业务配置不同 CT。CT 的个数为 VPN1 的业务数量+VPN2 的业务数量=3。

- 不同 VPN，业务类型完全相同

这种情况下，所需 TE 的隧道数目为 VPN 的数目。每个隧道上所需的 CT 数等于对应 VPN 的业务数。

例如 VPN1 和 VPN2 同时接入。VPN 的业务有 EF、BE 类型，VPN2 的业务也是 EF、BE 类型，则需要建立两条 TE 隧道，不同 VPN 使用不同隧道。每个隧道上再为不同业务类型配置不同 CT。

- 不同 VPN，业务类型部分相同

这种情况下，也需要为每个 VPN 建立一个隧道。每个隧道上所需的 CT 数等于对应 VPN 的业务数。

- DS-TE 应用场景 3：VPN 与非 VPN 流量同时接入


VPN 网络中同时存在 VPN 与非 VPN 流量，且各自有着不同的 QoS 需求。如果使用同一条 TE 隧道承载，则可能导致 VPN 与非 VPN 流量之间竞争资源，使得各类业务的 QoS 要求得不到保证。

此场景分为三种情况，下面对每种情况描述其解决方案：

- 不同 VPN，业务类型完全不同

这种情况下，可以使用一条 TE 隧道承载。为 VPN 和非 VPN 的各类业务配置不同 CT。CT 的个数为 VPN 的业务数量+非 VPN 的业务数量，如图 6-33。


图6-33 VPN 与非 VPN 业务接入同一条隧道组网



- 不同 VPN，业务类型完全相同

这种情况下，需要建立两条隧道，VPN 和非 VPN 业务分别使用一条隧道。每个隧道上为不同业务类型配置不同 CT，如图 6-34。

图6-34 VPN 与非 VPN 业务分别接入不同隧道组网



- 不同 VPN，业务类型部分相同

这种情况下，需要建立两条隧道，VPN 和非 VPN 业务分别使用一条隧道。每个隧道上为不同业务类型配置不同 CT，如图 6-34。

6.6 MPLS VPN QoS


MPLS VPN 对 QoS 的需求

MPLS VPN 由于在灵活性、扩展性和 QoS 方面的优势，逐渐成为最主要的 VPN 技术，在电信运营网和企业网中都获得了广泛的应用，主要集中在如下两方面：

- 企业互联：即企业总部、分支机构和出差员工通过 VPN 技术进行安全、可靠的通信。
- 业务隔离：在一个物理基础网络上承载多种业务（如大客户互连、3G、NGN 业务），为了保证每个业务的独立运营，采用 VPN 相互隔离。

因此，VPN 用户需要的是一种端到端的 QoS 保证。用户对于运营商提供的 VPN 业务寄以很高的期望，希望能达到物理专线，或是 ATM PVC 的 QoS 效果。PE-CE 之间的 QoS 是用户自己的网络来保证的，因此对于 MPLS VPN 运营商而言，要实现的是 PE 之间对于 VPN 流量的 QoS 保证。

图6-35 MPLS VPN 的 QoS 需求



MPLS QoS 解决方案

由于 MPLS VPN 网络是 Internet 用户及多个 VPN 用户共享的公共网络资源，VPN 之间、Internet 用户与 VPN 之间都存在资源竞争。如果通过普通的 DiffServ 模型，只能在单个节点上预留资源，难以实现 VPN 要求的 PE 之间端到端 QoS 保证。

现有的解决方案有：

- 方案一：LDP LSP/Static LSP+MPLS HQoS
- 方案二：MPLS-TE+MPLS HQoS
- 方案三：CE-CE 专用 MPLS-TE 隧道（隧道绑定 VPN）+MPLS HQoS
- 方案四：MPLS Diffserv+专用 MPLS-TE+资源隔离 VPN
- 方案五：MPLS DS-TE

方案一：LDP LSP/Static LSP+MPLS HQoS

适用场景：MPLS VPN 使用静态 LSP，LDP LSP 或没有带宽保证的 TE 隧道，PE 节点支持 MPLS HQoS。仅适用于支持 MPLS HQoS 的版本。

由于静态 LSP，LDP LSP 或没有带宽保证的 TE 隧道并不在其转发路径上预留资源，无法保证端到端的 QoS 业务。如果 MPLS VPN 使用这些隧道时，一般采用 MPLS HQoS 方案实现端到端 VPN QoS。

先在 PE 间建立 LDP LSP 或 Static LSP；VPN 流量进入 PE 时，或者预先设置了优先级，或者由 PE 设置优先级；进入 MPLS 域后，根据优先级在每一跳上进行 QoS 处理。

图6-36 使用 MPLS Diffserv+HQoS 实现 VPN QoS





图6-37 方案一 HQoS 调度模型



方案一实现简单，但存在以下问题：

- 使用 MPLS HQoS 仅能在入口 PE 上区分 VPN 和各 VPN 中的业务类型，在 P 节点和出口 PE 上都无法区分出不同 VPN 的流量，也不能实现基于 VPN 流量的 HQoS，只能区分不同优先级的业务流。
- 每一跳上为某个优先级分配的资源是被多个业务流共享的，包括 VPN 业务流，也包括非 VPN 业务流（如公网的 Internet 业务流），它们之间存在着竞争。由于 Internet 流量具有突发性的特点，如果按照高峰流量分配带宽，存在极大的资源浪费，如果按照平均流量分配带宽，则无法避免某个业务流在拥塞时发生丢包；
- 业务流经过多个链路，虽然这些链路上都为优先级分配了带宽，但可能存在不匹配的情况，有些链路带宽是足够的，而有些链路可能不够，这就无法保证端到端的 QoS。
- 此外，对于 LDP LSP，如果配置了 LDP FRR，当主 LDP LSP 故障时，会引起多个 VPN 流量从主 LDP LSP 同时切换到备 LDP LSP 上。切换到备 LDP LSP 后，目前入口 PE 基于 VPN 流量的 HQoS 功能失效；当主 LDP LSP 故障恢复，流量回切后，入口 PE 恢复基于 VPN 流量的 HQoS 功能。

方案二：MPLS-TE+MPLS HQoS


适用场景：MPLS VPN 使用 MPLS-TE 隧道，PE 节点支持 MPLS HQoS。仅适用于支持 MPLS HQoS 的版本。

在方案一中，VPN 业务流经过的每个链路上，不同 VPN 之间，以及 VPN 和非 VPN 业务之间都可能存在资源竞争。为解决此问题，可将方案一中的 VPN 隧道类型换成 MPLS-TE。

MPLS-TE 隧道可以保证去往某个对端 PE 的所有 VPN 流量的总带宽。VPN 流量进入 MPLS-TE 后，再在入口 PE 节点上通过 MPLS HQoS 区分 VPN 和各 VPN 的业务类型。

与方案一不同的是，该方案使用的是 MPLS-TE 隧道，缺省情况下 MPLS-TE 隧道承载的流量为一个用户组；并且，通过 TE 隧道已经区分了对端 PE，无需再区分对端 PE。因此，HQoS 模型改为如图 6-38。

图6-38 方案二的 HQoS 调度模型



**说明**

当然也可以根据需要，使用方案一的 HQoS 调度模型，这样就不是使用默认情况——基于 TE Tunnel 进行用户组队列调度。

这样，在隧道入口将所有接入隧道的 VPN 的总带宽限制在隧道可预留带宽之下，隧道的下游各节点就不会存在竞争了。

对隧道保护的附加说明：

VPN 所选定的 MPLS-TE 隧道在属性改变时，会采用 make-before-break 机制重建 CR-LSP：

- MPLS-TE 隧道带宽被修改时，触发重建 CR-LSP，如果修改后的隧道带宽小于 VPN 带宽，VPN 将选择其他符合条件的 MPLS-TE 隧道；如果修改后的隧道带宽依然大于或者等于 VPN 带宽，VPN 将选择原 MPLS-TE 隧道新建的 CR-LSP。
- MPLS-TE 隧道的显式路径被修改时，触发重建 CR-LSP，如修改后的显式路径不满足 MPLS-TE 要求，MPLS-TE 仍然选择原显式路径进行转发，如果满足要求，则切换到新的显式路径上进行转发。无论是否切换，VPN 仍选择该 MPLS-TE 隧道进行转发，而不是其他符合条件的 MPLS-TE 隧道。

如果 VPN 所选定的 MPLS-TE 隧道配置了 CR-LSP 热备份（Hot-standby），当隧道主 CR-LSP 故障时，触发重建 CR-LSP，VPN 流量切换到备份 CR-LSP 上，此时可以对 VPN 流量实现基于 VPN 的带宽保证、流量整形、队列调度等 QoS 功能。

如果 VPN 所选定的 MPLS-TE 隧道配置了 Hot-standby 和逃生路径，当隧道主 CR-LSP 和备份 CR-LSP 同时故障时，VPN 流量切换到逃生路径上，此时基于 VPN 的带宽保证和流量限制在公网侧将不再生效；隧道故障恢复后，基于 VPN 的带宽保证和流量限制在公网侧会重新生效。


如果 VPN 所选定的 MPLS-TE 隧道配置的保护机制是 CR-LSP 普通备份（非 Hot-standby）、TE FRR、隧道保护组，则目前无法实现基于 VPN 的带宽保证、流量整形、队列调度等 QoS 功能。

方案三：CE-CE 专用 MPLS-TE 隧道（隧道绑定 VPN）+MPLS HQoS

适用场景：MPLS VPN 使用专用 MPLS-TE 隧道，PE 节点支持 MPLS HQoS。仅适用于支持 MPLS HQoS 的版本。

为每一对 CE-CE 连接建立专用的 MPLS-TE 隧道，将隧道和特定的某个 VPN 应用绑定，使该 VPN 到指定对端的流量固定地从专用的隧道传输。被绑定的隧道只承载特定的一个 VPN 业务，不再承载其他 VPN 业务。这个 MPLS-TE 隧道有带宽保证，两端的 PE-CE 链路是专用的，因此保证了端到端的带宽。

图6-39 CE-CE 专用 MPLS-TE 隧道



为了在隧道中区分优先级，在入口 PE 上使用 MPLS HQoS 区分 VPN 和各 VPN 中的业务类型，HQoS 模型请参见如图 6-38。

这种方式的缺点是在隧道中各种业务流量是不分优先级的，因此隧道内一旦发生实际流量超出预约流量的情况，对 QoS 敏感的业务将直接受到影响。此外，这种方式可扩展性差，由于没有采用隧道复用技术，隧道的数目与 CE 的平方成正比，在骨干网中需要大量的隧道。MPLS-TE 需要有信令协议定时刷新整个隧道上的资源预留状态，消耗资源比较大。


方案四：MPLS Diffserv+专用 MPLS-TE+资源隔离 VPN

适用场景：MPLS VPN 使用 MPLS-TE 隧道，且 VPN 内部区分业务类型。此方案仅适用于支持资源隔离 VPN 的部分版本，如 NE40EV300R003。

如上文所述，如果 MPLS VPN 仅使用专用 MPLS-TE 时，隧道的数目与 CE 的平方成正比，在骨干网中需要大量的隧道。如果不采用专用隧道，那么同一个 TE 隧道又可能被多个 VPN 共享，当各 VPN 竞争资源时必将导致 QoS 的下降，如一个 VPN 遭受攻击，就会影响其它 VPN 的正常通信。

为解决此矛盾，可采用专用 MPLS-TE 隧道+资源隔离 VPN 的方案：

图6-40 专用 MPLS-TE+资源隔离 VPN



- 在隧道入口 PE 节点进行简单流分类/复杂流分类，或指定 MPLS Diffserv 模式为 Uniform、Pipe 或 Short pipe；
- 使用专用 MPLS-TE 隧道，将隧道和特定的某个或某些 VPN 应用绑定，使 VPN 到指定对端 PE 的流量固定地从专用的隧道传输；
- 对专用 MPLS-TE 隧道应用资源隔离 VPN 技术。资源隔离 VPN 技术采用隧道复用技术，且该技术本身具备了流量监管（CAR）和 HQoS 功能，可以在 TE 隧道的入口对每个 VPN 进入 MPLS TE 隧道的流量进行监管，同时也可以对该 VPN 的各类业务做流量监管。

这样，在隧道入口将所有接入隧道的 VPN 的总带宽限制在隧道可预留带宽之下，隧道的下游各节点就不会存在竞争了。

方案五：MPLS DS-TE

适用场景：仅适用于支持 MPLS DS-TE 的版本。

请参见“MPLS DiffServ-Aware TE”章节中的“[MPLS DS-TE 典型组网应用](#)”。

6.7 单板实现差异

6.7.1 MPLS DiffServ 实现差异

前面章节介绍的单板实现差异，同样适用于 MPLS DiffServ 场景。

章节	链接
流分类和标记	6.7 单板实现差异
流量监管和流量整形	4.4.1 流量监管和整形的单板实现差异
拥塞管理和避免	5.6 单板实现差异

章节	链接
MPLS QoS	6.3 MPLS DiffServ 配置解析

7 ATM QoS

关于本章

7.1 ATM QoS 概述

7.2 ATMoPSN 及 PSNoATM 的 QoS

7.1 ATM QoS 概述

什么是 ATM


ATM（Asynchronous Transfer Mode）技术是一种以信元为单位的异步转移模式。

ATM 综合了电路交换和分组交换的特点：ATM 是面向连接的，即任何一个 ATM 终端用户在与另一用户通信时都需要建立连接；另一方面 ATM 传输采用了固定长的信元，因而其又具有分组交换的特点，使各连接可以共享带宽资源。

ATM 的统计复用

ATM 对网络资源进行统计复用，实现了对任何形式的业务分布都能达到最佳的网络资源利用率。所谓统计复用就是根据各种业务的统计特性，在保证业务质量要求的前提下，在各业务间动态地分配网络资源，以达到最佳的资源利用率。从而 ATM 网络可以支持多速率、多业务，可以支持语音、数据、图像的传递，对实时业务提供完全的 QoS 保证。

图7-1 ATM 统计复用




如图 7-1，假设每个链路的 metric 值相同。R1（R8）到 R5 的最短路径为 R1（R8）→ R2→R3→R4→R5，尽管存在其他到达 R5 的路径，数据转发也走 R1（，用户 D、C、A 的数据按到达的先后顺序排列到输出线路上，而用户 B 因为此时没有数据，故不占用输出线路的带宽资源，从这个意义上说，ATM 连接是一个虚连接。

ATM 虚连接

类似于电话呼叫接续过程，ATM 网络在通信前必须在源和目的端之间建立连接，该连接是虚连接，称为 VCC（Virtual Circuit Connection），用 VPI/VCI 来标识。

从路由的角度看，VPI/VCI 是信元在 ATM 网络中传输的路由地址，多个路由地址形成了一条连接并且标识一条连接。当交换节点接收到信元时，根据信元头中的 VPI/VCI 查找映射表，确定输出的 VPI/VCI。

图7-2 ATM 虚连接



ATM 交换分为虚通路 VP（Virtual Path）交换和 VC（Virtual Circuit）交换两种。VP 交换就是指在交换的过程中只改变 VPI 的值，透传 VCI 的值；而 VC 交换过程中 VPI、VCI 都改变。因此，VP 相当于一个大的管道，而 VC 相当于一个小的管道。虚通路与虚通道的关系如图 7-3。

图7-3 虚通路 VP 与虚通道 VC



ATM 信元的复用、交换和传输过程，均在 VC 上进行。

PVC 与 SVC

ATM 通过 VC 建立连接有两种方式：

- 交换虚通路 SVC (Switched VC)：用户需要通信时，通过终端设备由信令建立的虚通路。SVC 类似于电话网的用户线路，只有经过呼叫请求，网络为通信双方建立起相应虚通路后，才能进行通信。通信完成后，由信令释放 SVC。使用 SVC 的用户对网络资源的利用率高，通信费用较低。
- 永久虚通路 PVC (Permanent VC)：通过管理员静态配置的，一旦连接就不会自动释放。PVC 类似于电话网中的租用线路，经过 PVC 连接的用户需要通信时，不会因通信网络资源不够而导致通信失败。PVC 适合一直使用有高级需求的连接。

现在 ATM 网中基本上都是使用 PVC。

ATM 网络拥塞管理的重要性

与电路交换网或分组交换网相比，ATM 网络的拥塞管理既重要又困难。

- 重要性体现在：ATM 是一种异步时分、统计型复用的信息传送方式，而统计复用能提高网络资源利用率、增强灵活性的同时不可避免地增加了引起网络拥塞的风险。
- 困难表现在两个方面：
 - ATM 网中传送的是各种类型的业务信息综合而成的数据流，其流量特性十分复杂难于控制；
 - 由于 ATM 网络传输速率高，一旦某处发生拥塞而不能及时解决，拥塞范围将迅速扩大。

由此可见，ATM 网的拥塞管理是个重要问题。

网络拥塞管理的基本思想

为了满足 ATM 网中拥塞管理的要求，ITU-T 提出了一套新的拥塞控制机制。其基本思想在于：引入预防性控制措施，不再是出现拥塞之后再采取措施来消除拥塞，而是通过精心管理网络资源而避免拥塞的出现。

拥塞管理的功能分成两个层次：

- 第一层是预防性措施，称为**流量控制**（Traffic Control），是为防止网络出现拥塞而采取的一系列措施，包括流量合同的确定、连接允许控制、流量参数控制等；
- 第二层是反应性措施，称为**拥塞控制**（Congestion Control），是当网络出现拥塞后为将拥塞的强度、影响范围、持续时间减到最小而采取的一系列措施，包括信元选择性丢弃与拥塞指示等。

流量控制

ATM 流量控制是针对不同的业务和业务质量来进行的，因此业务类型和不同的业务质量是流量控制制定的基础。


ATM Forum 对业务进行了分类，分为 CBR、rt-VBR、nrt-VBR、ABR、UBR，这些业务分类主要以速率为基础。这些业务类型将在本章后面的“[ATM 业务类型](#)”一节中详细介绍。

除了以速率来表征业务，ATM Forum 还制定了流量参数和 QoS 参数来衡量 ATM 业务质量。流量参数和 QoS 参数通过虚连接建立前，用户与网络之间，或网络与网络之间共同协商，形成流量合同。

流量合同参数

当用户与网络，或网络与网络建立一个虚连接的时候，双方就确定了一份流量合同，类似于 IP 网络的 SLA。

图7-4 ATM 流量合同



流量合同，包括：流量参数，QoS参数

ATM 流量合同包括流量参数和 QoS 参数两部分。

• 流量参数

有些流量参数用于描述业务本身的流量特性，又称为源流量参数，包括：

- PCR（Peak Cell Rate）：峰值信元速率，指业务提供者所能保证的虚电路的最大带宽。超过这一速率发送的信元将被 ATM 入口节点丢弃或加上可以丢弃的标志。带有可丢弃标志的 ATM 信元可能会被网络中任何遇到阻塞的节点丢弃。对于 CBR 业务来说，这一参数代表虚电路保证达到的恒定带宽。
- SCR（Sustain Cell Rate）：可持续信元速率，定义了信元有效通过一条电路的持续平均速率。仅适于 VBR 业务。

- MCR (Minimum Cell Rate): 最小信元速率。用户发送到网络的信元速率不能小于该值。
- MBS (Maximum Burst Size): 最大突发度, 规定了在 PCR 速率下且仍然满足业务合同要求所能传输的最大信元数量。仅适于 VBR 业务。突发度 BS 是业务的峰值比特率与平均比特率之比。所以突发度越大, 表明业务的速度变化越大。

另一些业务特性参数并不表示业务本身的流量特性, 而是体现业务对时间特性的要求, 例如 CDVT (Cell Delay Variance Tolerance), 表示信元时延抖动容限, 规定了两个端站之间信元时延偏差 CDV 的最大允许容限。适于实时性业务。

- **QoS 参数**

QoS 参数主要包括:

- peak-to-peak CDV (peak-to-peak Cell Delay Variance): 峰峰信元时延抖动。
- MCTD (Maximum Cell Transfer Delay): 最大信元传递时延。信元传递时延是指信元的第一个比特离开发送站点的时间和信元的最后一个比特到达接收站点的时间之差。这对于恒定比特速率的应用是一个重要的数值, 因为如果信元穿越网络耗时过长, 就会被接收站点判定为丢失或发生延误, 重新组装的整个包也将被丢弃。这将影响语音或话音的质量。
- CLR (Cell Loss Rate): 信元丢失率, 是指传输过程中丢失的信元数量与所传输的全部信元数量之比。信元可能因为以下原因而无法到达目的地:
 - 1) 目的地错误
 - 2) ATM 节点严重阻塞
 - 3) 发送站点的突发流量超过流量合同限度造成信元丢弃
 - 4) 信元传送耗时过长, 超过 MCTD, 到达太晚而无法处理。

连接准许控制 CAC

用户向网络发出呼叫请求时需要向网络提交即将发送的流量特性以及对服务质量的要求。

当网络收到呼叫请求后首先启动 CAC (Call Admission Control) 功能, 检测当前网络资源的分配与占用情况, 对照用户呼叫请求中提交的流量特性与服务质量要求, 确定当前可供使用的网络资源能否满足用户要求。

如果能够满足要求, 并在建立新虚电路连接的同时仍能保证已有连接的服务质量, 则网络将接纳这一呼叫并建立相应的虚电路, 否则拒绝用户的请求。

流量参数控制

虚电路成功建立后, 在通信过程中, 用户实际输入网络的流量特性可能超越 CAC 功能执行过程中所确定的值, 对这种情况需要加以限制否则将影响网络的服务质量。为此在用户 / 网络接口设立了流量监测与限制机制, 以确保每条虚电路中实际入网的流量特性参数符合流量合同的协商值, 这一机制即是流量参数控制功能。

目前流量参数控制的限制措施主要是对属于超越协商值的那部分流量的信元打上标记, 表示这部分信元的服务质量不能保证, 一旦网络发生拥塞首先丢弃这类信元。


拥塞控制

ATM 网一旦检测到出现拥塞状况，则启动拥塞控制功能，首先是有选择地丢弃掉重要程度相对低的信元以缓解拥塞，同时进行拥塞状态信息的前向、反向指示。当这些措施仍不能很好地控制住拥塞时，网络将进行释放连接或重选路由。

- 信元选择性丢弃

ATM 网中传送的信元有两种优先级别，通过信元头中的 CLP（Cell Loss Priority）位来区分。CLP=0 表示优先级高，CLP=1 表示优先级低。当网络发生拥塞时首先选择 CLP=1 的信元丢弃以缓解拥塞。

图7-5 ATM 信元结构



CLP=1 的信元有两个来源，一是由用户产生，说明此信元所承载的信息属于低优先级，二是 UPC/NPC 将某些 CLP=0 的信元改成 CLP=1，说明此信元属于超越协定值的流量部分。实际上 ATM 网拥塞时就是牺牲掉这些信元来保证高优先级信元的传送质量。

- 拥塞信息指示

选择性信元丢弃是在网络发生拥塞的地点进行的，在有些情况下仅仅依靠这一处采取措施不足以控制拥塞，而要求整个网络协调行动，这就要求某处发生拥塞后能及时地将拥塞信息传递给网络的其它部分，以便采取措施协助对拥塞的控制。拥塞信息指示根据方向可分成前向拥塞指示 EFCI（Explicit Forward Congestion Indication）与反馈拥塞指示。

前向拥塞指示的过程：

- 源端发出 EFCI=0 的信元；
- 若信元经过路径上的 ATM 节点发生拥塞，置 EFCI=1；
- 目的端检测到 EFCI=1 的信元时，在发往源端的后向信元中也置 EFCI=1；

- d. 源端若收到 EFCI=1 的后向信元，了解了网络发生拥塞，于是降低发送速率以缓解拥塞。

反馈拥塞指示用于 ABR 业务，通过特定的控制信元（资源管理 RM 信元）来实现。其过程如下：

- a. 源端在信元流中注入 RM 信元，其信元头标记 CLP=0，PTI=110；用于检测可用带宽；
- b. 源端发出的 RM 信元被目的端返回给源端；
- c. 返回到源端的 RM 信元含有沿途各 ATM 设备加入的反馈控制信息，反映网络的可用带宽；
- d. 源端根据反馈的情况进行如下的操作：
 - 若源端没有收到后向 RM 信元，应连续降低发送速率；
 - 若源端收到可用带宽增加的（正向）指示，则提高发送速率；
 - 若源端收到可用带宽较少的（正向）指示，则加快降低发送速率。


ATM 业务类型

ATM 支持五类业务类型，包括：

- CBR 业务

固定速率 CBR（Constant Bit Rate）业务，是指在整个虚电路上提供所预定的恒定可用带宽。适用于需要持续数字信息流的交互式数字语音和视频应用，例如电话会议、电话业务、远程教学。

图7-6 CBR 业务特征




CBR 业务所分配带宽的数量是通过峰值信元速率 PCR 来量化的。在 CBR 中源端可以在任何时候以 PCR 的速率发出信元，并可以持续任意长的时间。

- VBR 业务

可变速率 VBR（Variable Bit Rate）业务的源端发送信元的速率是可变的，也就是说源端可以被认为是“突发性的”。VBR 业务包括：

- 实时可变速率 RT-VBR (Real Time-Variable Bit Rate), 对时延和抖动有严格的限制, 适于实时性要求高的突发性业务, 如分组化语音和视频业务。
- 非实时可变速率 NRT-VBR (Non Real Time-Variable Bit Rate), 适用于实时性要求不高且具有突发性特点的业务, 例如订票系统和银行交易系统。对那些满足流量合同的信元, NRT-VBR 业务可以保证很低的信元丢失率但是对时延没有限制。

图7-7 VBR 业务特征



- ABR 业务

可用比特率 ABR (Available Bit Rate) 业务, 对时延和时延变化没有边界限制, 即对时延抖动没有很高的要求, 不支持实时的应用。ABR 采取了一定的流控手段来控制网络拥塞和避免信元丢失, 因此 ABR 在信元丢失率、可用带宽方面是有保证的。ABR 典型应用有 LAN 仿真和 LAN 互连业务。

图7-8 ABR 业务特征




- UBR 业务

未指定比特率 UBR (Unspecified Bit Rate) 业务不保证可用带宽。适用于非时间敏感性的 BE (Best-Effort) 业务, 也就是那些对时延和时延变化要求都不太严格的应用, 如 email, FTP 文件传送。

UBR 业务不存在任何的服务质量的承诺, 连接的信元丢失率和信元传输时延均没有数值保证。网络可以选择在 CAC 和 UPC 中是否需要运用 PCR。在网络对 PCR 没有强制性的要求的时候, PCR 的值没有什么意义。

ABR 和 UBR 的区别是当虚电路上发生阻塞时, ABR 业务将降低传输速率, 而 UBR 业务将被网络通道上发生阻塞的设备丢弃。

图7-9 UBR 业务特征



7.2 ATMoPSN 及 PSNoATM 的 QoS

ATM 与 PSN 的结合


ATM 最初的构想是通过 ATM 技术可以解决所有的网络通信问题。由于 ATM 技术过于完善，其协议体系的复杂性造成了 ATM 系统研制、配置、管理和故障定位的难度。ATM 诞生后始终没有机会建立一个纯 ATM 网来表现其卓越的性能。

到了 90 年代后期，Internet 及相应的 IP 技术以其简单性和灵活性在市场上压倒了 ATM，在应用领域取得了迅猛的发展。不过，ATM 在提供有质量保证的综合业务传送能力方面的优势无可置疑。于是，诞生了 ATM 网络与现有分组交换网络 PSN（Packet Switched Network）相互结合使用的技术，包括：ATMoPSN（ATM over PSN）、IPoA（IP over ATM）、IPoEoA（IP over Ethernet over ATM）、PPPoA（PPP over ATM）、PPPoEoA（PPP over Ethernet over ATM）。

ATMoPSN


ATMoPSN 即 ATM 业务在 PSN 网络上透明传输，指利用 PSN 网络的 PWE3（Pseudo-Wire Emulation Edge to Edge）技术将传统的 ATM 网络连通起来，在 PSN 网络上提供传统的 ATM 业务的仿真。

图7-10 ATMoPSN 组网模型



ATMoPSN 的报文结构如图 7-11。

图7-11 ATM PWE3 封装格式



一个 ATMoPSN 报文可以只封装一个 ATM 信元，也可以使用信元级联，将多个信元放在一个 PW 报文中进行传输，以提高带宽利用率。

PSNoATM



说明

为了方便，本文将 IPoA、IPoEoA、PPPoA、PPPoEoA 统称为 PSNoATM（PSN over ATM）技术。

● IPoA 和 IPoEoA

随着核心网络 IP 化的趋势以及以太网技术在接入层设备的普及，ATM 网络广泛用于承载 IP 业务和 Ethernet 业务。ATM 作为 IP 业务和 Ethernet 业务的承载网，提供了高速点对点连接，优良的网络性能，和完善、成熟的 QoS 保证。


IP 在 ATM 网上通信，IP 分组必须在 AAL 层上进行适配，从而在源端分段成信元并在目的端组装成分组。RFC1483 提供了这种适配的技术标准。

图7-12 IPoA 和 IPoEoA



- IPoA: 用 ATM 直接承载网络层的 IP 包，采用 RFC1483R 封装。
- IPoEoA: 将 IPoE（IP over Ethernet）报文封装在 ATM 上传输，采用 RFC1483 B 封装。

图7-13 ATM 封装 Ethernet 和 IP 业务



● PPPoA 和 PPPoEoA

PPPoA: 在 ATM 上承载 PPP 协议报文。ATM 信元封装 PPP 报文，IP 或其它协议的报文则封装在 PPP 报文中。

PPPoEoA（PPPoE over ATM）: 指的是在 ATM 上承载 PPPoE（PPP over Ethernet）协议报文。

 **说明**
为了实现在 ATM 上承载以太网报文（包括 IPoEoA 和 PPPoEoA 报文），华为路由器提供了一种新的接口类型——VE（Virtual Ethernet）接口。这种接口具有以太网的特性，由用户通过配置命令动态创建。为这种接口配置的协议栈是：底层为 ATM 的 PVC，通过 PVC 收发报文；链路层为以太网协议；网络层及以上各层协议与普通以太网接口相同。

ATMoPSN 的 QoS

ATMoPSN 的典型组网模型如图 7-14，ATM PWE3 报文结构如图 7-15。

图7-14 ATMoPSN 组网模型





图7-15 ATM PWE3 封装格式




根据 ATMoPSN 组网模型及 ATM PWE3 封装格式可知，ATM 信元在 PSN 网络传递过程中被封装了 MPLS 标签，只需要采用 MPLS 网络现有的 QoS 机制，就可以保证 PW 端到端的 QoS。

但要在 PSN 网络传输 ATM 信元的过程中保持 ATM 网络的 QoS 能力，还需要对 ATM 的 QoS 参数与 MPLS QoS 机制中的 QoS 优先级标记（MPLS Exp）进行映射。华为路由器通过 ATM 流分类实现此功能：

- 在对进入 PSN 网络的 ATM 信元进行封装时，入节点 PE 根据 ATM 网络的服务类型和 CLP 值映射到路由器的内部的服务等级（Service-Class）和丢弃优先级（Color）；
- 在 ATM 信元离开 PSN 网络前，出节点 PE 在进行解封时根据路由器内部优先级和颜色映射成 ATM 信元原有的 CLP 值。

图7-16 ATMoPSN 优先级映射过程



ATMoPSN QoS 中使用的 ATM 流分类包括简单流分类和强制流分类。

• ATM 简单流分类

ATMoPSN 中，ATM 简单流分类是指在 ATM 信元进入 PSN 网络时，将 ATM 网络的服务类型和 CLP 值映射到路由器的内部的服务等级（Service-Class）和丢弃优先级（Color）。在 ATM 信元离开 PSN 网络时，将内部优先级和颜色映射成 ATM 信元原有的 CLP 值。

可以在入口 PE 设备上使能 ATM 简单流分类和配置 ATM-->PSN 的优先级映射关系，在出口 PE 设备上配置 PSN-->ATM 的优先级映射关系。缺省情况下的优先级映射关系如下。

表7-1 ATM->PSN 缺省映射关系

ATM 服务类型	ATM CLP	Service-Class	Color
CBR	0	EF	Green
	1	EF	Green
ABR	0	AF1	Green
	1	AF1	Yellow
NRT-VBR	0	AF2	Green
	1	AF2	Yellow
RT-VBR	0	AF4	Green
	1	AF4	Yellow
UBR	0	BE	Green
	1	BE	Green
OAM-Cell	-	EF	Green

表7-2 PSN->ATM 缺省映射关系

Service-Class	Color	ATM CLP
BE	Green	1
AF1	Green	1
AF1	Yellow	1
AF1	Red	1
AF2	Green	0
AF2	Yellow	1
AF2	Red	1
AF3	Green	1
AF3	Yellow	1
AF3	Red	1
AF4	Green	0
AF4	Yellow	1
AF4	Red	1
EF	Green	0
CS6	Green	0
CS7	Green	0

- **ATM 强制流分类**

在 ATM 网络中，虽然 ATM 信元本身携带有优先级的信息，但是在信元级联（多个信元放在一个 PW 报文中进行传输）的情况下，根据 ATM 信元的优先级来实现简单流分类功能，比较复杂。可以采用强制流分类的方案。

强制流分类不关注 ATM 信元的服务类型和优先级，在 ATM 网络的边缘路由器的上行接口，强制为某个 PVC、某个接口（包括主接口和子接口）或者某个 PVP 的流量指定 IP 报文的业务优先级和颜色，并根据指定的业务优先级和报文颜色在 ATM 网络边缘路由器的下行接口应用 QoS 策略。

PSNoATM 的 QoS



说明

为了方便，本文将 IPoA、IPoEoA、PPPoA、PPPoEoA 统称为 PSNoATM（PSN over ATM）技术。

在华为路由器上，除了 ATM 协议本身的流量控制和拥塞控制机制外，还实现了以下几种 ATM QoS 机制：

- **ATM 流分类**

ATM 网络在承载 IP 业务、Ethernet 业务和 PPP 业务时，为了在 ATM 网络传递过程中保持报文的优先级，需要将 IP 报文的各种优先级映射到 ATM 业务优先级，实现这一功能的是 ATM 流分类。

PSNoATM 中，ATM 流分类支持三种方法：

- **ATM 简单流分类**

PSNoATM 中，ATM 简单流分类是指在 ATM 网络入口节点上，信任端口的上行报文携带的优先级标记（DSCP、IP Precedence、802.1p、MPLS Exp），并根据优先级映射表，上行将报文携带的优先级标记统一映射到设备内部的服务等级和颜色，下行将内部服务等级和颜色映射成 ATM 的 CLP 值。在 ATM 网络出口节点上，上行将 ATM 信元原有的 CLP 值映射成报文的内部的服务等级和颜色，下行将报文的内部的服务等级和颜色映射成报文的优先级标记。

可以在 ATM 入口设备上使能 ATM 简单流分类和配置 PSN-->ATM 的优先级映射关系，在 ATM 出口设备上配置 ATM-->PSN 的优先级映射关系。

缺省情况下的优先级映射表如下：

- PSN 报文优先级到设备内部服务等级和颜色的映射关系请参见“3.3.2 QoS 优先级映射”。
- 设备内部服务等级和颜色到 ATM CLP 的映射关系见本章节的表 7-1。
- ATM CLP 到设备内部服务等级和颜色的映射关系见本章节的表 7-2。
- 设备内部服务等级和颜色到 PSN 报文优先级的映射关系请参见“3.3.2 QoS 优先级映射”。

- **ATM 强制流分类**

实现原理与 ATMoPSN 中的类似，此处不再赘述。

- **ATM 复杂流分类**

ATM 复杂流分类的原理与 IP QoS 中的类似，唯一区别在于：ATM 复杂流分类的流量策略需要应用在 ATM（子）接口或 Virtual-Ethernet 接口上。

关于 IP QoS 复杂流分类的详细描述，请参见“3.4 复杂流分类”。

- **ATM 流量整形**

ATM 流量整形是一种改变 VCC 或 VPC 上的信元流的业务特性，使这类信元以比较均匀的速度向外发送，以利于 ATM 网络上下游之间的带宽匹配。

ATM 流量整形通过降低峰值速率、限制突发业务流的长度、及时调整信元间隔以降低信元时延变化、业务排队机制等几个方面来实现。ATM 流量整形的实现原理与 IP QoS 中的流量整形类似，差别在于：

- IP QoS 流量整形的对象是 IP 报文，而 ATM 流量整形对象是 ATM 信元。
 - IP QoS 流量整形采用令牌桶算法，而 ATM 流量整形采用漏桶算法。

这两种算法的区别在于：漏桶算法能够强行限制数据的传输速率，而令牌桶算法能够在限制数据的平均传输速率的同时还允许某种程度的突发传输。

ATM 流量整形可在 ATM 网络中任何地方实现，但一般用在 ATM 网络出口处。

- **ATM PVC 拥塞管理**

ATM PVC 拥塞管理是指对超过 PVC 带宽的报文不丢弃，而是缓存起来，在网络有空闲带宽的时候再通过队列调度机制发送。

一个 PVC 有 8 个队列，其中只有一个队列采用 SP 调度算法，称为 PQ 队列，其他队列采用 WFQ 算法，称为 WFQ 队列。ATM PVC 目前只支持一级队列调度，队列调度机制与 IP QoS 类似，详细的介绍请参见“5.2 队列及拥塞管理”。

系统缺省情况下，ATM PVC 没有配置队列调度。如果 PVC 下的一个队列的队列调度被配置为 PQ 或 WFQ，则其它队列均默认为 WFQ 队列调度，调度参数缺省为 20，建议调度参数的取值大于 10。

此外，华为路由器支持对 UBR 类型的 PVC/PVP 的流量内部服务等级进行调整，从而实现对不同优先级的 PVC 的流量进行调度。

8 路由器 QoS 转发全流程

上、下行概念解释


根据数据流方向，路由器报文转发可以分为上行、下行两个流程。对于设备内部实现而言，流量去往交换网方向为“上行”；流量远离交换网方向为“下行”，如图 8-1




说明

对于网络流量而言，流量从用户方向去往运营商网络方向称之为“上行”；流量从运营商网络去往用户方向称之为“下行”。

图8-1 报文转发流程中的上行和下行



转发平面单板结构



缩略语解释:

PIC: Physical Interface Controller

PFE: Packet Forward Engine

TM: Traffic Manager


FIC: Fabric Interface Controller

eTM: egress Traffic Manager

→ 上行

→ 下行

QoS 在单板各部件的分布情况



有的单板的 PIC 卡（Physical Interface Card，物理接口卡）嵌了一个 TM 芯片，称为 eTM（egress Traffic Manager）子卡。有的单板的 PIC 卡没有 eTM 子卡。

如果下行 PIC 不嵌 eTM 子卡，则下行基于包的队列管理是在下行 TM 上进行；如果下行 PIC 嵌有 eTM 子卡，则下行基于包的队列管理是在 eTM 上进行的，而不是在下行 TM 上。

在任意视图下执行 **display device pic-status** 命令，可查看对应的单板是否嵌有 eTM 子卡。如果显示信息中 “Type” 字段值包含 “_T_CARD”，则表示对应的是 eTM 子卡。例如：

```
<HUAWEI> display device pic-status
Pic-status information in Chassis 1:
-----
SLOT PIC Status      Type                      Port count Init result  Logic down
1    1  Registered ETH 20XGF NB CARD      20        SUCCESS    SUCCESS
2    0  Registered LAN WAN 2x10GF T CARD  2         SUCCESS    SUCCESS
-----
```




注意

对队列统计的 pass 计数（用 **display port-queue statistics** 命令查看）可能比从端口发出的报文要多，因为报文在下行 PFE 的 CAR、Filter、组播减枝等处理时可能被丢掉一部分。

报文转发流程

当 PIC 不带 eTM 子卡时，本文以以太网报文为例说明转发流程，如图 8-2。

图8-2 PIC 不带 eTM 子卡时的转发流程



- 上行转发流程：

- 物理链路的光/电信号经 PIC 卡打包成以太帧后，送给上行 PFE，即 NP（Network Processor）或者 ASIC（Application Specific Integrated Circuit）。
- 在上行 PFE 的入接口处理模块对链路层协议进行解析、识别报文类型。
- 在上行 PFE 的流分类模块根据入接口的配置先后进行简单流分类和复杂流分类。
- 上行 PFE 根据数据包信息（如 MAC、目的 IP、MPLS 标签等），查转发表项获得出接口和下一跳等信息。对于转发行为为丢弃的报文，在上行 PFE 被丢弃，不经过 CAR 统计。
- 上行 PFE 根据入接口配置的 CAR，或者是上行复杂流分类中配置的 CAR 进行上行限速。



说明

上送 CPU 以及 CPU 下发的数据包不经过上行 CAR 处理，这是为了避免当流量突发时上送 CPU 的数据包在上行因 CAR 被丢弃。

- 上行 PFE 将数据包发给上行 TM（Traffic Manager，流量管理器）。
- 上行 TM 根据数据包入接口/上行复杂流分类中配置的 **user-queue** 进行上行流队列处理（可选），然后根据报文出接口所对应的槽位进行 VOQ 处理，VOQ 处理后，报文转发给上行 FIC。
- 上行 FIC 将数据包进行切片，并封装成交换网信元后发送给交换网板。

**说明**

交换网板是基于固定信元长度交换的，类似于 ATM，所以数据包送入交换网板前 TM 对其进行切片。

- 下行转发流程：

交换网信元经过交换网板后，发送给下行 TM。

- 下行 FIC 将交换网信元重新组装成数据包。
- 对于多播报文，下行 TM 进行复制。
- 下行 TM 先根据出接口（含 VLAN 子接口）配置的 user-queue 进行流队列处理（可选），接着对物理出口的 CQ 队列进行处理，之后将数据包发送给下行 PFE。
- 下行 PFE 查表（例如，对于 IPv4 报文，使用下一跳信息查 ARP 表项；对于 MPLS 转发，查 MPLS 转发表）获得报文封装信息。
- 下行 PFE 根据出接口配置进行下行复杂流分类，之后进行简单流分类（仅进行内部服务等级和丢弃优先级到外部优先级的映射）。
- 下行 PFE 根据出接口下配置的 CAR，或者下行复杂流分类中配置的 CAR 进行下行限速。
- 对于需要上送 CPU 的数据包，进行 CPCar 处理后上送给 CPU。对于不需要上送 CPU 的数据包，发给出接口处理模块将新的二层头封装好，发给 PIC 卡。


**说明**

有部分单板，链路层帧头封装是在下行 CAR 处理之前进行，有的则在下行 CAR 之后。无论链路层帧头封装在下行 CAR 之前还是之后，CAR 的带宽计算都包括链路层帧头。

- PIC 卡将数据包转换成光电信号发送到物理链路。

当 PIC 带有 eTM 子卡时，报文转发流程如图 8-3。其中上行处理与 PIC 不带 eTM 子卡的情况一致。下行处理的区别在于：PIC 带有 eTM 子卡时下行的流队列处理是在 eTM 子卡上进行的；PIC 不带 eTM 子卡时下行的流队列处理是在下行 TM 上进行的。此外，带有 eTM 子卡的下行流队列处理是 5 级流队列调度（请求调度的过程：FQ->SQ->GQ->VI->Port），不带 eTM 子卡的下行流队列处理是 3 级流队列调度（FQ->SQ->GQ）+ 2 级 CQ 队列调度（CQ->Port）。


图8-3 PIC 带有 eTM 子卡时的转发流程



转发过程中的 QoS 处理

如图 8-4，报文转发过程中的 QoS 处理详细描述如下：

图8-4 转发过程中的 QoS 处理



- 上行 PFE 的处理：

- 首先初始化报文的内部流标记（Service-class=BE，Color=Green）。
- 根据入接口配置进行上行简单流分类处理，即提取报文的优先级字段（8021p、DSCP 或 MPLS Exp）进行流分类，根据上行入映射表重新设置报文的内部流标记（Service-class & Color）。
- 根据入接口配置进行上行复杂流分类处理，即提取报文的多个信息字段进行流分类。根据分类结果执行 filter、remark、redirect 等处理。如果是 remark，则会再次重新设置内部流标记（Service-class & Color）。

说明

remark 命令、**qos default-service-class** 命令、**service-class** 命令和带 **service-class** 参数的 **qos car** 命令都会重新设置内部流标记（Service-class & Color），那么这几条命令，无论配置的顺序是什么，其上行执行顺序是：**remark** 命令-> **qos default-service-class** 命令-> 流行为视图的 **service-class** -> 接口视图的 **qos car** -> 流行为视图的 **car**。

- 根据报文的目的 IP 查路由表，获得报文的出接口。
- 根据报文入接口下配置的 CAR，或者是上行复杂流分类中配置的 CAR 进行上行 CAR 处理（如果同时配置了接口 CAR 与复杂流分类 CAR，支持两级 CAR 特性的单板，先执行复杂流分类 CAR 再执行接口 CAR；不支持两级 CAR 的单板最终按复杂流分类 CAR 处理）。支持色敏模式的 CAR，可以感知前面得到的内部标记 Color。在 CAR 处理中，可以根据输入流量的情况执行 Pass 或者 Drop 动作，也可以支持 Pass+Remark 的处理。如果是 Pass+Remark 处理，则再次重新设置内部流标记（Service-class & Color）。
- 之后，报文进入上行 TM。

- 上行 TM 的处理：

- 根据报文入接口配置的 user-queue，或者是上行复杂流分类中配置的 user-queue 进行上行流队列处理（如果同时配置了接口 user-queue 与复杂流分类 user-queue，最终按复杂流分类 user-queue 处理）。报文根据 Service-class 入

- 对应的 FQ，根据 Color 做 FQ WRED 处理。（上行流队列处理是可选的配置）。
- b. 进行 VOQ 处理。VOQ 是针对目标单板划分的，根据之前查路由表获得的出接口得到目标单板，再根据 Service-class 进入具体的 VOQ。
 - c. 经过 VOQ 调度后，报文被送给交换网转发到出接口所在的目标单板。
 - d. 之后报文进入下行 TM。
- 下行 TM 的处理：
 - a. （下行 PIC 存在 eTM 的情况下，将跳过此步骤）根据报文出接口配置的 **user-queue** 进行下行流队列处理。报文根据 Service-class 入对应的 FQ，根据 Color 做 FQ WRED 处理。（下行流队列处理是可选的配置）。
 - b. （下行 PIC 存在 eTM 的情况下，将跳过此步骤）端口队列处理。根据 Service-class 进入出接口的 CQ，根据 Color 做 Port WRED 处理。
 - c. 报文进入下行 PFE。
 - 下行 PFE 的处理：
 - a. 根据出接口配置进行下行复杂流分类处理，即提取报文的多个信息字段进行流分类。根据分类结果执行 filter、Remark 等处理，如果是 Remark，则会再次重新设置内部流标记（Service-class & Color）。
 - b. 根据报文出接口下配置的 CAR，或者是下行复杂流分类中配置的 CAR 进行下行 CAR 处理（如果同时配置了接口 CAR 与复杂流分类 CAR，支持两级 CAR 特性的单板，先执行复杂流分类 CAR 再执行接口 CAR；不支持两级 CAR 的单板最终按复杂流分类 CAR 处理）。支持色敏模式的 CAR，可以感知前面得到的内部标记 Color，在 CAR 处理中，可以根据输入流量的情况执行 Pass 或者 Drop 动作，也可以支持 Pass+Remark 的处理。如果是 Pass+Remark 处理，则再次重新设置内部流标记（Service-class & Color）。
 - c. 执行下行简单流分类反射：即根据 Service-class & Color 设置（新封装的报文头）或者改写（已经存在的报文头）出口报文的优先级字段。



说明

remark 命令、**service-class** 命令和带 **service-class** 参数的 **qos car** 命令都会重新设置内部流标记（Service-class & Color），且会影响到下行简单流分类反射的结果。这几条命令和下行反射，无论配置的顺序是什么，其执行顺序是：**service-class**->接口 **qos car**->流 **car**->**remark**。


- d. 报文进入下行 PIC。
 - 对于无 eTM 的 PIC，添加链路层 CRC，将报文转发到物理链路上；
 - 对于有 eTM 的 PIC，添加完链路层 CRC 后，在将报文转发到物理链路之前，还将进行一轮流队列调度。根据报文出接口配置的 **user-queue** 进行下行流队列处理。报文根据 Service-class 入对应的 FQ，根据 Color 做 FQ WRED 处理。（存在 eTM 的情况下，下行报文将跳过下行 TM 的调度处理）。

转发过程中的报文字段变化

在 QoS 的 CAR 和流量整形处理后，流量的带宽计算与报文长度相关，因此需要关注转发过程中报文的字段变化。

作为参考，下文给出了几种常见场景下的报文字段变化。

图8-5 子接口接入 L3VPN 场景--报文入隧道时的格式转换



说明

- 经过上行 PIC 处理后的以太网帧只包含 Destination MAC 至 Data payload 之间的内容，不包含 Inter frame gap、Preamble、SFD（这三个字段统称为 IFG 字段，共 20 字节）以及 CRC 字段。完整的以太网帧如下（长度单位：字节）：

Minimum 12	7	1	6	6	2	46 to 1500	4
Inter frame gap	Preamble	SFD	Destination MAC	Source MAC	Length/type	Data payload	CRC


CAR 之后的带宽计算不包括 IFG 字段，但包括 CRC 字段。

- Frame Header 字段是上行 PFE 添加的，下行 PFE 剥离，用于各个芯片间传递信息。NPtoTM 字段和 TMtoNP 字段用于 NP 和 TM 之间传递信息。
- 当 PIC 无 eTM 子卡时，在下行 TM 队列调度时处理的数据包长度与实际发送到链路上的数据包长度不一致，为了更精确地进行流量 Shaping，需要配置 **network-header-length** 命令，对报文的长度进行补偿。

本例场景中，在网络侧下行接口：

- 对于 **Type-A** 和 **Type-B** 类单板，下行 TM 处理的数据包比发送到链路上的数据包少了 IFG、L2 Header、2 个 MPLS Label、CRC，但多了 Frame Header，Frame Header 长度正好等于 L2 Header，因此需要修正的长度为“+12”（即 2 个 MPLS Label 长度+CRC 长度，不考虑 IFG 字段），或者“+32”（考虑 IFG 字段）。
- 对于 **Type-C** 类单板，则下行 TM 计算数据包时不考虑 Frame Header，因此需要修正的长度为“+26”（不考虑 20 字节的帧间隙 IFG 字段）或者“+46”（考虑 IFG 字段）。
- 当 PIC 有 eTM 子卡时，不需要进行报文长度补偿。

图8-6 子接口接入 L3VPN 场景--报文出隧道时的格式转换




说明

本例场景中，在用户侧下行接口：

- 对于 **Type-A** 和 **Type-B** 类单板，下行 TM 处理的数据包比发送到链路上的数据包少了 IFG、L2 Header、VLAN Tag、CRC，但多了 Frame Header，Frame Header 长度正好等于 L2 Header，因此需要修正的长度为 “+8”（即 VLAN Tag 长度+CRC 长度，不考虑 IFG 字段），或者 “+28”（考虑 IFG 字段）。
- - 对于 **Type-C** 类单板，则下行 TM 计算的数据包长度不包括 Frame Header，因此需要修正的长度为 “+22”（不考虑 20 字节的帧间隙 IFG 字段）或者 “+42”（考虑 IFG 字段）。

其他说明事项请参见“子接口接入 L3VPN 场景--报文入隧道时的格式转换”。

图8-7 子接口终结接入 VPLS 场景--报文入隧道时的格式转换




说明

本例场景中，在网络侧下行接口：

- 对于 **Type-A** 和 **Type-B** 类单板，下行 TM 处理的数据包比发送到链路上的数据包少了 IFG、1 个 L2 Header、2 个 MPLS Label、CRC，但多了 Frame Header，Frame Header 长度正好等于 L2 Header，因此需要修正的长度为“+12”（即 2 个 MPLS Label 长度+CRC 长度，不考虑 IFG 字段），或者“+32”（考虑 IFG 字段）。
- 对于 **Type-C** 类单板，则下行 TM 计算数据包时不考虑 Frame Header，因此需要修正的长度为“+26”（不考虑 20 字节的帧间隙 IFG 字段）或者“+46”（考虑 IFG 字段）。

其他说明事项请参见“[子接口接入 L3VPN 场景--报文入隧道时的格式转换](#)”。

图8-8 子接口终结接入 VPLS 场景--报文出隧道时的格式转换



说明

本例场景中，在用户侧下行接口：

- 对于 **Type-A** 和 **Type-B** 类单板，下行 TM 处理的数据包比发送到链路上的数据包少了 IFG、VLAN Tag、CRC，但多了 Frame Header，因此需要修正的长度为“-6”（即 VLAN Tag 长度+CRC 长度-Frame Header 长度=4+4-14=-6，不考虑 IFG 字段），或者“+14”（考虑 IFG 字段）。
- 对于 **Type-C** 类单板，则下行 TM 计算的数据包长度不包括 Frame Header，因此需要修正的长度为“+8”（不考虑 20 字节的帧间隙 IFG 字段）或者“+28”（考虑 IFG 字段）。

其他说明事项请参见“子接口接入 L3VPN 场景--报文入隧道时的格式转换”。

关于报文补偿的补充说明

对报文的长度进行补偿的命令 **network-header-length** 是在业务模板下配置的。华为路由器预先设定了一些模板，使用这些预先设定的模板则不用关注需要对报文补多少长度。

如果想手工设置补偿值，可以通过 **display interface** 命令查看出接口统计，计算出发送到链路上的数据包长 L1，再通过 **display port-queue** 命令查看队列统计，计算出下行 TM 处理的包长 L2，则补偿值 = L1 - L2。

模板名称	转换类型
bridge-outbound	隧道出方向网桥间转换
ip-outbound	IP 报文转换或者接口出方向上 IP 报文转换成 8021Q 报文

模板名称	转换类型
ip-outbound1	接口出方向上 IP 报文转换成 QinQ 报文
ip-outbound2	POS 接口出方向上 IP 报文转换文
ip-outbound3	FR 接口出方向上 IP 报文转换
l3vpn-outbound	FR 接口出方向上 L3VPN 报文间的转换或 L3VPN 报文转换成 8021Q 报文
l3vpn-outbound1	接口出方向上 L3VPN 报文转换成 QinQ 报文
l3vpn-outbound2	POS 或 FR 接口出方向上 L3VPN 报文间转换
pbt-outbound	接口出方向上 PBT 报文转换
vlan-mapping-outbound	接口出方向上 VLAN Mapping 报文转换
vll-outbound	POS 接口出方向上 VLL 报文同异种媒介的转换或者隧道出方向上 VLL 报文转换成 QinQ 报文
vll-outbound1	POS 接口出方向上 VLL 报文与同种媒介的转换或者隧道出方向上 VLL 报文转换成 QinQ 报文
vpls-outbound	隧道出方向 VPLS 报文转换成 8021Q 报文
vpls-outbound1	隧道出方向 VPLS 报文转换成 QinQ 报

9 协议报文的 QoS 处理


上送 CPU 的网络协议报文的 QoS 处理

需要上送 CPU 处理的网络协议报文主要包括如下几类：

- 从二层帧头的协议字段就可以直接判断出是需要上送本机 CPU 处理的协议报文，如 ARP、RARP、IS-IS、LLDP、STP/RSTP/MSTP、Eth-OAM、LACP、PPP 控制报文等等，或者目的地址为特定的保留组播 IP 地址（标准中定义，组播地址 224.0.0.1～224.0.0.255 供路由协议使用）的协议报文。
- 封装在 TCP/UDP 中，再封装到 IP 数据包中，例 BFD、BGP、RIP、DHCP、DNS、MPLS LDP、NTP、RADIUS、SNMP、L2TP 控制消息等等；或者直接封装在 IP 数据包中，例如，ICMP、RSVP、VRRP、IGMP、PIM 等协议消息。这类网络控制报文虽然无法直接二层帧头识别出来的，但其目的地址通常为路由器上的某个直连物理接口的 IP 地址，或者逻辑接口 LoopBack 接口或 VT（Virtual-Template）接口的 IP 地址，或者为 IP 广播地址（如 DHCP Request 消息报文）。路由器进行查表转发，如果匹配这类地址的报文，便可认定为发给自己的消息，需要上送自己的应用协议栈进行进一步处理。

对于上送 CPU 的网络协议报文，QoS 相关的处理流程同其他流量类似，如图 9-1 所示。

图9-1 上送 CPU 的网络协议报文 QoS 处理流程



与其他流量的 QoS 处理相比，不同的地方在于：

- 上送 CPU 的网络协议报文，不做上行 CAR 处理。这是为了避免当流量突发时上送 CPU 的网络协议报文在上行因 CAR 被丢弃。
- 由于在下行就要送往 CPU 进行报文解析，下行流分类和标记已经没有作用，跟下行流分类相关的流策略（复杂流分类）等功能也是无用的，所有对于上送 CPU 的网络协议报文，在下行不再做复杂流分类和简单流分类映射。
- 为了防止大流量报文上送导致 CPU 过于繁忙，被确认为需要继续上送到 CPU 的流量，将进行 CP-CAR 的过滤，之后再上送 CPU。CP-CAR 全称是 Control Plane CAR（Committed Access Rate），是用来限制转发引擎向接口板 CPU 发送报文的速度。

CP-CAR 根据协议的类型，报文的 VLAN 或者所属的用户，分成很多个管道，每一个管道使用令牌桶进行速率限制，当上送的流量宽值超过设置的速率时，上送的报文将会被随机丢弃，避免 CPU 过载。

因此，对于上送 CPU 的流量，下行不再做 CAR 处理，而是做 CP-CAR 处理。



说明

详细的端到端 QoS 详细处理流程请参见[报文转发流程](#)，此不赘述。

上送 CPU 的网络协议报文的优先级映射


如章节[用于做上行映射（BA）的 QoS 优先级字段是哪个](#)所述：

- 如果报文入接口没有配置 **trust upstream** 命令，那么所有流量，包括上送 CPU 的网络协议报文，都映射到<BE, Green>，从而进入 BE 队列。
- 如果入接口配置了 **trust upstream** 命令，所有流量，包括上送 CPU 的网络协议报文，都是根据报文携带的 802.1p、MPLS EXP、DSCP 或者 ATM CLP 等优先级字段做入映射，进入到对应的队列中。
- 如果入接口配置了 **trust upstream** 命令，但报文没有携带 802.1p、MPLS EXP、DSCP 或者 ATM CLP 等优先级字段，如果从二层帧头的协议字段就可以直接判断出是协议报文，例如 IS-IS 报文、ARP 报文等，则映射到<CS6, Green>，从而进入 CS6 队列。如果是识别不出来的报文，则被映射到<BE, Green>，进入 BE 队列，因为这类报文通常为错误报文。

CPU 发送的网络协议报文的 QoS 处理

如图 9-2 所示，从 CPU 发送的协议报文，在上行不经过接口卡的处理，直接送到包转发引擎 PFE。由于 CPU 发送的报文，大部分都带有目的单板和出接口信息，CPU 已经告诉转发平面报文要发往哪块单板的哪个出接口，因此无需在转发平面查转发表，报文直接入队列。但有一小部分特殊的报文需要再查转发表，例如指定源接口的 ping 报文（命令行 **ping ip-address -si interface-name**），由于只指定了源接口，CPU 并不清楚源接口对应的 IP 地址是多少，因此需要由转发平面查表获得。这些查表转发后的报文也不经过 CAR 处理，直接送到 TM。之后，协议报文的后续处理与其他报文相同，最后跟其他报文一起从出接口发送出去。只是在下行不做 CAR 和流分类等处理，理由和上送 CPU 的网络协议报文是相同的，不再赘述。

图9-2 CPU 发送的网络协议报文的 QoS 处理流程



CPU 发送的网络协议报文的优先级映射

为了保证协议报文在网络阻塞的情况下可以被优先调度，设备发出的网络协议报文，缺省情况下在进行内部队列调度时都映射为内部优先级<CS6, Green>，进入 CS6 队列。

可以使用 **host-packet dscp dscp-value map local-service service-class [color color]** 命令修改映射关系。

CPU 发送的网络协议报文的优先级设置

可以使用 **host-packet type { management-protocol | control-protocol } dscp dscp-value** 命令来设置管理协议报文（包括 SSH、FTP、TFTP、TELNET、SNMP、SYSLOG）或控制协议报文（包括 BFD、BGP、LDP、OSFP、IS-IS）的优先级值。

缺省情况下，CPU 发送的网络协议报文的优先级设置值如表 9-1 所示。

表9-1 CPU 发送的网络协议报文的优先级默认值

协议	优先级
1588v2 (PTP)	IP Precedence = 7 (P2P over UDP) 802.1p = 7 (P2P over Ethernet)
802.1ag	802.1p = 7
802.3ah	无优先级字段
ARP/RARP	无优先级字段
BGP	IP Precedence = 6 TOS = 0xc0
BFD	IP Precedence = 7 TOS = 0xe0
ERPS	802.1p = 7
FTP 控制消息	IP Precedence = 6 TOS = 0xc0
ICMP	IP Precedence = 0 TOS = 0x00
ICMPv6 Echo (type = 128/129, code = 0)	IPv6 Traffic Class = 0x00
ICMPv6 RS/RA/NS/NA (type = 133/134/135/136/137, code = 0)	IPv6 Traffic Class = 0xC0
ICMPv6 差错控制消息	IPv6 Traffic Class = 0x00
IGMP	IP Precedence = 6 TOS = 0xc0
IKE	IP Precedence = 6 TOS = 0xc0
IP FPM	IP Precedence = 6 TOS = 0xc0
IS-IS	无优先级字段
L2TP 控制消息	IP Precedence = 6 TOS = 0xc0
LACP	无优先级字段
LDP	IP Precedence = 6
LLDP	无优先级字段

协议	优先级
MLD	IP Precedence = 6 TOS = 0xc0
MSDP	IP Precedence = 0 TOS = 0x00
MSTP	无优先级字段
NQA	IP Precedence = 0 TOS = 0x00
NTP	IP Precedence = 6 TOS = 0xc0
OSPF	IP Precedence = 6 TOS = 0xc0
OSPFv3	IPv6 Traffic Class = 0xC0
PIM	IP Precedence = 6 TOS = 0xc0
RIP	IP Precedence = 0 TOS = 0x00
RIPng	IPv6 Traffic Class = 0xC0
RRPP	802.1p = 7
RSTP	无优先级字段
RSVP	IP Precedence = 6 TOS = 0xc0
SNMP	IP Precedence = 6 TOS = 0xc0
SSH	IP Precedence = 6 TOS = 0xc0
STP	无优先级字段
Telnet	IP Precedence = 6 TOS = 0xc0
TFTP	IP Precedence = 6 TOS = 0xc0
TWAMP	IP Precedence = 0 TOS = 0x00
VRRP	IP Precedence = 6 TOS = 0xc0

10 单板类型描述约定

华为提供了类型丰富的单板，形成灵活的解决方案。

为了方便描述，本文根据单板的 QoS 行为，将单板进行分类，并给每类命名，本文后续描述此类单板使用此类型名替代单板列表。

类型名	NE40E/80E/5000E 单板	ME60 单板	CX600 单板
Type-A	LPUA LPUG LPUH LPUF-10	BSUF-10 MSUF-10	ISUF-10
Type-B	LPUB LPUF-20, LPUF-21, LPUF-21-A, LPUF-21-B, LPUF-21-E LPUS-20 LPUF-40, LPUF-40-A, LPUF-40-B, LPUF-40-E LPUI-40 NPUI-20	BSUF-21 MSUF-21 BSUF-40 MSUF-40 BSUI-40 MSUI-40	ISUF-20 ISUI-21 ISUF-40, ISUF-40-B
Type-C	LPUI-41 LPUS-41 LPUF-100 LPUI-100 LPUS-100	BSUI-41 BSUF-100 BSUI-100, BSUI-100-E MSUF-100 MSUI-100	ISUI-41 ISUF-100 ISUI-100
Type-D	LPUI-21-L LPUF-50, LPUF-50-L LPUF-51, LPUF-51-B, LPUF-51-E, LPUF-51-L	BSUF-51 BSUI-51, BSUI-51-E MSUF-51 MSUI-51 BSUF-240	ISUI-21 ISUF-50 ISUF-51, ISUF-51-B ISUI-51, ISUI-51-L ISUF-101

类型名	NE40E/80E/5000E 单板	ME60 单板	CX600 单板
	LPUF-51 with P51-H LPUI-51, LPUI-51-B, LPUI-51-E, LPUI-51- L, LPUI-51-S LPUS-51 LPUF-101, LPUF-101- B LPUI-101, LPUI-101- B LPUS-101 LPUF-102, LPUF-102- E LPUI-102, LPUI-102-E LPUF-120, LPUF-120- B, LPUF-120-E LPUF-120 with P120- H LPUI-120, LPUI-120- B, LPUI-120-E, LPUI- 120-L LPUS-120 LPUF-200 LPUI-200, LPUI-200-L LPUF-400 LPUF-240, LPUF-240- B, LPUF-240-E LPUF-240 with P240- H LPUI-240, LPUI-240- B, LPUI-240-L LPUF-480, LPUI-480 LPUI-1T, LPUI-1T-B NPU-50, NPU-50-E NPU-120, NPU-120-E NE40E-M2E (80G)的 集成式 NPU NE40E-M2F (160G)的 集成式 NPU		ISUI-101 ISUF-102 ISUI-102 ISUF-120 ISUI-120 ISUF-200 ISUI-200 ISUF-240 ISUI-240 NPU-50 NPU-120 NPU-240

11 参考文档

关于本章

- [11.1 RFC 参考文档](#)
- [11.2 宽带论坛参考文档](#)
- [11.3 DSL 论坛参考文档](#)

11.1 RFC 参考文档

编号	描述	链接
RFC 791	Internet Protocol Specification	http://www.ietf.org/rfc/rfc791
RFC 1349	Type of Service in the Internet Protocol Suite	http://www.ietf.org/rfc/rfc1349
RFC 1483	Multiprotocol Encapsulation over ATM Adaptation Layer 5	http://www.ietf.org/rfc/rfc1483
RFC 1633	Integrated Services in the Internet Architecture: an Overview	http://www.ietf.org/rfc/rfc1633
RFC 2474	Definition of the Differentiated Services Field (DS Field) in the IPv4 and IPv6 Headers	http://www.ietf.org/rfc/rfc2474
RFC 2475	An Architecture for Differentiated Services	http://www.ietf.org/rfc/rfc2475
RFC 2597	Assured Forwarding PHB Group	http://www.ietf.org/rfc/rfc2597
RFC 2598	An Expedited Forwarding	http://www.ietf.org/rfc/rfc2598

编号	描述	链接
	PHB	98
RFC 2697	A Single Rate Three Color Marker	http://www.ietf.org/rfc/rfc2697
RFC 2698	A Two Rate Three Color Marker	http://www.ietf.org/rfc/rfc2698
RFC 3168	The Addition of Explicit Congestion Notification (ECN) to IP	http://www.ietf.org/rfc/rfc3168
RFC 3209	RSVP-TE: Extensions to RSVP for LSP Tunnels	http://www.ietf.org/rfc/rfc3209
RFC 3246	An Expedited Forwarding PHB (Per-Hop Behavior)	http://www.ietf.org/rfc/rfc3246
RFC 3260	New Terminology and Clarifications for Diffserv	http://www.ietf.org/rfc/rfc3260
RFC 3270	Multi-Protocol Label Switching (MPLS) Support of Differentiated Services	http://www.ietf.org/rfc/rfc3270
RFC 3545	Enhanced Compressed RTP (CRTP) for Links with High Delay, Packet Loss and Reordering	http://www.ietf.org/rfc/rfc3545
RFC 3564	Requirements for Support of Differentiated Services-aware MPLS Traffic Engineering	http://www.ietf.org/rfc/rfc3564
RFC 4124	Protocol Extensions for Support of Diffserv-aware MPLS Traffic Engineering	http://www.ietf.org/rfc/rfc4124
RFC 4125	Maximum Allocation Bandwidth Constraints Model for Diffserv-aware MPLS Traffic Engineering	http://www.ietf.org/rfc/rfc4125
RFC 4127	Russian Dolls Bandwidth Constraints Model for Diffserv-aware MPLS Traffic Engineering	http://www.ietf.org/rfc/rfc4127
RFC 4717	Encapsulation Methods for Transport of Asynchronous Transfer Mode (ATM) over MPLS Networks	http://www.ietf.org/rfc/rfc4717
RFC 4816	Pseudowire Emulation Edge-to-Edge (PWE3) Asynchronous Transfer	http://www.ietf.org/rfc/rfc4816

编号	描述	链接
	Mode (ATM) Transparent Cell Transport Service	

11.2 宽带论坛参考文档

编号	描述	链接
TR-059	DSL Evolution - Architecture Requirements for the Support of QoS-Enabled IP Services	http://www.broadband-forum.org/technical/download/TR-059.pdf
TR-101	Migration to Ethernet Based DSL Aggregation	http://www.broadband-forum.org/technical/download/TR-101.pdf
TR-126	Triple-Play Services Quality of Experience (QoE) Requirements	http://www.broadband-forum.org/technical/download/TR-126.pdf

11.3 DSL 论坛参考文档

编号	描述
MEF 6.1	Amendment to Ethernet Services Attributes Phase 2
MEF 10.1	Ethernet Services Definitions, Phase 2

12 缩略语

缩略语	英文全名	中文解释
3		
3G	3rd Generation	第 3 代移动通信
A		
AAL	ATM Adaptation Layer	ATM 适配层
ABR	Available Bit Rate	可用比特率业务
ACL	Access Control List	访问控制列表
AF	Assured Forwarding	确保转发
ATM	Asynchronous Transfer Mode	异步传输模式
B		
BA	Behavior Aggregation	简单流分类
BC	Bandwidth Control	带宽控制
BE	Best-Effort	尽力而为
BGP	Border Gateway Protocol	边界网关协议
BRAS	Broadband Remote Access Server	宽带远程接入服务器
C		
CAC	Call Admission Control	连接准许控制
CAR	Committed Access Rate	承诺访问速率
CBR	Constant Bit Rate	固定速率业务
CBS	Committed Burst Size	承诺突发尺寸

缩略语	英文全名	中文解释
CDVT	Cell Delay Variation Tolerance	信元时延抖动容限
CE	Customer Edge	用户边缘设备
CIR	Committed Information ate	承诺信息速率
CLP	Cell Loss Priority	信元丢弃优先级
CLR	Cell Loss Rate	信元丢失率
COS	Class Of Service	服务等级
CQ	Class Queue	类队列
CR	Core Router	核心路由器
CR-LSP	Constraint-based Routed LSP	基于约束路由的标签交换路径
CRC	Clic Redundancy Check	循环冗余校验
CS	Class Selector	类选择码
CSCP	Class Selector Code Point	类选择代码点
CSPF	Constraint Shortest Path First	约束最短路径优先
CT	Class Type	
CTD	Cell Transfer Delay	信元传输时延
D		
DF	Don' t Fragment	不分片标记
DiffServ	Differentiated Service	差分服务
DRR	Deficit Round Robin	差分轮询调度
DS	Differentiated Service	差分服务
DS-TE	DiffServ-aware Traffic Engineering	差分服务流量工程
DSCP	Differentiated Services Code Point	有差别服务编码点
DSLAM	Digital Subscriber Line Access Multiplexer	数字用户线接入复接器
DWRR	Deficit Weighted Round Robin	差分加权轮询调度
E		

缩略语	英文全名	中文解释
E-LSP	EXP-Inferred-PSC (PHB Scheduling Class) LSP	
EBS	Extended burst size	超额突发尺寸
EF	Expedited Forwarding	加速转发
EFCI	Explicit Forward Congestion Indication	前向拥塞指示
eTM	egress Traffic Manager	后置流量管理器
EXP	Experimental Bits	实验比特位
F		
FIC	Fabric Interface Controller	交换网接口控制器
FIFO	First In First Out	先入先出
FL	Flow Label	流标签
FQ	Flow Queue	流队列
FR	Frame Relay	帧中继
FRR	Fast ReRoute	快速重路由
FTP	File Transfer Protocol	文件传输协议
G		
GQ	Group Queue	用户组队列
GRE	Generic Routing Encapsulation	通用路由封装协议
H		
HG	Home Gateway	家庭网关
HQoS	Hierarchical Quality of Service	层次化 QoS
HSI	High Speed Internet	高速宽带上网
HTML	Hypertext Markup Language	超文本标记语言
HTTP	Hypertext Transfer Protocol	超文本传输协议
I		
ICMP	Internet Control Message Protocol	因特网控制报文协议
IEEE	Institute of Electrical and	电气和电子工程师学会

缩略语	英文全名	中文解释
	Electronics Engineers	
IETF	Internet Engineering Task Force	Internet 工程任务组
IGMP	Internet Group Management Protocol	因特网组管理协议
IGW	Internet Gateway	Internet 网关
IntServ	Integrated Service	综合服务
IP	Internet Protocol	互联网协议
IPinIP	IP in IP Encapsulation	IP-in-IP 封装
IPoA	IP over ATM	ATM 网承载 IP 报文
IPoEoA	IP over Ethernet over ATM	ATM 网承载 IPoE 报文
IPoE	Internet Protocol over Ethernet	以太网承载 IP 协议
IPTV	Internet Protocol Television	IP 电视
IPv4	Internet Protocol version 4	第四版互联网协议
IPv6	Internet Protocol version 6	第六版互联网协议
ISP	Internet Service Provider	因特网服务提供商
L		
L-LSP	Label-Only-Inferred-PSC (PHB Scheduling Class) LSP	
L3VPN	Layer 3 Virtual Private Network	三层虚拟专用网
LAN	Local Area Network	局域网
LDP	Label Distribution Protocol	标签分发协议
LPQ	Low Priority Queue	低优先级队列
LPU	Line Processing Unit	线路处理板
LR	Line Rate	接口限速
LSP	Labeled Switch Path	标签交换路径
LSW	LAN Switch	局域网交换机
M		
MAC	Medium Access Control	介质访问控制

缩略语	英文全名	中文解释
MAM	Maximum Allocation Model	最大分配模型
MBS	Maximum Burst Size	最大突发度
MCDT	Maximum Cell Transfer Delay	最大信元传递时延
MCR	Minimum Cell Rate	最小信元速率
MF	Multiple Field	复杂流分类
MP	Merge Point	汇聚点
MPLS	Multiprotocol Label Switching	多协议标签交换
MTU	Maximum Transmission Unit	最大传输单元
N		
NGN	Next Generation Network	下一代网络
NPC	Network Parameter Control	网络参数控制
NRT-VBR	Non Real Time-Variable Bit Rate	非实时可变速率业务
O		
OLT	Optical Line Terminal	光线路终端
ONT	Optical Network Terminal	光网络终端
OSPF	Open Shortest Path First	开放式最短路径优先
P		
PBS	Peak Burst Size	峰值突发尺寸
PC	Personal Computer	个人计算机
PCP	Priority Code Point	优先级编码点
PCR	Peak Cell Rate	峰值信元速率
PE	Provider Edge	运营商边缘设备
PFE	Packet Forward Engine	报文转发引擎
PHB	Per Hop Behaviors	逐跳行为
PIC	Physical Interface Card	物理接口卡
PIR	Peak Information Rate	峰值速率
PLR	Point of Local Repair	本地修复节点

缩略语	英文全名	中文解释
PPP	Point-to-Point Protocol	点对点协议
PPPoA	PPP over ATM	ATM 网络承载 PPP 报文
PPPoEoA	PPP over Ethernet over ATM	ATM 网络承载 PPPoE 报文
PQ	Priority Queuing	优先级队列调度
PSN	Packet Switched Network	分组交换网络
PSNoATM	PSN over ATM	ATM 网络承载分组报文
PWE3	Pseudo-Wire Emulation Edge to Edge	端到端伪线仿真
PVC	Permanent Virtual Circuit	永久虚电路
PVP	Permanent Virtual Path	永久虚通路
Q		
QinQ	802.1Q in 802.1Q	802.1Q 嵌套 802.1Q
QoS	Quality of Service	服务质量
QPPB	QoS Policy Propagation on BGP	通过 BGP 传播 QoS 策略
R		
RDM	Russian Dolls Model	俄罗斯套娃模型
RED	Random Early Detection	随机早期检测
RFC	Request For Comments	请求注解/征求意见稿
RR	Round Robin	轮询调度
RSVP	Resource Reservation Protocol	资源预留协议
RT-VBR	Real Time-Variable Bit Rate	实时可变速率业务
RTN	Radio Transmission Node	无线传输节点
RTT	Round Trip Time	往返时间
S		
SCR	Sustain Cell Rate	可持续信元速率
SFD	Start-of-Frame Delimiter	帧起始定界符
SLA	Service Level Agreements	服务水平协议
SLS	Service Level Specification	服务等级规范

缩略语	英文全名	中文解释
SP	Strict Priority	严格优先级调度
SQ	Subscriber Queue	用户队列
SR	Service Router	业务路由器
STB	Set Top Box	机顶盒
SVC	Switched VC	交换虚通路
T		
TB	Target Blade	目的板
TC	Traffic Class	流量类别
TCA	Traffic Conditioning Agreement	流量控制协议
TCP	Transmission Control Protocol	传输控制协议
TCS	Traffic Conditioning Specification	流量控制说明
TE	Tranffic Engineering	流量工程
TLV	Type-Length-Value	类型长度值
TM	Traffic Manager	流量管理器
ToS	Type of Service	服务类型
TP	Traffic Policing	流量监管
TTL	Time To Live	生存时间
U		
UBR	Unspecified Bit Rate	未指定比特率业务
UCL	User Control List	基于用户的访问控制列表
UDP	User Datagram Protocol	用户数据报协议
UPC	Usage Parameter Control	使用参数控制
URPF	Unicast Reverse Path Forwarding	单播反向路由转发
V		
VBR	Variable Bit Rate	可变速率业务
VC	Virtual Circuit	虚通路
VCC	Virtual Circuit Connection	虚通路连接

缩略语	英文全名	中文解释
VCI	Virtual Channel Identifier	虚信道标识符
VE	Virtual Ethernet	虚拟以太网接口
VI	Virtual Interface	虚端口队列调度
VLAN	Virtual Local Area Network	虚拟局域网
VLL	Virtual Leased Line	虚拟租用线
VoD	Video on Demand	视频点播
VoIP	Voice over IP	IP 承载语音
VOQ	Virtual Output Queue	虚拟输出队列
VP	Virtual Path	虚通路
VPI	Virtual Path Identifier	虚通路标识符
VPN	Virtual Private Network	虚拟专用网
W		
WFQ	Weighted Fair Queuing	加权公平队列调度
WRED	Weighted Random Early Detection	加权随机早期检测
WRR	Weighted Round Robin	加权轮询调度
WWW	World Wide Web	万维网